Université des sciences et de la technologie d'Oran – USTO-MB
Faculté des Mathématiques et de l'Informatique - Département d'informatique
3ème Année LMD – S6 – SI & ISIL

Cours 1

Données semi structurées

L3 Informatique / FMI / USTO-MB / 2022-2023

Cours présenté par K. BELMABROUK

21/02/2025

1. Contexte et problématique

1.1. Rappels sur les bases de données

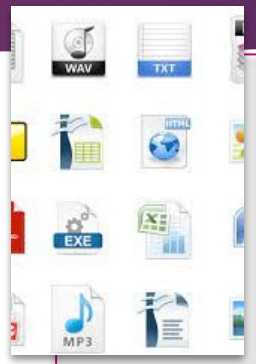

1.2. Multimédia et document

1.3. Hypermédia, Internet et Web

1.4. Problématique de ce cours

1.1. Rappels sur les bases de données

Définitions et types de bases de données

1.1. Rappels sur les bases de données

Base de données

- C’est un système de stockage et d'organisation de données structurées.
- Elle permet de stocker, gérer et accéder à des informations en utilisant des techniques telles que la normalisation, l'indexation et les requêtes SQL.
- Les bases de données peuvent être utilisées pour de nombreuses applications telles que la gestion de la clientèle, la gestion de la supply chain, la gestion de la santé et les analyses de données.

1.1. Rappels sur les bases de données

Système de Gestion de Bases de Données (SGBD)

- C’est un logiciel permettant de stocker la donnée dans une base de données en garantissant la qualité, la pérennité et la confidentialité des informations. La complexité des opérations de traitement des données ne nécessite pas d'être totalement connue par les utilisateurs.

1.1. Rappels sur les bases de données

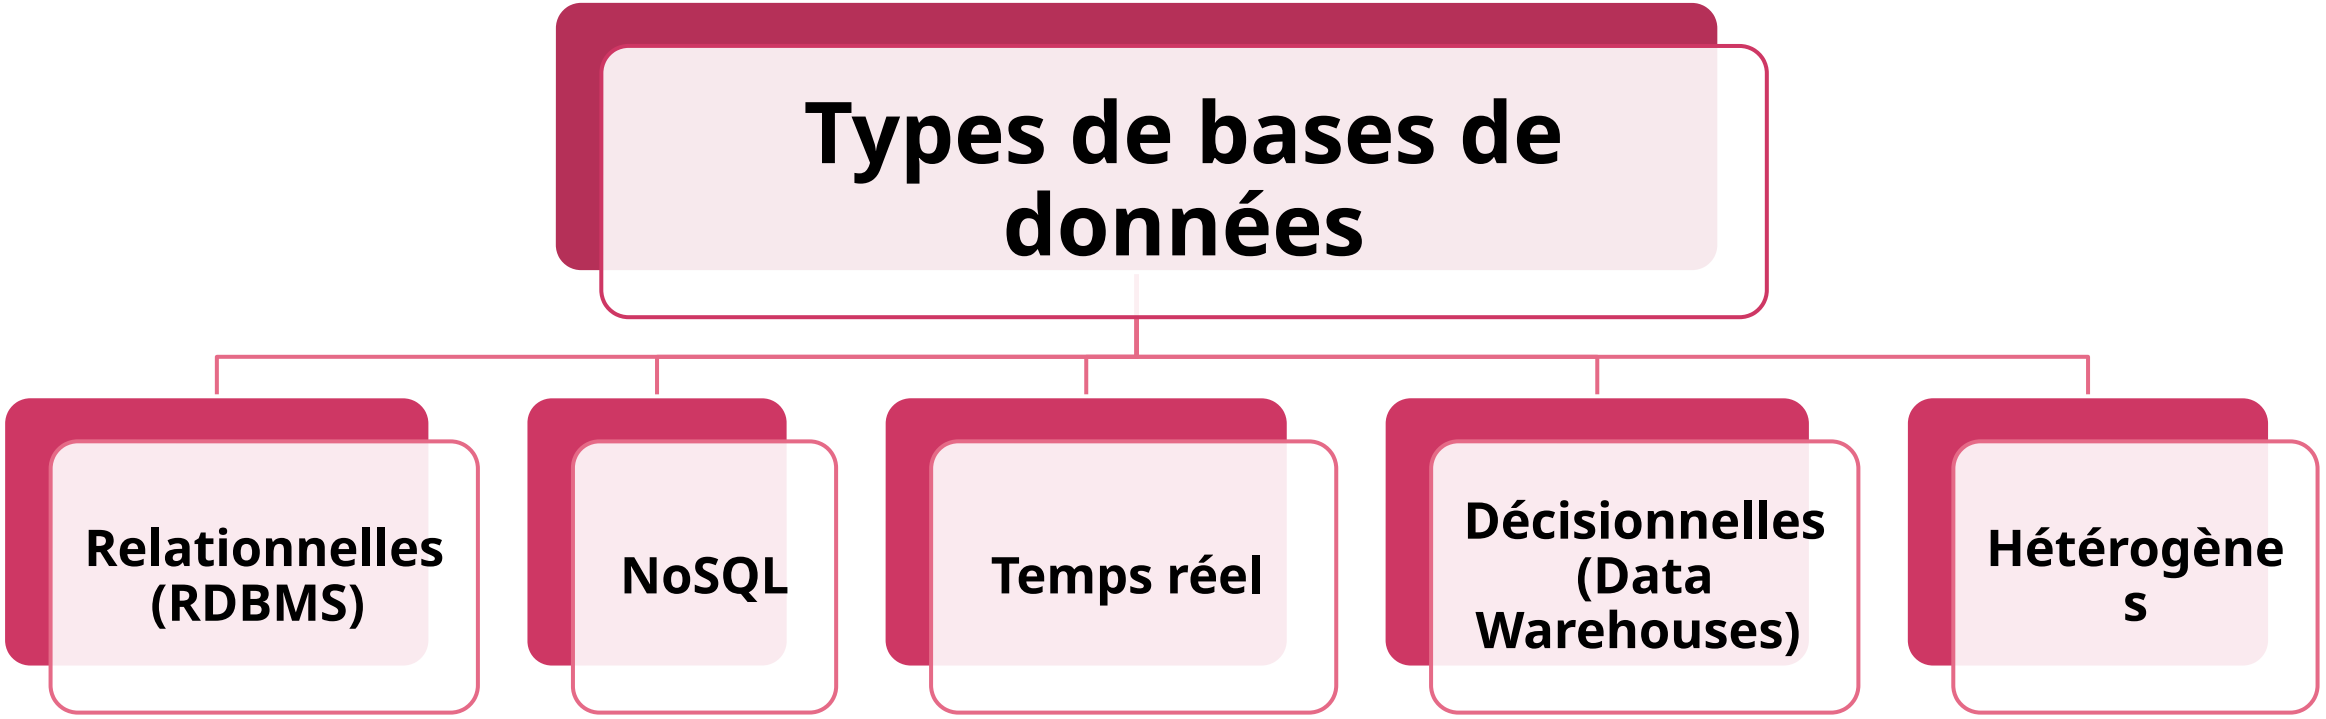

1.1. Rappels sur les bases de données

Types de bases de données

1. **Bases de données relationnelles (RDBMS) :** utilisent des tables pour stocker les données et des relations pour décrire les relations entre les tables (MySQL, Oracle, Microsoft SQL Server, etc).
2. **Bases de données NoSQL :** ne se basent pas sur les modèles de données relationnelles. Elles incluent les bases de données documentaires (MongoDB et CouchDB), les bases de données graphiques (Neo4j et GraphDB), les bases de données clé-valeur (Redis et Riak, etc).
3. **Bases de données en temps réel :** permettent la lecture et l'écriture rapides des données, souvent utilisées pour les applications en temps réel (jeux en ligne, systèmes de surveillance, etc).
4. **Bases de données décisionnelles (Data Warehouses) :** conçues pour les analyses de données et les prévisions, souvent utilisées dans les entreprises pour les décisions commerciales.
5. **Bases de données hétérogènes :** peuvent inclure des données provenant de différents types de bases de données et de sources, souvent utilisées pour les intégrations de systèmes complexes.

1.1. Rappels sur les bases de données

Niveaux de données

- **Niveau physique** (Système de gestion de fichier)
- **Niveau logique** (tables, vues, index, …)
- **Niveau de schéma** (types de données, les clés primaires, les clés étrangères)
- **Niveau de vue utilisateur (**formulaires, tableaux de bord, requêtes, …**)**

1.1. Rappels sur les bases de données

Niveaux de données

1. **Niveau physique :** ce niveau décrit comment les données sont stockées sur le support physique, tels que les disques durs, les disques SSD, les bandes, etc.
2. **Niveau logique :** ce niveau décrit comment les données sont organisées et stockées dans des structures logiques telles que les tables, les vues, les index, etc.
3. **Niveau de schéma :** ce niveau décrit les règles et les contraintes qui régissent la structure des données, telles que les types de données, les clés primaires, les clés étrangères, etc.
4. **Niveau de vue utilisateur :** ce niveau décrit comment les données sont présentées aux utilisateurs, telles que les formulaires, les tableaux de bord, les requêtes, etc.

1.1. Rappels sur les bases de données

Acteurs et rôles

- Analyste
- Concepteur de la base
- Administrateur de la base (DBA ou DataBase Administrator)
- Administrateur Système
- Utilisateurs

1.1. Rappels sur les bases de données

Acteurs et rôles

- **Analyste :** C’est un professionnel qui utilise les systèmes de base de données pour effectuer des analyses de données complexes et tirer des conclusions précises.
- **Concepteur de la base :** Il traduit le modèle conceptuel et un modèle logique exploitable par un SGBD donné. Il prépare les tables, les vues, les Schémas.
- **Administrateur de la base (DBA ou Data Base Administrator)** : Il a la responsabilité du fonctionnement du SGBD. Il crée les bases, gère les droits d'accès et les rôles.
- **Administrateur Système :** Il gère l'installation du système. Il dispose des droits de plus haut niveau sur la base (Super-user) et sur le système d'exploitation.
- **Utilisateurs :** Ils ont accès au système d'information défini dans le SGBD grâce aux schémas, tables et vues définies par le concepteur.

1.1. Rappels sur les bases de données

Clef primaire et clefs étrangères

- Clef primaire
- Clefs étrangères

1.1. Rappels sur les bases de données

Clef primaire et clef étrangère

- Une clé primaire est une colonne ou une combinaison de colonnes dans une table de base de données qui identifie de manière unique chaque enregistrement de la table. Elle garantit que les données sont uniques et empêche les doublons.
- Une clé étrangère est une colonne ou une combinaison de colonnes dans une table qui fait référence à une clé primaire dans une autre table. Elle permet de créer une relation entre les deux tables.
- En d'autres termes, la clé primaire est utilisée pour identifier de manière unique chaque enregistrement dans une table, tandis que la clé étrangère est utilisée pour créer des relations entre les tables.

1.2. Multimédia et documents multimédia

1.2. Multimédia et documents multimédia

- Le multimédia est l'utilisation de plusieurs formes de médias (**texte**, **audio**, **vidéo**, **image**) pour communiquer une information ou une histoire.
- Les documents multimédias incluent des **présentations, des films, des vidéos, des sites Web, des livres électroniques, des jeux vidéo**, etc.

1.2. Multimédia et documents multimédia

Concepts clés

1. **Types de médias :** les différents types de médias utilisés dans les documents multimédias comprennent le texte, l'audio, la vidéo, les images, les animations, etc.
2. **Compression de données :** la compression de données est utilisée pour réduire la taille des fichiers multimédias afin de les rendre plus faciles à stocker et à distribuer.
3. **Codecs :** les codecs sont utilisés pour coder et décoder les données audio et vidéo.
4. **Interactivité :** les documents multimédias peuvent être interactifs, permettant aux utilisateurs de prendre des décisions, de naviguer dans des contenus, etc.
5. **Édition :** les outils d'édition multimédia permettent de créer et de modifier des documents multimédias.
6. **Diffusion :** les documents multimédias peuvent être diffusés sur des supports tels que le Web, les CD/DVD, les télévisions, les théâtres, etc.

1.3. Hypermédia, Internet et Web

L'Hypermedia, l'Internet et le Web sont des concepts importants liés à l'informatique et aux technologies de l'information.

1.3. Hypermédia, Internet et Web

Hypermédia

- C'est un système de documents multimédias qui peut être relié les uns aux autres de manière dynamique pour permettre une navigation fluide entre les différentes informations.
- Les liens hypermédias permettent aux utilisateurs de se déplacer entre les différentes sections d'un document ou entre plusieurs documents sans avoir à utiliser un menu ou une liste de sommaires.

1.3. Hypermédia, Internet et Web

Internet

- C'est un réseau mondial de réseaux informatiques qui connecte des ordinateurs de différents endroits pour permettre l'échange de données et la communication.
- Il permet aux utilisateurs de se connecter à d'autres ordinateurs à partir de n'importe où dans le monde pour accéder à des informations, des services en ligne, etc.

1.3. Hypermédia, Internet et Web

Web (World Wide Web)

C’est un système de documents hypermédias qui fonctionne sur Internet et utilise HTTP (Hypertext Transfer Protocol) et HTML (Hypertext Markup Language) pour la communication et la présentation des informations.

1.4. Problématique de ce cours

1.4. Problématique de ce cours

- La problématique des données semi-structurées est un défi pour les professionnels de l'informatique qui travaillent avec des données non structurées telles que les e-mails, les messages texte, les documents de type mémo, les images, les vidéos, les médias sociaux, etc.
- Les données semi-structurées ne sont pas organisées de la même manière que les données structurées telles que les bases de données relationnelles. Elles ont une structure complexe et souvent incohérente, ce qui rend difficile leur stockage, leur analyse et leur utilisation.

1.4. Problématique de ce cours

Défis liés à la gestion des données semi-structurées

- **Stockage :** le stockage des données semi-structurées nécessite des systèmes de gestion de données spéciaux qui peuvent gérer la complexité et la variabilité de ces données.
- **Analyse :** l'analyse des données semi-structurées nécessite des algorithmes de traitement de la langue naturelle et d'apprentissage automatique pour extraire des informations utiles.
- **Métadonnées :** les métadonnées associées aux données semi-structurées peuvent être incomplètes ou erronées, ce qui peut rendre difficile l'identification et la recherche des informations.
- **Interopérabilité :** les données semi-structurées peuvent provenir de sources diverses et être codées dans des formats différents, ce qui peut rendre difficile leur intégration avec d'autres systèmes.

1.4. Problématique de ce cours

- Pour gérer efficacement les données semi-structurées, il est important de disposer de méthodologies, de techniques et d'outils pour traiter, stocker, analyser et intégrer ces données avec des systèmes existants.
- Les professionnels de l'informatique peuvent également tirer parti de technologies telles que le XML (eXtensible Markup Language) et le JSON (JavaScript Object Notation) pour représenter les données semi-structurées de manière structurée.

2. Documents et hyper documents multimédia

Cours suivant

Merci de votre attention!