Université des sciences et de la technologie d'Oran – USTO-MB
Faculté des Mathématiques et de l'Informatique - Département d'informatique
3ème Année LMD – S6 – SI & ISIL

Cours 3

Données semi structurées

L3 Informatique / FMI / USTO-MB / 2022-2023

Cours présenté par K. BELMABROUK

21/02/2025

3. Noyau XML

3.1. Introduction à XML

3.2. Structure de base

3.3. Domaines nominaux

3.4. Validation XML

3.1. Introduction à XML

XML (e**X**tensible **M**arkup **L**anguage) est un format de données informatiques utilisé pour :

- stocker et transmettre des informations structurées.
- échanger des données entre différents systèmes informatiques
- stocker des données dans un format standardisé qui peut être facilement lu et traité par une variété de systèmes.

3.1. Introduction à XML

But de XML

- Le but principal de XML est de permettre aux développeurs de **définir leur propre syntaxe pour les données**, ce qui leur permet de mieux **contrôler la structure des informations** et de **les utiliser de manière plus efficace**.
- XML est conçu pour être flexible, extensible et lisible à la fois par les ordinateurs et les êtres humains.
- En utilisant des balises et des attributs pour structurer les données, XML permet de **stocker des informations de manière claire et cohérente**, ce qui **facilite leur traitement** et **leur analyse** ultérieurs.

3.1. Introduction à XML

Utilisation de XML

- **Échange de données:** XML est utilisé pour échanger des données entre différents systèmes, applications et organisations.
- **Stockage de données:** XML peut être utilisé pour stocker des données structurées dans un format standardisé et facilement accessible.
- **Développement d'applications:** (Applications Web et applications mobiles).XML permet aux développeurs de créer des interfaces de données riches et faciles à utiliser.
- **Description de métadonnées:** XML peut être utilisé pour décrire des métadonnées, telles que les informations sur les documents, les images et les médias numériques.
- **Document électronique:** XML peut être utilisé pour représenter des documents électroniques (livres électroniques, articles scientifiques) pour une meilleure présentation et une meilleure accessibilité.

3.1. Introduction à XML

Principe clé de XML: **séparer** la **structure** d'un document de sa **présentation**

Avantages:

- **indépendance** entre les **outils de présentation** (browser) et les **outils de gestion de l'information**
- **différentes présentations** sont possibles pour le même document (t**ransformation**)
- **interrogation (semi-)structurée** de documents

3.2. Structure de base de XML

Un document XML comprend trois parties :

- le **prologue**, avec la déclaration XML, la DTD, des commentaires, des instructions de traitements (optionnels)
- un **élément racine** avec son contenu
- un **épilogue** avec **des commentaires**, ou **des instructions de traitements** (optionnels)

Le contenu du document proprement dit est le contenu de l'élément racine.

3.2. Structure de base de XML

```xml
<?xml version="1.0" encoding="UTF-8"?>
<users>
  <user Name="mscott">
    <DisplayName>SCOTT Michael</DisplayName>
    <Mail>mscott@dundermifflin.inc</Mail>
    <TelephoneNumber>555</TelephoneNumber>
  </user>
  <user Name="dschrute">
    <DisplayName>SCHRUTE Dwight</DisplayName>
    <Mail>dschrute@dundermifflin.inc</Mail>
    <TelephoneNumber>410</TelephoneNumber>
  </user>
  <user Name="jhalpert">
    <DisplayName>HALPERT Jim</DisplayName>
    <Mail>jhalpert@dundermifflin.inc</Mail>
    <TelephoneNumber>411</TelephoneNumber>
  </user>
  <user Name="rhoward">
    <DisplayName>HOWARD Ryan</DisplayName>
    <Mail>temp@dundermifflin.inc</Mail>
    <TelephoneNumber>404</TelephoneNumber>
  </user>
</users>
```

Le prologue

La racine

L' épilogue

3.2. Structure de base de XML

```xml
<?xml version="1.0" encoding="UTF-8"?>
<!-- Déclaration de la version d'XML et de l'encodage -->

<!-- Racine du document -->
<livres>

  <!-- Un élément livre -->
  <livre>
    <!-- Attributs du livre -->
    <titre langue="français">Les Misérables</titre>
    <auteur>Victor Hugo</auteur>
    <pages>1488</pages>
    <description>Roman historique publié en 1862.</description>
  </livre>

  <!-- Un autre élément livre -->
  <livre>
    <!-- Attributs du livre -->
    <titre langue="anglais">To Kill a Mockingbird</titre>
    <auteur>Harper Lee</auteur>
    <pages>324</pages>
    <description>Roman publié en 1960.</description>
  </livre>

</livres>
```

Le prologue

Un commentaire

Un autre commentaire

L' épilogue

3.2. Structure de base de XML

```
1   <?xml version="1.0"?>
2   <root>
3     <element attribute="value">Element content</element>
4   </root>
```

- La première ligne déclare **le type de document XML** et la **version de XML** utilisée
- Le '**<root>**' est la racine du document et contient tous les autres éléments
- Les '**<element>**' représentent les différents blocs de données dans le document
- Les **attributs** sont utilisés pour ajouter des informations supplémentaires à un élément

3.2. Structure de base de XML

- Balises
- Attributs
- Nœuds
- Exemples

3.2. Structure de base de XML

- **Balises**
- Les balises définissent la structure des données et sont entourées de crochets angulaires.
- Par exemple, la balise "**<book>**" peut être utilisée pour définir un livre dans une bibliothèque en ligne.

3.2. Structure de base de XML

- **Attributs**
- Les attributs fournissent des **informations supplémentaires** sur les balises.
- Par exemple, un livre peut avoir un attribut "**title**" pour définir son titre et un attribut "**author**" pour définir son auteur.
- Les attributs sont définis à l'intérieur des balises et suivent ce format: **attribut="valeur"**.

3.2. Structure de base de XML

- **Nœuds**
- Les nœuds représentent les unités de données dans l'arbre de structure XML.
- Les **balises** et les **attributs** sont des **types de nœuds**.
- Par exemple, le nœud "**book**" peut contenir des nœuds "**title**" et "**author**".

3.2. Structure de base de XML

Exemple 1

Dans cet exemple, la balise "**library**" représente la bibliothèque en ligne, les balises "book" représentent les livres dans la bibliothèque et les attributs "**title**" et "**author**" fournissent des informations supplémentaires sur les livres. Les nœuds "**description**" décrivent les livres.

```
1  <library>
2    <book title="XML: A Manager's Guide"  author="Kevin Dick">
3      <description>The book provides a non-technical overview of XML and its uses,
       including data exchange, data storage, and application development</
       description>
4    </book>
5    <book title="XML: Une Approche Pratique" author="Michel Rodriguez">
6      <description>C'est une introduction complète et pratique à XML (Extensible
       Markup Language).</description>
7    </book>
8  </library>
```

3.2. Structure de base de XML

Exemple 2

Cet exemple définit un livre avec son **titre**, son **auteur**, **l'année de publication** et l'**éditeur**. Les éléments XML sont enfermés entre des **balises**, qui définissent le **nom de l'élément** et **son contenu**.

```
1  <livre>
2    <titre>La Guerre et la Paix</titre>
3    <auteur>Léon Tolstoï</auteur>
4    <année>1869</année>
5    <éditeur>Maison d'édition française</éditeur>
6  </livre>
```

3.2. Structure de base de XML

Document bien formé (Règles)

1) Avoir une structure en arborescence, avec racine unique
2) Chaque élément doit avoir une balise d'ouverture et une balise de fermeture
3) Tous les éléments doivent être correctement imbriqués
4) Les noms des éléments et des attributs doivent être
5) Tous les attributs doivent avoir une valeur entre guillemets
6) Les éléments doivent avoir une seule valeur ou un contenu sous forme d'enfant ou de texte.
7) Les entités XML réservées doivent être correctement échappées, comme par exemple "<" pour "<".

3.2. Structure de base de XML

Exercice

- Modéliser un **catalogue de produits** d'une **entreprise** de **vente en ligne**.
- Le **catalogue** contient des informations sur les **produits** tels que le **nom**, la **description**, la **catégorie**, le **prix** et **une image**.
- Chaque produit appartient à une seule catégorie et peut être acheté en plusieurs quantités.
- Les **catégories** sont également décrites par leur **nom** et une **description**.
- Le but de cet exercice est de concevoir un **modèle XML** qui reflète ces informations et les **structure** de **manière cohérente** et **logique**.

3.2. Structure de base de XML

Solution

```xml
<catalogue>
  <categories>
    <category id="1">
      <name>Electronique</name>
      <description>Produits électroniques tels que les téléphones, ordinateurs, etc.</description>
    </category>
    <category id="2">
      <name>Vêtements</name>
      <description>Vêtements pour hommes, femmes et enfants</description>
    </category>
    ...
  </categories>
  <products>
    <product id="1">
      <name>iPhone</name>
      <description>Téléphone portable haut de gamme</description>
      <category_id>1</category_id>
      <price>1000</price>
      <image>iPhone.jpg</image>
      <quantity>100</quantity>
    </product>
    <product id="2">
      <name>Chemise blanche</name>
      <description>Chemise classique pour homme en coton</description>
      <category_id>2</category_id>
      <price>50</price>
      <image>Chemise_blanche.jpg</image>
      <quantity>200</quantity>
    </product>
    ...
  </products>
</catalogue>
```

3.3. Domaines nominaux (Espaces de noms)

- Les domaines nominaux XML ou les espaces de noms sont des ensembles de **valeurs prédéfinies** qui peuvent être attribuées à des éléments ou des attributs XML dans un document XML.
- Les domaines nominaux peuvent être définis dans un schéma XML ou dans une DTD.

3.3. Domaines nominaux

- ***Par exemple***, un domaine nominal peut être défini pour un élément "**genre**" pour qu'il ne puisse prendre que les valeurs "**homme**" ou "**femme**".
- De cette façon, le parseur XML peut vérifier que les **valeurs** pour l'élément "**genre**" se trouvent bien dans le domaine nominal approprié, ce qui garantit la qualité et la fiabilité des données.

3.3. Domaines nominaux

Exemples Un domaine nominal pour l'élément:

- **"Genre" :** peut être défini pour accepter uniquement les valeurs "**homme**" ou "**femme**".
- **"État civil" :** peut être défini pour accepter uniquement les valeurs "**marié**", "**célibataire**", "**divorcé**" ou "**veuf**".
- **"Monnaie" :** peut être défini pour accepter uniquement les valeurs "**USD**", "**EUR**", "**GBP**" ou "**DA**".

3.3. Domaines nominaux

ns: **n**ame **s**pace

Déclaration d'espaces de noms

- Pour déclarer un espace de noms sur un élément, utilisez l'attribut **xmlns:<name>=<"uri">** où <name> est le préfixe de l'espace de noms et <"**uri**"> fait référence à l'**URI** qui identifie l'espace de noms.
- Une fois que vous avez déclaré le préfixe, vous pouvez l'utiliser pour qualifier des éléments et des attributs dans un document XML et les associer à un URI d'espace de noms.
- Le préfixe de l'espace de noms étant utilisé dans la totalité d'un document, il doit être court de préférence.

3.3. Domaines nominaux

- Cet exemple définit deux éléments **BOOK**. Le premier élément est qualifié par le préfixe **mybook**, tandis que le deuxième élément est qualifié par le préfixe **bb**.
- Chaque préfixe est associé à un URI d'espace de noms différent :

```
<mybook:BOOK xmlns:mybook="http://www.contoso.com/books.dtd">
    <bb:BOOK xmlns:bb="urn:blueyonderairlines" />
</mybook:BOOK>
```

- Pour indiquer qu'un élément fait partie d'un espace de noms particulier, ajoutez-lui le préfixe de l'espace de noms.
- Par exemple, si un élément **Author** appartient à l’espace **mybook** de noms, il est déclaré en tant que <**mybook:Author**>.

3.3. Domaines nominaux (Espaces de noms)

3.3. Domaines nominaux

Exemples de « NameSpace »

- **« DocBook » : URI** http://docbook.org/ns/docbook.
- **« MathML » : URI** https://www.w3.org/1998/Math/MathML/
- **« XML Schema » : URI** https://www.w3.org/2001/XMLSchema

3.3. Domaines nominaux

- En plus de garantir la **qualité** et la **fiabilité** des données, les domaines nominaux peuvent également améliorer la **lisibilité** et la **compréhension** du **document XML** en définissant les **types de données** pour les **éléments** et les **attributs.**

3.4. Validation XML

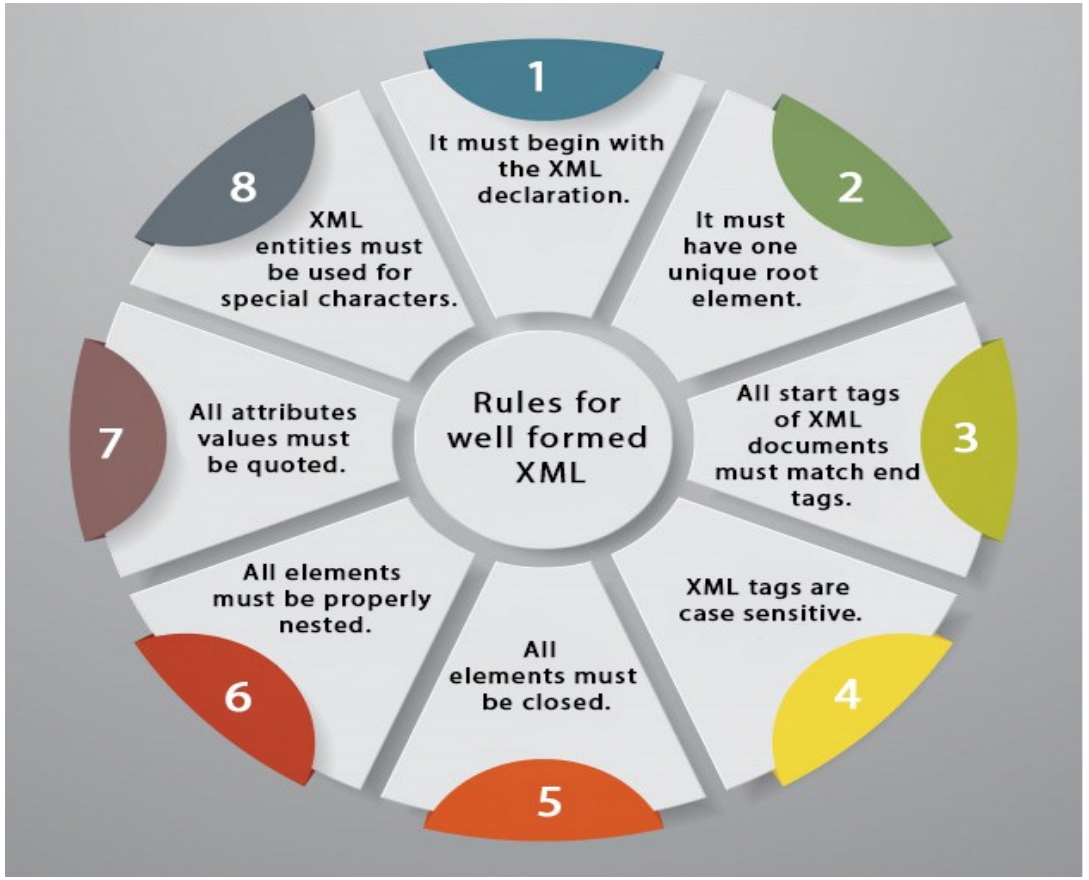

3.4. Validation XML

- La validation XML est le processus de **vérification** d'un document XML pour s'assurer qu'il est **conforme** à une définition spécifique, telle qu'une DTD ou un schéma XML.
- Cela comprend la vérification de la **syntaxe**, de la **structure** et de la **sémantique** du document pour s'assurer que toutes les **règles** définies dans la définition sont **respectées**.

3.4. Validation XML

- **DTD** (**Document Type Definition**) est une méthode de validation XML qui définit les éléments, les attributs et la structure d'un document XML.
- Les documents XML doivent se conformer à la DTD spécifiée pour être considérés valides.

3.4. Validation XML


```
1  <!DOCTYPE catalogue [
2    <!ELEMENT catalogue (livre+)>
3    <!ELEMENT livre (titre, auteur, annee, prix)>
4    <!ELEMENT titre (#PCDATA)>
5    <!ELEMENT auteur (#PCDATA)>
6    <!ELEMENT annee (#PCDATA)>
7    <!ELEMENT prix (#PCDATA)>
8    <!ATTLIST livre ISBN CDATA #REQUIRED>
9  ]>
```

Exemple de DTD

Avec cette DTD, un document XML valide aura une structure similaire à ceci

```
1  <catalogue>
2    <livre ISBN="123456">
3      <titre>Titre du livre</titre>
4      <auteur>Auteur du livre</auteur>
5      <annee>Année de publication</annee>
6      <prix>Prix du livre</prix>
7    </livre>
8    <!-- Plusieurs autres livres peuvent être ajoutés ici -->
9  </catalogue>
```

3.4. Validation XML

- Les **schémas XML** (**XML Schema**) sont une autre méthode de validation XML qui offre une plus grande flexibilité et richesse de fonctionnalités par rapport à DTD.
- Les **schémas XML** peuvent définir des **types de données personnalisés**, des **contraintes** sur les éléments et les attributs, ainsi que des **règles de validation plus complexes**.

3.4. Validation XML

```xml
<?xml version="1.0" encoding="UTF-8"?>
<xs:schema xmlns:xs="http://www.w3.org/2001/XMLSchema">

  <xs:element name="personne">
    <xs:complexType>
      <xs:sequence>
        <xs:element name="nom" type="xs:string"/>
        <xs:element name="prenom" type="xs:string"/>
        <xs:element name="age" type="xs:positiveInteger"/>
      </xs:sequence>
    </xs:complexType>
  </xs:element>

</xs:schema>
```

Exemple de fichier XML Schema

Ce schéma XML définit un élément « personne » qui a un type complexe comprenant une séquence de trois éléments « nom », « prenom » qui sont définis comme étant de type « **xs:string** » et « age » qui est défini de type « **xs:positiveInteger** »

4. Galaxie XML

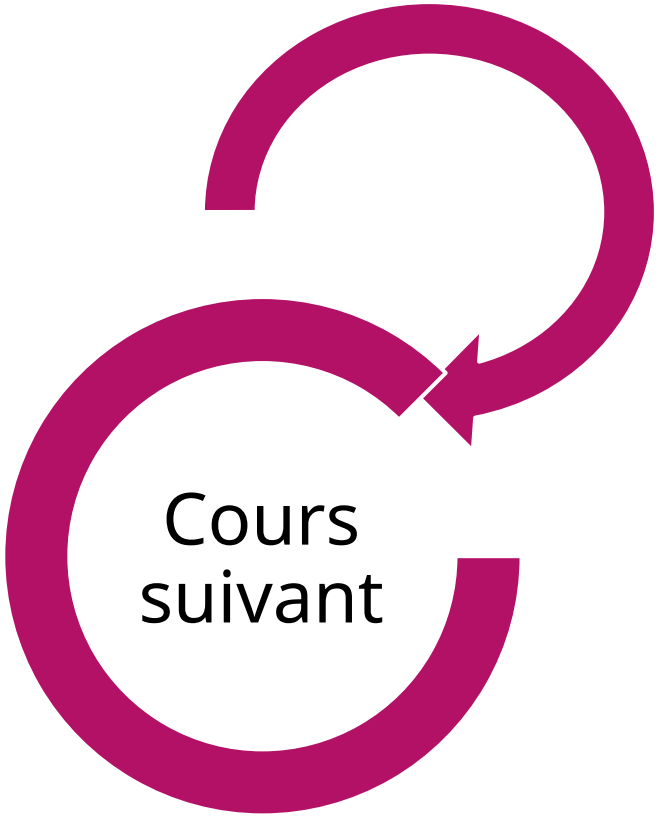

Merci de votre attention!