Introduction

Ce chapitre est dédié à l'introduction de quelques notions de bases de statistique multidimensionnelle comme la nature des variables et leurs codages adéquats, les tableaux de données, les mesures de ressemblance/dissemblance (distances), les tableaux de fréquences et certains tableaux spéciaux tels que les profiles lignes et profiles colonnes. Il est important de connaitre les différentes métriques utilisées pour le calcul de la distance. La réduction des tableaux de données reste un vrai challenge qui sera introduit dans ce chapitre en définissant le tableau de BURT et la réduction par regroupement.

1.Mesures de similarité

- **Distance**

  Soit E un ensemble de N individus caractérisés par p variables, une distance est une application de $E \times E$ dans $\Re^+$ telle que pour tout couple d'individus i et j appartenant à E:

$$\begin{cases} d(i,j) = d(j,i) \\ d(i,j) \geq 0 \\ d(i,i) = 0 \Leftrightarrow i = j \\ d(i,j) \leq d(i,k) + d(k,j) \end{cases}$$

  Une mesure de distance bien connue est la distance euclidienne qui est utilisée pour des variables mesurables (quantitatives).

  Soient $X\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ et $Y\begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$ deux individus de $\Re^2$

$$d(X,Y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2} \qquad (1)$$

  D'une façon générale, la distance est munie d'une métrique M et elle est définie par :

$$d^2(X,Y) = (X-Y)^t M (X-Y) \qquad (2)$$

  Si M est égale à la matrice identité (dans $\Re^2$ la matrice identité$= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$), l'équation (2) est calculée selon l'écriture de l'équation (1).

  Une autre écriture de l'équation (2) est :

  $d^2 = \|X - Y\|_M^2$ communément appelée norme du vecteur *(X-Y)*.

- **Mesures de ressemblance (similarité)**

  Généralement toute mesure nous informant sur la ressemblance (similarité ou proximité) ou la dissemblance (différence ou éloignement) entre les individus et qui ne vérifie pas les conditions nécessaires pour une distance est appelée mesure de ressemblance ou mesure de dissemblance. Une autre appellation de cette mesure est mesure de similarité ou mesure de dissimilarité.

Prenons le cas de vecteurs binaires. En analyse de données, C'est vecteurs sont généralement issus d'un codage appelé codage disjonctif des modalités des variables qualitatives. Le calcul de la similarité de deux vecteurs binaires nécessite l'évaluation de certains paramètres comme suivant :

Soient $X\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_j \\ \vdots \\ x_p \end{pmatrix}$ $et\ Y\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_j \\ \vdots \\ y_p \end{pmatrix}$ deux vecteurs binaires (x_j et y_j sont des éléments binaires : 0 ou 1)

Soient les paramètres :

- **a** représente le nombre de fois où x_j =1 et y_j=1.
- **b** représente le nombre de fois où x_j =0 et y_j=1.
- **c** représente le nombre de fois où x_j =1 et y_j=0.
- **d** représente le nombre de fois où x_j =0 et y_j=0.

↶	1	0
1	**a**	**b**
0	**c**	**d**

Plusieurs indices de similarité ont été proposés. Ces derniers combinent de diverses manières les quatre nombres (**a, b, c** et **d**) associés à un couple d'individus (vecteurs binaires *I* et *J*):

1) L'indice de Jaccard : $S(I,J)=\dfrac{a}{a+b+c}$
2) L'indice de Dice : $S(I,J)=\dfrac{2a}{2a+b+c}$
3) L'indice de Russsel et Rao : $S(I,J)=\dfrac{a}{a+d+b+c}$
4) L'indice de Rogers et Tanimoto : $S(I,J)=\dfrac{a+d}{a+d+2(b+c)}$
5) L'indice de Jaccard : $S(I,J)=\dfrac{2a}{2a+b+c}$
6) L'indice de Sokal et Sneath : $S(I,J)=\dfrac{a}{a+2(c+d)}$
7) L'indice de Kulzinsky : $S(I,J)=\dfrac{a}{c+d}$

- **Type de variables**

Rappelons ici qu'un individu est décrit par un ensemble de caractéristiques appelées **variables**.

On distingue principalement deux types de variables :

- **Variables quantitatives** ce sont toutes les variables mesurables (des mesures ou des quantités). Par exemple Age, poids et taille. Les modalités de ces variables s'expriment par des nombres réels sur lesquels il est possible d'appliquer opérations arithmétiques (addition, soustraction, …).

- **Variables qualitatives** ce sont toutes les variables non mesurables. Par exemple couleur des yeux, la profession, la situation familiale, code. Les modalités de ces variables s'expriment généralement par une chaine de caractères numériques, alphabétiques ou alphanumériques. Selon que les modalités de la variable suivent une relation d'ordre ou pas, nous pouvons distinguer deux types de variables qualitatives. Les variables **qualitatives nominales (sans relation d'ordre**) telles que la profession (agent de sécurité, enseignant, agriculteur, …) et les variables **qualitatives ordinales** (**avec une relation d'ordre**) telles que la mention obtenu au baccalauréat (passable, assez bien, bien,…).

Codage disjonctif des variables qualitatives nominales

$$\mathbf{N}\left(x_{ij}\right)=\left(0,0,0\cdots,1,0,0\cdots 0\right):\begin{cases}1 & \textit{pour la coordonnée de rang } x_{ij}\\ 0 & \textit{ailleur}\end{cases}$$

1.2.2 Codage disjonctif des variables qualitatives ordinales

$$\mathbf{O}\left(x_{ij}\right)=\left(1,1,1,1,0,0\cdots 0\right):\begin{cases}1 & \textit{pour toute les coordonnées jusqu'au rang } x_{ij}\\ 0 & \textit{ailleur}\end{cases}$$

Les deux fonctions précédemment mentionnées sont explicité dans l'exemple suivant :
Soit le tableau décrivant la couleur, le poids et la forme de dix produits quelconques.

Produit	**Couleur**	**Poids**	**Forme**
P1	Bleu	Lourd	Rond
P2	Blanc	Léger	Carré
P3	Vert	Léger	Rond
P4	Bleu	Très lourd	Carré
P5	Blanc	Léger	Rond
P6	Vert	Très lourd	Carré
P7	Bleu	Léger	Rond
P8	Blanc	Très lourd	Carré
P9	Vert	Très lourd	Rond
P10	Bleu	Lourd	Carré

Codage disjonctif :

- Couleur (bleu, blanc, vert) : variable qualitative nominale qui a 3 modalités. La fonction de codage se fera de la manière suivante:

  N (bleu)=(1,0,0) , N (blanc)=(0,1,0) et N (vert)=(0,0,1) ;

- **Poids (**Léger, Lourd, Très lourd) possède 3 modalités avec Léger <Lourd <Très lourd. Donc la variable qualitative Poids est une variable qualitative ordinale.
  O (Léger)= (1, 0, 0) ; O(Lourd)= (1, 1, 0) ; O (Très lourd)= (1, 1, 1)
- **Forme (**Rond, carré) : possède deux modalités et elle est qualitative nominale
  N (Rond) =(1, 0) ; N (Carré) =(0, 1)

Notons ici que l'ordre des modalités est aléatoire pour les variables Forme et Couleur. Par contre, pour la variable Poids, celui-ci est imposé par la relation d'ordre.

Après codage, le tableau résultant est :

	Couleur			Poids			Forme	
	V1	**V2**	**V3**	**V4**	**V5**	**V6**	**V7**	**V8**
P1	**1**	**0**	**0**	**1**	**1**	**0**	**1**	**0**
P2	**0**	**1**	**0**	**1**	**0**	**0**	**0**	**1**
P3	**0**	**0**	**1**	**1**	**0**	**0**	**1**	**0**
P4	**1**	**0**	**0**	**1**	**1**	**1**	**0**	**1**
P5	**0**	**1**	**0**	**1**	**0**	**0**	**1**	**0**
P6	**0**	**0**	**1**	**1**	**1**	**1**	**0**	**1**
P7	**1**	**0**	**0**	**1**	**0**	**0**	**1**	**0**
P8	**0**	**1**	**0**	**1**	**1**	**1**	**0**	**1**
P9	**0**	**0**	**1**	**1**	**1**	**1**	**1**	**0**
P10	**1**	**0**	**0**	**1**	**1**	**0**	**0**	**1**

Nous sommes passés d'un tableau 10x3 (10 lignes et 3 colonnes) à un tableau 10x8.

2.Type de tableaux de données

- **Tableau individus/variables** : ce type de tableau contient n lignes et p colonnes de telle sorte les lignes représentent les individus, tandis que les colonnes représentent les variables qui sont des caractéristiques des individus.
  Exemple : le tableau précédent (Tableau des 10 produits) est un tableau Individus/Variables

- **Tableau de contingence** : est un tableau d'effectifs obtenus en croisant les modalités de deux variables définies sur une même population de n individus. Ce tableau est dit tableau de type variable/variable ou tableau de correspondances (comptant les correspondances entre les modalités de deux variables).

Exemple (Tableaux de contingences déduits du tableau individus/variables**):**

- **Tableaux de contingence : (Couleur/ Poids)**

Poids / Couleur	Léger	Lourd	Très Lourd
Bleu	**1**	**2**	**1**
Blanc	**2**	**0**	**1**
Vert	**1**	**0**	**2**

- **Tableaux de contingence : (Couleur/ Formes)**

Forme / Couleur	Rond	Carré
Bleu	**2**	**2**
Blanc	**1**	**2**
Vert	**2**	**1**

- **Tableaux de contingence : (Poids/Formes)**

Forme / Poids	Rond	Carré
Léger	**3**	**1**
Lourd	**1**	**1**
Très Lourd	**1**	**3**

Notons ici que pour ce type de tableau les lignes et les colonnes jouent un **rôle symétrique**.

- **Tableau de distance** : ce tableau est symétrique tel que les entrées des lignes et les entrées des colonnes représentent les individus et toute case d_{ij} représente la distance ou la mesure de similarité entre les deux individus I_i et I_j.

Exemple : Soit un tableau Ind/Var obtenu après codage disjonctif :

	Réponse 1		Réponse 2	
	V1	**V2**	**V3**	**V4**
I1	**1**	**0**	**1**	**0**
I2	**1**	**0**	**0**	**1**
I3	**0**	**1**	**1**	**0**
I4	**0**	**1**	**0**	**1**
I5	**1**	**0**	**1**	**0**
I6	**1**	**0**	**0**	**1**
I7	**0**	**1**	**1**	**0**

Soit la mesure de similarité suivante : $d(I,J) = \dfrac{b+c}{a+b+c+d}$

Cette mesure nous informe sur la différence (comme une distance), c'est-à-dire que plus les individus sont différents plus la mesure est grande et plus ils sont proches (Se ressemblent) plus la mesure est petite. Dans notre cas, cette mesure ne prend que trois valeurs possibles (0, ½ et 1). Le tableau de distance résultant est :

d	**I1**	**I2**	**I3**	**I4**	**I5**	**I6**	**I7**
I1	**0**	**1/2**	**1/2**	**1**	**0**	**1/2**	**1/2**
I2	**1/2**	**0**	**1**	**1/2**	**1/2**	**0**	**1**
I3	**1/2**	**1**	**0**	**1/2**	**1/2**	**1**	**0**
I4	**1**	**1/2**	**1/2**	**0**	**1**	**1/2**	**1/2**
I5	**0**	**1/2**	**1/2**	**1**	**0**	**1/2**	**1/2**
I6	**1/2**	**0**	**1**	**1/2**	**1/2**	**0**	**1/2**
I7	**1/2**	**1**	**0**	**1/2**	**1/2**	**1/2**	**0**

- **Tableau de BURT** : sert à réduire le tableau de codage disjonctif complet en calculant le produit matriciel : $\boldsymbol{B=X^t.X}$. Tel que X est le tableau de codage disjonctif complet (Aucune variable qualitatif ordinale). L'analyse du tableau $\boldsymbol{B}$ ainsi obtenu est équivalente à l'analyse du tableau $\boldsymbol{X}$.

3.Transformation d'un tableau de contingence en tableaux de profiles

Un tableau de contingence (Var/Var) est généralement transformé en tableaux de type Ind/Var. Cette transformation est nécessaire pour l'analyse factorielle que nous développerons dans le chapitre suivant.

Soit le tableau de contingence suivant :

	y_1	y_2	.....	y_j	.....	y_p
x_1						
x_2						
. .						
x_i				K_{ij}		
. .						
x_n						

Tableau de fréquences : ce tableau est obtenu après normalisation du tableau de contingence en divisant par K (le nombre total d'individus) c.à.d. $f_{ij} = \frac{K_{ij}}{K}$ avec $K = \sum_i \sum_j Kij$.

Puis nous ajoutons une ligne et une colonne correspondants aux fréquences marginales $f_{i\bullet}$ et $f_{\bullet j}$ et calculées de la manière suivante :

$$f_{i.} = \sum_{j=1}^{p} f_{ij} \text{ et } f_{.j} = \sum_{i=1}^{n} f_{ij}$$

Tableau des profils lignes F_J^i : est un tableau des fréquences **conditionnelles** $F_J^i = \frac{f_{ij}}{f_{i\bullet}}$, cette valeur représente la probabilité d'avoir la modalité j de la variable Y sachant que la modalité de la variable X est

i. Le tableau de profil est considéré comme tableau Ind/Var et forme donc un nuage de points (Individus) dans l'espace avec leurs poids. Le nuage de point est un couple composé de cordonnées des individus F_J^i associés à leurs poids $f_{i\bullet}$, noté par : $N(I)=\left\{\left(F_J^i, f_{i\bullet}\right), i=1.....n\right\}$.

Tableau des profils colonnes : F_I^j : est un tableau des fréquences **conditionnelles** $F_I^j=\frac{f_{ij}}{f_{\bullet j}}$, cette valeur représente la probabilité d'avoir la modalité i de la variable X sachant que la modalité de la variable Y est j. Le nuage de point est un couple composé de cordonnées des individus F_I^j associés à leurs poids $f_{\bullet j}$, noté par : $N(J)=\left\{\left(F_I^j, f_{\bullet j}\right), j=1.....p\right\}$.

Exemple : soit le **tableau de contingence : (Couleur/ Formes) ;** $K=\sum_i\sum_j Kij=10$

Forme / Couleur	Rond	Carré
Bleu	**2**	**2**
Blanc	**1**	**2**
Vert	**2**	**1**

- **Tableau de fréquences :** $f_{ij}=\frac{K_{ij}}{K}$ est :

f_{ij}	f_{i1}	f_{i2}	$f_{i.}$
f_{1j}	**2/10**	**2/10**	**4/10**
f_{2j}	**1/10**	**2/10**	**3/10**
f_{3j}	**2/10**	**1/10**	**3/10**
$f_{.j}$	**5/10**	**5/10**	**1**

- **Tableau des profils lignes :** F_J^i : $F_J^i=\frac{f_{ij}}{f_{i.}}$

F_J^i	F_1^i	F_2^i	$f_{i.}$
F_J^1	**2/4**	**2/4**	**4/10**
F_J^2	**1/3**	**2/3**	**3/10**
F_J^3	**2/3**	**1/3**	**3/10**

$$N(I)=\left\{\left(F_J^i, f_{i.}\right), i=1.....n\right\}=\left\{[(2/4;2/4),4/10] \;\; ;[(1/3;2/3),3/10] \;; [(2/3;1/3),3/10]\right\}$$

- **Tableau des profils colonnes :** F_I^j : $F_I^j=\frac{f_{ij}}{f_{.j}}$

F_I^j	F_I^1	F_I^2
F_1^j	**2/5**	**2/5**
F_2^j	**1/5**	**2/5**
F_3^j	**2/5**	**1/5**
$f_{.j}$	**5/10**	**5/10**

$$N(J)=\left\{\left(F_I^j, f_{.j}\right), j=1.....p\right\}=\left\{[(2/5;1/5;2/5),5/10] \quad ;[(2/5;2/5;1/5),5/10] \ ;\right\}$$

N(I) et *N(J)* représentent les nuages de points des profils lignes et profiles colonnes respectivement.

La distance entre profils :

Pour déterminer la ressemblance entre deux individus de profils lignes ou profiles colonnes, on calcule la distance munie d'une métrique $\aleph^2$ qui est définie par :

- La matrice diagonale $D_{\frac{1}{f_{\bullet j}}}$ définie la métrique pour le nuage $N(I)$, tandis que la matrice diagonale $D_{\frac{1}{f_{i\bullet}}}$ définie la métrique pour le nuage $N(J)$. Alors la distance entre deux individus profils lignes est donnée par : $d^2\left(F_J^i, F_j^{i'}\right)=\left\|F_J^i-F_j^{i'}\right\|^2_{D_{\frac{1}{f_{\cdot j}}}}=\sum_{j=1}^{p}\left(F_J^i-F_j^{i'}\right)^2/f_{.j}$,

  tandis que la distance entre deux individus profils colonnes est donnée par : $d^2\left(F_I^j, F_i^{j'}\right)=\left\|F_I^j-F_i^{j'}\right\|^2_{D_{\frac{1}{f_{i\cdot}}}}=\sum_{i=1}^{n}\left(F_I^j-F_I^{j'}\right)^2/f_{i.}$

Exemple :

- **Le tableau de distance pour le nuage $N(I)$:**

Soit le Tableau des profils lignes : F_J^i : $F_J^i=\dfrac{f_{ij}}{f_{i.}}$

F_J^i	F_1^i	F_2^i	$f_{i.}$
F_J^1	**2/4**	**2/4**	**4/10**
F_J^2	**1/3**	**2/3**	**3/10**
F_J^3	**2/3**	**1/3**	**3/10**

$$N(I)=\left\{\left(F_J^i, f_{i.}\right), i=1.....n\right\}=\left\{[(2/4;2/4),4/10] \quad ;[(1/3;2/3),3/10] \ ;[(2/3;1/3),3/10]\right\}$$

$f_{.j}=\begin{pmatrix}5/10\\5/10\end{pmatrix}$ alors :

$$d^2\left(F_J^1,F_J^2\right)=\left\|F_J^1-F_J^2\right\|^2_{D_{\frac{1}{f_{\cdot j}}}}=\sum_{j=1}^{p}\left(F_J^1-F_J^2\right)^2/f_{.j}=\frac{(2/4-1/3)^2}{5/10}+\frac{(2/4-2/3)^2}{5/10}=\frac{1}{9}$$

$$d^2\left(F_J^1,F_J^3\right)=\left\|F_J^1-F_J^3\right\|^2_{D_{\frac{1}{f_{\cdot j}}}}=\sum_{j=1}^{p}\left(F_J^1-F_J^3\right)^2/f_{.j}=\frac{(2/4-2/3)^2}{5/10}+\frac{(2/4-1/3)^2}{5/10}=\frac{1}{9}$$

$$d^2\left(F_J^2,F_J^3\right)=\left\|F_J^2-F_J^3\right\|^2_{D_{\frac{1}{f_{.j}}}}=\sum_{j=1}^{p}\left(F_J^2-F_J^3\right)^2/f_{.j}=\frac{(1/3-2/3)^2}{5/10}+\frac{(2/3-1/3)^2}{5/10}=\frac{4}{9}$$

$d^2\left(F_J^i,F_J^{i'}\right)$	F_J^1	F_J^2	F_J^3
F_J^1	**0**	**1/9**	**1/9**
F_J^2	**1/9**	**0**	**4/9**
F_J^3	**1/9**	**4/9**	**0**

- **Centre de gravité pour chaque nuage** : généralement, le centre de gravité est donné par la formule suivante : $g=\frac{\sum_{i=1}^{n}P_i*x_i}{\sum_{i=1}^{n}P_i}$ telle que P_i est le poids de l'individu x_i.

Nous pouvons donc calculer le Centre de gravité pour le nuage $N(I)$ par :

$$g_{N(I)}=\frac{\sum_{i=1}^{n}f_{i.}*F_J^i}{\sum_{i=1}^{n}f_{i.}}=$$

$$\frac{\sum_{i=1}^{n}f_{.j}*\frac{f_{ij}}{f_{.j}}}{\sum_{i=1}^{n}f_{i.}}=\frac{\sum_{i=1}^{n}f_{ij}}{\sum_{i=1}^{n}f_{i.}}$$

$$=\frac{f_{.j}}{\sum_{i=1}^{n}\sum_{j=1}^{p}f_{ij}}=\frac{f_{.j}}{\sum_{i=1}^{n}\sum_{j=1}^{p}\frac{K_{ij}}{K}}=\frac{f_{.j}}{\frac{1}{K}\sum_{i=1}^{n}\sum_{j=1}^{p}K_{ij}}=\frac{f_{.j}}{\frac{1}{K}*K}$$

$$=f_{.j}$$

Concernant le centre de gravité pour le nuage $N(J)$ est défini par :

$$g_{N(J)}=\frac{\sum_{j=1}^{p}f_{.j}*F_I^j}{\sum_{j=1}^{p}f_{.j}}$$

$$=\frac{\sum_{j=1}^{p}f_{.j}*\frac{f_{ij}}{f_{.j}}}{\sum_{j=1}^{p}f_{.j}}=\frac{\sum_{j=1}^{p}f_{ij}}{\sum_{j=1}^{p}f_{.j}}$$

$$=\frac{f_{i.}}{\sum_{j=1}^{p}\sum_{i=1}^{n}f_{ij}}=\frac{f_{i.}}{\frac{1}{K}\sum_{j=1}^{p}\sum_{i=1}^{n}K_{ij}}=\frac{f_{i.}}{\frac{1}{K}*K}$$

$$=f_{i.}$$

Remarque :

Le centre de gravité pour le nuage $N(I)$ corresponds aux fréquences marginales colonnes, tandis que e centre de gravité pour le nuage $N(J)$ corresponds aux fréquences marginales lignes.

Exemple :(pour le tableau précédent)

- **Le centre de gravité du nuage** $N(I)$

$$g_{N(I)} = \frac{\sum_{i=1}^{n} p_i.x_i}{\sum_{i=1}^{n} p_i} = \frac{\sum_{i=1}^{n} f_{i.} * F_J^i}{\sum_{i=1}^{n} f_{i.}} = \frac{4}{10}\begin{pmatrix}2/4\\2/4\end{pmatrix} + \frac{3}{10}\begin{pmatrix}1/3\\2/3\end{pmatrix} + \frac{3}{10}\begin{pmatrix}2/3\\1/3\end{pmatrix} = \begin{pmatrix}5/10\\5/10\end{pmatrix} = f_{.j}$$

- **Le centre de gravité du nuage** $N(J)$

$$g_{N(J)} = \frac{\sum_{j=1}^{p} f_{.j} * F_I^j}{\sum_{j=1}^{p} f_{.j}} = \frac{5}{10}\begin{pmatrix}2/5\\1/5\\2/5\end{pmatrix} + \frac{5}{10}\begin{pmatrix}2/5\\2/5\\1/5\end{pmatrix} = \begin{pmatrix}4/10\\3/10\\3/10\end{pmatrix} = f_{i.}$$

Calcul d'inertie :

L'inertie du nuage de points représente la variance et qui est calculée par : $I = \sum_{i=1}^{n} P_i d^2(x_i, g)$

- L'inertie pour le nuage $N(I)$ est calculée par : $I_{N(I)} = \sum_{i=1}^{n} f_{i.} d^2(F_J^i, f_{.j})$ avec

$$d^2(F_J^i, f_{.j}) = \left\|F_J^i - f_{.j}\right\|^2_{D_{\frac{1}{f_{.j}}}} = \sum_{j=1}^{p}(F_J^i - f_{.j})^2 / f_{.j}$$

Donc : $I_{N(I)} = \sum_{i=1}^{n} f_{i.} \sum_{j=1}^{p}(F_J^i - f_{.j})^2 / f_{.j}$

- L'inertie pour le nuage $N(J)$ est déterminée par : $I_{N(J)} = \sum_{j=1}^{p} f_{.j} d^2(F_I^j, f_{i.})$ avec

$$d^2(F_I^j, f_{i.}) = \left\|F_I^j - f_{i.}\right\|^2_{D_{\frac{1}{f_{i.}}}} = \sum_{i=1}^{n}(F_I^j - f_{i.})^2 / f_{i.}$$

$$I_{N(J)} = \sum_{j=1}^{p} f_{.j} d^2(F_I^j, f_{i.}) \qquad d^2(F_I^j, f_{i.}) = \left\|F_I^j - f_{i.}\right\|^2_{D_{\frac{1}{f_{i.}}}} = \sum_{i=1}^{n}(F_I^j - f_{i.})^2 / f_{i.}$$

Donc : $I_{N(J)} = \sum_{j=1}^{p} f_{.j} \sum_{i=1}^{n}(F_I^j - f_{i.})^2 / f_{i.}$

Exemple :

- **L'inertie du nuage** $N(I)$

$$N(I)=\left\{\left(F_J^i, f_{i.}\right), i=1.....n\right\}=\left\{[(2/4;2/4),4/10] \quad ;[(1/3;2/3),3/10] \;;[(2/3;1/3),3/10]\right\}$$

$$f_{.j}=\begin{pmatrix}5/10\\5/10\end{pmatrix}$$

$$I_{N(I)}=\sum_{i=1}^{n} f_{i.}d^2\left(F_J^i, f_{.j}\right) \quad et \quad d^2\left(F_J^i, f_{.j}\right)=\left\|F_J^i-f_{.j}\right\|_{D_{\frac{1}{f_{.j}}}}^2=\sum_{j=1}^{p}\left(F_J^i-f_{.j}\right)^2/f_{.j}$$

$$I_{N(I)}=f_{1.}.d^2\left(F_J^1, f_{.j}\right)+f_{2.}.d^2\left(F_J^2, f_{.j}\right)+f_{3.}.d^2\left(F_J^3, f_{.j}\right)=4/10.\left[\frac{(2/4-5/10)^2}{5/10}+\frac{(2/4-5/10)^2}{5/10}\right]$$

$$+3/10.\left[\frac{(1/3-5/10)^2}{5/10}+\frac{(2/3-5/10)^2}{5/10}\right]+3/10.\left[\frac{(2/3-5/10)^2}{5/10}+\frac{(1/3-5/10)^2}{5/10}\right]=\frac{1}{15}$$

- **L'inertie du nuage** $N(J)$**:**

$$N(J)=\left\{\left(F_I^j, f_{.j}\right), j=1.....p\right\}=\left\{[(2/5;1/5;2/5),5/10] \quad ;[(2/5;2/5;1/5),5/10] \;;\right\} \; f_{i.}=\begin{pmatrix}4/10\\3/10\\3/10\end{pmatrix}$$

$$I_{N(J)}=\sum_{j=1}^{p} f_{.j}d^2\left(F_I^j, f_{i.}\right) \; et \quad d^2\left(F_I^j, f_{i.}\right)=\left\|F_I^j-f_{i.}\right\|_{D_{\frac{1}{f_{i.}}}}^2=\sum_{i=1}^{n}\left(F_I^j-f_{i.}\right)^2/f_{i.}$$

$$I_{N(J)}=f_{.1}.d^2\left(F_I^1, f_{i.}\right)+f_{.2}.d^2\left(F_I^2, f_{i.}\right)=5/10.\left[\frac{(2/5-4/10)^2}{4/10}+\frac{(1/5-3/10)^2}{3/10}+\frac{(2/5-3/10)^2}{3/10}\right]$$

$$+5/10.\left[\frac{(2/5-4/10)^2}{4/10}+\frac{(2/5-3/10)^2}{3/10}+\frac{(1/5-3/10)^2}{3/10}\right]=\frac{1}{15}$$

Exercice 1 :

Soit un ensemble de 12 personnes à qui nous avons posé ces deux questions :

Q1 : Lisez- vous le journal « le quotidien d'Oran» ?

Q2 : Quelle est votre fréquence de lecture ?

Leurs réponses étaient comme suivantes :

P1=(Oui, Souvent) ; P2=(Non, Jamais) ; P3=(Oui, Rarement) ; P4=(Oui, Toujours) ;

P5=(Non, Jamais) ; P6=(Oui, Souvent) ; P7=(Oui, Souvent) ; P8=(Oui, Toujours) ;

P9=(Non, Jamais) ; P10=(Oui, Souvent) ; P11=(Oui, Rarement) ; P12=(Oui, Souvent) ;

En supposant que les fréquences de lecture obéissent à la relation d'ordre suivante : Jamais<rarement<Souvent<Toujours

1. Donner le tableau de codage correspondant.

2. Expliquer brièvement comment peut-on réduire ce tableau ?

3. Réduire le tableau de codage.

4. Une étude parallèle s'intéresse à une analyse factorielle des correspondances

- Donner le tableau de contingence correspondant.
- Etablir les nuages de points à étudier et montrer la relation entre ces deux nuages.

1. Le tableau de codage correspondant.

Réponse1 (Oui , Non) : Oui(1, 0) ; Non (0, 1) ;
Réponse 2(Jamais, Rarement, Souvent, Toujours) : Jamais<rarement<Souvent<Toujours

Jamais (1, 0, 0,0) ; Rarement (1, 1, 0,0) ; Souvent(1, 1, 1,0) ; Toujours (1,1,1,1)

	Réponse1		**Réponse2**			
	V1	**V2**	**V3**	**V4**	**V5**	**V6**
P1	**1**	**0**	**1**	**1**	**1**	**0**
P2	**0**	**1**	**1**	**0**	**0**	**0**
P3	**1**	**0**	**1**	**1**	**0**	**0**
P4	**1**	**0**	**1**	**1**	**1**	**1**
P5	**0**	**1**	**1**	**0**	**0**	**0**
P6	**1**	**0**	**1**	**1**	**1**	**0**
P7	**1**	**0**	**1**	**1**	**1**	**0**
P8	**1**	**0**	**1**	**1**	**1**	**1**
P9	**0**	**1**	**1**	**0**	**0**	**0**
P10	**1**	**0**	**1**	**1**	**1**	**0**
P11	**1**	**0**	**1**	**1**	**0**	**0**
P12	**1**	**0**	**1**	**1**	**1**	**0**

2. Pour réduire le tableau de codage, il faut tout d'abord ignorer la relation d'ordre de la deuxième variable (Fréquence de lecture) ensuite, on calcule le tableau de Burt.

- Tableau de codage disjonctif complet

	Réponse1		**Réponse2**			
	V1	**V2**	**V3**	**V4**	**V5**	**V6**
P1	**1**	**0**	**0**	**0**	**1**	**0**
P2	**0**	**1**	**1**	**0**	**0**	**0**
P3	**1**	**0**	**0**	**1**	**0**	**0**
P4	**1**	**0**	**0**	**0**	**0**	**1**
P5	**0**	**1**	**1**	**0**	**0**	**0**
P6	**1**	**0**	**0**	**0**	**1**	**0**
P7	**1**	**0**	**0**	**0**	**1**	**0**
P8	**1**	**0**	**0**	**0**	**0**	**1**
P9	**0**	**1**	**1**	**0**	**0**	**0**
P10	**1**	**0**	**0**	**0**	**1**	**0**
P11	**1**	**0**	**0**	**1**	**0**	**0**
P12	**1**	**0**	**0**	**0**	**1**	**0**

- Tableau de Burt

B=X^t.X=

9	**0**	**0**	**2**	**5**	**2**
0	3	3	0	0	0
0	3	3	0	0	0
2	0	0	2	0	0
5	0	0	0	5	0
2	0	0	0	0	2

3. Analyse factorielle des correspondances

- Le tableau de contingence correspondant. $K = \sum_i \sum_j K_{ij} = 12$

R2 / R1	**Jamais**	**Rarement**	**Souvent**	**Toujours**
Oui	0	2	5	2
Non	3	0	0	0

- Les nuages de points :

Tableau de fréquence : $f_{ij} = \frac{K_{ij}}{K}$

f_{ij}	f_{i1}	f_{i2}	f_{i3}	f_{i4}	$f_{i.}$
f_{1j}	**0**	**2/12**	**5 /12**	**2/12**	**9/12**
f_{2j}	**3/12**	**0**	**0**	**0**	**3/12**
$f_{.j}$	**3/12**	**2/12**	**5/12**	**2/12**	

Tableau des profils lignes : F_J^i : $F_J^i = \frac{f_{ij}}{f_{i.}}$

F_J^i	F_1^i	F_2^i	F_3^i	F_4^i	$f_{i.}$
F_J^1	**0**	**2/9**	**5/9**	**2/9**	**9/12**
F_J^2	**1**	**0**	**0**	**0**	**3/12**

$$N(I) = \{(F_J^i, f_{i.}), i = 1.....n\} = \{[(0;2/9;5/9;2/9), 9/12]; [(1;0;0;0), 3/12]\}$$

Tableau des profils colonnes : F_I^j : $F_I^j = \frac{f_{ij}}{f_{.j}}$

F_I^j	F_I^1	F_I^2	F_I^3	F_I^4
F_1^j	**0**	**1**	**1**	**1**
F_2^j	**1**	**0**	**0**	**0**
$f_{.j}$	**3/12**	**2/12**	**5/12**	**2/12**

$$N(J) = \{(F_I^j, f_{.j}), j = 1.....p\} = \{[(0;1), 3/12]; [(1;0), 2/12]; [(1;0), 5/12]; [(1;0), 2/12]\}$$

- **Calcul d'inertie du nuage $N(I)$:**

$$N(I)=\left\{\left(F_J^i, f_{i.}\right), i=1.....n\right\}=\left\{[(0;2/9;5/9;2/9),9/12];[(1;0;0;0),3/12]\right\}$$

$$f_{.j}=\begin{pmatrix}3/12\\2/12\\5/12\\2/12\end{pmatrix} \qquad I_{N(I)}=\sum_{i=1}^{n} f_{i.}d^2\left(F_J^i, f_{.j}\right) \quad et \quad d^2\left(F_J^i, f_{.j}\right)=\left\|F_J^i-f_{.j}\right\|^2_{D_{\frac{1}{f_{.j}}}}=\sum_{j=1}^{p}\left(F_J^i-f_{.j}\right)^2/f_{.j}$$

$$I_{N(I)}=f_{1.}.d^2\left(F_J^1, f_{.j}\right)+f_{2.}.d^2\left(F_J^2, f_{.j}\right)=9/12.\left[\frac{(0-3/12)^2}{3/12}+\frac{(2/9-2/12)^2}{2/12}+\frac{(5/9-5/12)^2}{5/12}+\frac{(2/9-2/12)^2}{2/12}\right]$$

$$+3/12..\left[\frac{(1-3/12)^2}{3/12}+\frac{(0-2/12)^2}{2/12}+\frac{(0-5/12)^2}{5/12}+\frac{(0-2/12)^2}{2/12}\right]=1$$

- **Calcul d'inertie du nuage $N(J)$:**

$$N(J)=\left\{\left(F_I^j, f_{.j}\right), j=1.....p\right\}=\left\{[(0;1),3/12];[(1;0),2/12];[(1;0),5/12];[(1;0),2/12]\right\} \; f_{i.}=\begin{pmatrix}9/12\\3/12\end{pmatrix}$$

$$I_{N(J)}=\sum_{j=1}^{p} f_{.j}d^2\left(F_I^j, f_{i.}\right)$$ et

$$d^2\left(F_I^j, f_{i.}\right)=\left\|F_I^j-f_{i.}\right\|^2_{D_{\frac{1}{f_{i.}}}}=\sum_{i=1}^{n}\left(F_I^j-f_{i.}\right)^2/f_{i.}$$

$$I_{N(J)}=f_{.1}.d^2\left(F_I^1, f_{i.}\right)+f_{.2}.d^2\left(F_I^2, f_{i.}\right)+f_{.3}.d^2\left(F_I^3, f_{i.}\right)+f_{.4}.d^2\left(F_I^4, f_{i.}\right)=$$

$$3/12.\left[\frac{(0-9/12)^2}{9/12}+\frac{(1-3/12)^2}{3/12}\right]+2/12.\left[\frac{(1-9/12)^2}{9/12}+\frac{(0-3/12)^2}{3/12}\right]+$$

$$5/12.\left[\frac{(1-9/12)^2}{9/12}+\frac{(0-3/12)^2}{3/12}\right]+2/12.\left[\frac{(1-9/12)^2}{9/12}+\frac{(0-3/12)^2}{3/12}\right]=1$$

Exercice 2 :

Soit un ensemble de sept individus ayant répondu à deux questions comme suivant :

I1=(Oui, Oui) ; I2=(Oui, Non) ; I3=(Non, OUI) ; I4=(Non, Non) ; I5=(Oui, Oui) ; I6=(Oui, Non) ; I7=(Non, Oui)

1. Déterminer le tableau de codage disjonctif complet.

2. En utilisant la mesure $d(I,J)=\dfrac{b+c}{a+b+c+d}$, donner le tableau de distance correspondant.

3. En déduire une classification en 4 classes, 3 classes.

4. Réduire le tableau de codage.

- **Solution :**

1. **Tableau de codage disjonctif :**

Réponse 1(Oui, Non) : N(Oui)=(1, 0) ; N(Non)=(0, 1)

Réponse 2(Oui, Non) : N(Oui)=(1, 0) ; N(Non)=(0, 1)

	Réponse 1		Réponse 2	
	V1	**V2**	**V3**	**V4**
I1	**1**	**0**	**1**	**0**
I2	**1**	**0**	**0**	**1**
I3	**0**	**1**	**1**	**0**
I4	**0**	**1**	**0**	**1**
I5	**1**	**0**	**1**	**0**
I6	**1**	**0**	**0**	**1**
I7	**0**	**1**	**1**	**0**

- **a** représente le nombre de fois où x_j =1 et y_j=1.
- **b** représente le nombre de fois où x_j =0 et y_j=1.
- **c** représente le nombre de fois où x_j =1 et y_j=0.
- **d** représente le nombre de fois où x_j =0 et y_j=0.

Calcul de la distance entre I1 et I2 : $I1\begin{pmatrix}1\\0\\1\\0\end{pmatrix}\ et\ I2\begin{pmatrix}1\\0\\0\\1\end{pmatrix}$

La mesure de dissemblance : $d\left(I,J\right)=\dfrac{b+c}{a+b+c+d}\Rightarrow a=1;b=1;c=1;d=1.\Rightarrow d\left(I1,I2\right)=2/4=1/2$

2. **Tableau de distance**

D	**I1**	**I2**	**I3**	**I4**	**I5**	**I6**	**I7**
I1	**0**	**1/2**	**1/2**	**1**	**0**	**1/2**	**1/2**
I2	**1/2**	**0**	**1**	**1/2**	**1/2**	**0**	**1**
I3	**1/2**	**1**	**0**	**1/2**	**1/2**	**1**	**0**
I4	**1**	**1/2**	**1/2**	**0**	**1**	**1/2**	**1/2**
I5	**0**	**1/2**	**1/2**	**1**	**0**	**1/2**	**1/2**
I6	**1/2**	**0**	**1**	**1/2**	**1/2**	**0**	**1/2**
I7	**1/2**	**1**	**0**	**1/2**	**1/2**	**1/2**	**0**

3. **Classification :** La classification consiste à regrouper dans chaque classe (partie de l'ensemble des individus) les individus qui se ressemblent le plus de telle sorte que les éléments de classes différentes doivent être assez différents entre eux. La classification consiste en un partitionnement. Selon la mesure utilisée dans le tableau de distance, les individus identiques ont cette mesure égale à 0 et ceux très différents entre eux ont cette mesure égale à 1.

   La classification en 4 classes est donc :

$C_1 = \{I_1, I_5\}$; $C_2 = \{I_2, I_6\}$; $C_3 = \{I_3, I_7\}$ **et** $C_4 = \{I_4\}$

- **Classification en 3 classes :**

  $C_1 = \{I_1, I_5\}$; $C_2 = \{I_2, I_6\}$; $C_3 = \{I_3, I_4, I_7\}$ **ou bien** $C_1 = \{I_1, I_5\}$; $C_2 = \{I_2, I_4, I_6\}$; $C_3 = \{I_3, I_7\}$

4. Réduction du tableau de codage :

- **Tableau de Burt :**

B=X^t.X=

	V1	V2	V3	V4
V1	**4**	**0**	**2**	**2**
V2	**0**	**3**	**1**	**2**
V3	**2**	**1**	**3**	**0**
V4	**2**	**2**	**0**	**4**

- **Réduction par regroupement :**

	V1	V2	V3	V4
C1	**2**	**0**	**2**	**0**
C2	**2**	**0**	**0**	**2**
C3	**0**	**2**	**2**	**0**
C4	**0**	**1**	**0**	**1**

Une autre manière de regrouper :(Utilisée généralement pour les tableaux de profils)

	V1	V2	V3	V4	**P_i**
C1	**1**	**0**	**1**	**0**	**2**
C2	**1**	**0**	**0**	**1**	**2**
C3	**0**	**1**	**1**	**0**	**2**
C4	**0**	**1**	**0**	**1**	**1**