Introduction

L'analyse en composantes principales (ACP) est une des premières analyses factorielles et qui attire l'attention des scientifiques jusqu'à présent sachant quel'ACP a été conçue par Karl Pearson en 1901. Plusieurs applications font appel à l'intégration de l'ACP comme une méthode de sélection des attributs. Souvent, l'ACP est appliqué comme une méthode de prétraitement dans le domaine d'intelligence artificielle. Plusieurs variantes de l'ACP figurent dans la littérature comme l'ACP non-normée (données homogènes) qui utilise un nuage de point centré, ou bien l'ACP centrée réduite (données hétérogènes) qui utilise un nuage de point centré et réduit. L'algorithme de l'ACP permet de traiter un tableau de type individu/variable <n, p>. (n : nombre d'individus, p : nombre de variables)

Les données

Les données pour l'ACP sont généralement présentées sous la forme d'un tableau où les lignes indiquent les individus, tandis que les colonnes représentent les variables. Elle traite des données quantitatives. Nous notons x_{ij}, la modalité de la variable j pour l'individu i. n désigne le nombre total des individus et p indique le nombre total des variables.

Les objectifs

Deux objectifs sont réalisés par l'ACP :

- Le premier est de représenter graphiquement les individus en calculant les composantes principales, qui représentent la projection des individus dans l'espace réduit.
- Le deuxième est de représenter les variables en calculant les coefficients de corrélation entre les variables et les composantes principales.

L'ACP répond à deux questions similaires qui sont : Peut on réduire les données en recherchant :

1. un ensemble réduit de variables non corrélées (combinaison linéaire des variables initiales).
2. un sous espace représentant au mieux le nuage initial.

Les types d'inertie

L'inertie est une notion fondamentale en ACP, puisqu'elle est une mesure de dispersion du nuage de points autour de son centre de gravité.

- **L'inertie d'un point par rapport au centre de gravité g :**

$$I_{x_i} = P_i.d^2(x_i, g)$$

- **L'inertie totale du nuage de points par rapport au centre de gravité g :**

$$I = \sum_{i=1}^{n} P_i.d^2(x_i, g)$$

- **L'inertie d'un point par rapport à un axe**

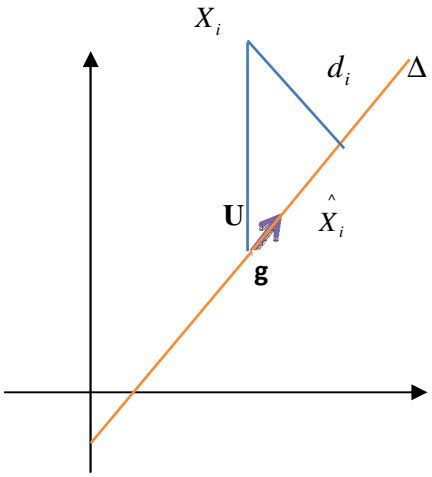
$$I_{X_i/\Delta} = P_i d_{i/\Delta}^2$$

- **L'inertie du nuage de points par rapport à un axe**

$$I_{/\Delta} = \sum_{i=1}^{n} P_i d_{i/\Delta}^2$$

Principe de l'ACP

Comme pour l'ajustement linéaire, l'ACP cherche à trouver des axes qui passent par tous les individus. Autrement dit, nous voulons réduire la dimension de l'espace de représentation des individus mais peut-on les représenter sur un seul axe. Si oui, comment le déterminer ?



Dans ce petit schéma, nous avons un espace à deux dimensions. L'axe Δ recherché doit obligatoirement passer par le centre de gravité **g** du nuage de points. Le vecteur directeur de

l'axe Δ à trouver est nommé **U.** Si nous avons un individu X_i sa projection sur l'axe Δ est $\hat{X}_i$ et d_i est la distance (en projection orthogonale) qui le sépare de l'axe Δ.

D'après le théorème de Pythagore : $\|X_i\|_M^2 = \left\|\hat{X}_i\right\|_M + \|d_{i/\Delta}\|^2 \Rightarrow \|d_{i/\Delta}\|^2 = \|X_i\|_M^2 - \left\|\hat{X}_i\right\|_M^2$

Tel que M est la métrique de l'espace. Nous cherchons les axes qui passent par tous les individus. Pratiquement, ces axes sont impossibles à trouver. Donc, nous allons chercher les axes qui sont proches de tous les individus en même temps. Evidemment, ces axes doivent passer par le centre de gravité qui est lui-même le point le plus proche de tous les individus en même temps. Nous voulons donc que, pour ces axes, toutes les d_i soient minimisées. Ce qui revient donc à minimiser l'inertie du nuage de point par rapport à l'axe recherché Δ.

$$I_{/\Delta} = \sum_{i=1}^{n} P_i d_{i/\Delta}^2 et \|d_{i/\Delta}\|^2 = \|X_i\|_M^2 - \left\|\hat{X}_i\right\|_M^2 \Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i \left(\|X_i\|_M^2 - \left\|\hat{X}_i\right\|_M^2 \right)$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - \sum_{i=1}^{n} P_i . \left\|\hat{X}_i\right\|_M^2 \rightarrow M : Métrique$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - \sum_{i=1}^{n} P_i . [< X_i, U >_M]^2$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - \sum_{i=1}^{n} P_i . < X_i, U >_M^t . < X_i, U >_M$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - \sum_{i=1}^{n} P_i . (X_i . M . U)^t . (X_i . M . U)$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - \sum_{i=1}^{n} P_i . U^t . M^t . X_i^t . X_i . M . U \rightarrow M^t = M$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - \sum_{i=1}^{n} P_i . U^t . M . X_i^t . X_i . M . U$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - U^t . M \sum_{i=1}^{n} P_i . X_i^t . X_i . M . U \rightarrow V = \sum_{i=1}^{n} P_i . X_i^t . X_i$$

$$\Rightarrow I_{/\Delta} = \sum_{i=1}^{n} P_i . \|X_i\|_M^2 - U^t . M . V . M . U$$

$$Min \quad I_{/\Delta} \Rightarrow Max[U^t . M . V . M . U]$$

La solution de ce problème d'optimisation est :

$V . M . U_k = \lambda_k . U_k$ Tels que U_k : Vecteurs propres de la matrice $V . M$ associés aux Valeurs propres λ_k .

Remarques :

- Les vecteurs propres constituent une base orthonormée c.-à-d. :

$$< U_i, U_j >_M = U_i^t M U_j = 0 \ \forall i \neq j \ \& \ \|U_i\|^2 = < U_i, U_i >_M = U_i^t M U_i = 1$$

-La métrique $M = \begin{cases} I & \text{dans le cas de données homogènes (même unité de mesure)} \\ D_{\frac{1}{\sigma_j^2}} & \text{dans le cas de données hétérogènes (unités de mesure différentes)} \end{cases}$

-Chaque valeur propre λ_k est appelée Inertie de l'axe Δ_k dirigé par U_k avec :

$\sum_k \lambda_k = Tr(VM)$: *Trace de la matrice VM*

Les composantes principales : Les composantes principales sont les projections des individus sur les axes trouvés. Ces axes sont appelé axes principaux d'inertie. Les composantes principales sont, donc, les nouvelles variables.

$C_k^i = < X_i, U_k >_M = X_i^t M U_k$ et $C_k = XMU_k$.

Les propriétés des composantes principales :

1) $Moy(C_k) = 0$ *car* $C_k = XMU_k$ *et* X *est un tableau centré*

2) $Var(C_k) = \lambda_k \Rightarrow Var(C_k) = \sum_{i=1}^{N} P_i . (C_k^i)^2 = \frac{1}{N} C_k^t * C_k$

3) $Cor(C_i, C_j) = \frac{Cov(C_i, C_j)}{\sigma_{C_i} . \sigma_{C_j}} = 0 \Rightarrow Cov(C_i, C_j) = 0 \Rightarrow \frac{1}{N} C_i^t * C_j = 0$

Ces propriétés montrent que les composantes principales sont des variables non corrélées entre elles. Le sens, du point de vue de l'application de l'ACP, de ces nouvelles variables est déduit par le calcul des différentes corrélations qu'elles ont avec les anciennes variables.

Donc nous pouvons résumer l'algorithme de l'ACP comme suivant :

Algorithme de l'ACP:

1. Centrer le tableau ($X_{<n,p>}$) : $X^{'} = X - g$ et $g^{j} = \frac{\sum_{i=1}^{N} p_i . x_{ij}}{\sum_{i=1}^{N} p_i}; j = 1...p; i = 1...N$ & $p_i = \frac{1}{N}$
2. Calculer la matrice de variances –covariances : $V = \frac{1}{N} X^{t}.X$
3. Déterminer la métrique $M = \begin{cases} I \\ D_{\frac{1}{\sigma_j^2}} \end{cases}$ Données homogènes/ hétérogènes.
4. Recherche des axes principaux U_k de la matrice (VM)
   - Calculer les valeurs propres : $dét(VM - \lambda I) = 0$
   - Trier les valeurs propres par ordre décroissant : $\lambda_1 > \lambda_2 > ..... > \lambda_p$.
5. Calculer la qualité de représentation : $Q_j = \frac{\Sigma_{i=1}^{J} \lambda_i}{\Sigma_{i=1}^{p} \lambda_i} \geq 80\%$.
6. Calculer les vecteurs propres U_k de la matrice (VM) en utilisant la formule : $VMU_k = \lambda_k U_k$.
7. Calculer les composantes principales : $C_k^i = < X_i, U_k >_M = X_i^t M U_k$ et $C_k = XMU_k$.
8. Représenter graphiquement les individus dans l'espace réduit en utilisant les composantes principales.
9. Les contributions aux inerties :
   - Part d'inertie de X_i prise en compte par l'axe U_k : $\cos^2(\theta_{ik}) = \frac{(C_k^i)^2}{\|X_i\|_M^2}$.
   - Contribution relative de l'individu X_i à l'inertie expliquée de l'axe U_k :

$$\rho_{ik} = \frac{P_i.(C_k^i)^2}{\sum_{i=1}^{n} P_i.(C_k^i)^2} = \frac{P_i.(C_k^i)^2}{Var(C_k)} = \frac{P_i.(C_k^i)^2}{\lambda_k}$$

10. Représentation des variables à l'aide du coefficient de corrélation :

$$Cor(X^j, C_K) = \frac{Cov(X^j, C_k)}{\sigma_{X^j}.\sigma_{C_k}} = \frac{\sum_{i=1}^{N} P_i.X_i^j.C_k^i}{\sigma_{X^j}.\sqrt{\lambda_k}} = \frac{\frac{1}{N}(X^j)^t.C_k}{\sigma_{X^j}.\sqrt{\lambda_k}}$$

Une dernière étape qui suit cet algorithme est l'étape de l'analyse. En effet, après application de l'ACP, les différentes représentations graphiques des individus sont analysées.

Notons que la représentation graphique ne se fait que sur un plan (espace à 2 dimensions). Ce qui veut dire que nous prendrons les axes principaux d'inertie 2 à 2 pour les représentations graphiques.

L'Analyse Factorielle des Correspondances (AFC) : Si le tableau de données à traiter est un tableau de contingence (Var/Var), l'algorithme à utiliser est un petit peu différent. L'AFC consiste à transformer le tableau de contingence en tableaux Ind/Var (Tableaux des profils) et ensuite appliquer une double ACP. C'est-à-dire que nous appliquons une ACP sur le tableau de profils lignes et une ACP sur le tableau de profils colonnes.

L'algorithme de l'AFC est donc :

Algorithme de l'AFC :

1. Tableau [Variable/Variable] $\rightarrow$ deux tableaux de profils [Individus/ Variables]
2. Application de deux ACP $\rightarrow N(I)$
   $\downarrow N(J)$
3. Les valeurs propres significatives du nuage $\lambda_k \in]0,1[$
   $N(I) \mapsto \lambda_k, U_k$
   $N(J) \mapsto \lambda_k, V_k$
4. Calculer les composantes principales : $$N(I) \mapsto C_k = F_J^I . D_{1/f.j}\, U_k \;\&\; N(J) \mapsto d_k = F_I^J . D_{1/fi.}\, V_k$$
5. Les formules de transitions : $$C_k^i = \frac{1}{\sqrt{\lambda_K}} \sum_{j=1}^{P} F_J^I . d_k^j \;\&\; d_k^j = \frac{1}{\sqrt{\lambda_K}} \sum_{i=1}^{n} F_I^J . C_k^i$$

Exemple sur l'analyse en composantes principales dans le cas des données homogènes :

Soit un ensemble de six individus caractérisés par trois notes chacun.

	N1	**N2**	**N3**
I1	8	1	0
I2	4	6	5
I3	6	8	7
I4	10	4	7
I5	8	2	5
I6	0	3	6

- Appliquer l'analyse en composante principale ($\lambda_1 = 12$).

1. Le tableau centré $X_{\prec n,p\succ}$:

- **Calcul du centre de gravité :** $g = \dfrac{\sum_{i=1}^{n} p_i.x_i}{\sum_{i=1}^{n} p_i}$

$P_i = \dfrac{1}{N}$ où N représente le nombre d'individus. Cela implique que $P_i = \dfrac{1}{6}$; $i = 1,.....,n;1...6$; $j = 1,.....p;1...3$

$$g = \begin{pmatrix} \frac{1}{6}(8+4+6+10+8+0) \\ \frac{1}{6}(1+6+8+4+2+3) \\ \frac{1}{6}(0+5+7+7+5+6) \end{pmatrix} = \begin{pmatrix} 6 \\ 4 \\ 5 \end{pmatrix}$$

	N1	N2	N3
I1	8	1	0
I2	4	6	5
I3	6	8	7
I4	10	4	7
I5	8	2	5
I6	0	3	6
g	**6**	**4**	**5**

Tableau centré $X = \begin{pmatrix} 8-6 & 1-4 & 0-5 \\ 4-6 & 6-4 & 5-5 \\ 6-6 & 8-4 & 7-5 \\ 10-6 & 4-4 & 7-5 \\ 8-6 & 2-4 & 5-5 \\ 0-6 & 3-4 & 6-5 \end{pmatrix} = \begin{pmatrix} +2 & -3 & -5 \\ -2 & +2 & 0 \\ 0 & +4 & +2 \\ +4 & 0 & +2 \\ +2 & -2 & 0 \\ -6 & -1 & +1 \end{pmatrix}$

2. Calcul de la matrice variance –covariance : $V = \dfrac{1}{N} X^t.X \Rightarrow V = \dfrac{1}{6}\begin{pmatrix} 64 & -8 & -8 \\ -8 & 34 & 22 \\ -8 & 22 & 34 \end{pmatrix}$.

3. Détermination de la métrique :

Les données sont homogènes car elles possèdent la même unité de mesure

$$\Rightarrow M = Id = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

4. Recherche des axes principaux U_k de la matrice (VM) :

- Calcul des valeurs propres λ_k de la matrice (VM) en utilisant la formule suivante :

  $dét(VM - \lambda I) = 0$

- $$dét(VM - \lambda I) = \frac{1}{6}\begin{vmatrix} 64-6\lambda & -8 & -8 \\ -8 & 34-6\lambda & 22 \\ -8 & 22 & 34-6\lambda \end{vmatrix} = 0 \Rightarrow \lambda^3 - 22\lambda^2 + 136\lambda - 192 = 0$$

$$\begin{array}{l|l} \lambda^3 - 22\lambda^2 + 136\lambda - 192 & \lambda - 12 \\ \underline{-\lambda^3 + 12\lambda^2} & \hline \lambda^2 - 10\lambda + 16 \\ -10\lambda^2 + 136\lambda - 192 & \\ \underline{+10\lambda^2 - 120\lambda} & \\ 16\lambda - 192 & \\ \underline{-16\lambda + 192} & \\ 0 & \end{array}$$

$$dét(VM - \lambda I) = 0 \Rightarrow \lambda^3 - 22\lambda^2 + 136\lambda - 192 = 0 \Rightarrow (\lambda - 12).(\lambda^2 - 10\lambda + 16) = 0$$

$$\Rightarrow \begin{cases} \lambda - 12 = 0 \\ \lambda^2 - 10\lambda + 16 = 0 \end{cases} \Rightarrow \begin{cases} \lambda_1 = 12 \\ \Delta = b^2 - 4ac = 100 - 4.1.16 = 36 \rightarrow \sqrt{\Delta} = 6 \Rightarrow \begin{cases} \lambda_2 = \dfrac{-b + \sqrt{\Delta}}{2a} = \dfrac{10+6}{2} = 8 \\ \lambda_3 = \dfrac{-b - \sqrt{\Delta}}{2a} = \dfrac{10-6}{2} = 2 \end{cases} \end{cases}$$

$$\lambda_1 = 12 \succ \lambda_2 = 8 \succ \lambda_3 = 2$$

5. Calcul de la qualité de représentation

$$Q_j = \frac{\sum_{i=1}^{j} \lambda_i}{\sum_{i=1}^{p} \lambda_i} \geq 80\% \Rightarrow Q_1 = \frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3} = \frac{12}{12+8+2} = 0.54 = 54\% \prec 80\%$$

$Q_2 = \dfrac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} = \dfrac{12+8}{12+8+2} = 0.9 = 90\% \geq 80\%$ **Il y'a deux axes principaux dirigés par les vecteurs** U_1, U_2 **associés aux valeurs propres** λ_1, λ_2

6. Calcul des vecteurs propres U_1, U_2 **de la matrice (VM) :** $VMU_k = \lambda_k U_k$

$$VMU_1 = \lambda_1 U_1 \Rightarrow \frac{1}{6}\begin{pmatrix} 64 & -8 & -8 \\ -8 & 34 & 22 \\ -8 & 22 & 34 \end{pmatrix}\begin{pmatrix} x \\ y \\ z \end{pmatrix} = 12\begin{pmatrix} x \\ y \\ z \end{pmatrix} \Rightarrow \begin{cases} 64x - 8y - 8z = 72x \\ -8x + 34y + 22z = 72y \\ -8x + 22y + 34z = 72z \end{cases} \Rightarrow \begin{cases} -8x - 8y - 8z = 0 \rightarrow (1) \\ -8x - 38y + 22z = 0 \rightarrow (2) \\ -8x + 22y - 38z = 0 \rightarrow (3) \end{cases}$$

$$\begin{matrix} Eq(1) - Eq(2) : 30y - 30z = 0 \Rightarrow y = z \rightarrow (4) \\ Eq(4) dans Eq(3) : -8x + 22y - 38y = 0 \Rightarrow x = -2y \end{matrix} \Rightarrow U_1^* = \begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix}$$

$$\left\| U_1^* \right\|_M^2 = U_1^{*t}.M.U_1^* = \begin{pmatrix} -2 & 1 & 1 \end{pmatrix}.Id.\begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix} = 6 \Rightarrow \left\| U_1^* \right\|_M = \sqrt{6} \Rightarrow U_1 = \frac{U_1^*}{\left\| U_1^* \right\|_M} = \frac{1}{\sqrt{6}}\begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix}$$

$$VMU_2 = \lambda_2 U_2 \Rightarrow \frac{1}{6}\begin{pmatrix} 64 & -8 & -8 \\ -8 & 34 & 22 \\ -8 & 22 & 34 \end{pmatrix}\begin{pmatrix} x' \\ y' \\ z' \end{pmatrix} = 8\begin{pmatrix} x' \\ y' \\ z' \end{pmatrix} \Rightarrow \begin{cases} 64x' - 8y' - 8z' = 48x' \\ -8x' + 34y' + 22z' = 48y' \\ -8x' + 22y' + 34z' = 48z' \end{cases} \Rightarrow \begin{cases} 16x' - 8y' - 8z' = 0 \rightarrow (a) \\ -8x' - 14y' - 8z' = 0 \rightarrow (b) \\ -8x' + 22y' - 14z' = 0 \rightarrow (c) \end{cases}$$

$$\begin{matrix} Eq(b) - Eq(c) : -36y' + 36z' = 0 \Rightarrow y = z \rightarrow (d) \\ Eq(d) dans Eq(a) : 16x' - 8y' - 8y' = 0 \Rightarrow x = y \end{matrix} \Rightarrow U_2^* = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

$$\left\| U_2^* \right\|_M^2 = U_2^{*t}.M.U_2^* = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix}.Id.\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = 3 \Rightarrow \left\| U_2^* \right\|_M = \sqrt{3} \Rightarrow U_2 = \frac{U_2^*}{\left\| U_2^* \right\|_M} = \frac{1}{\sqrt{3}}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

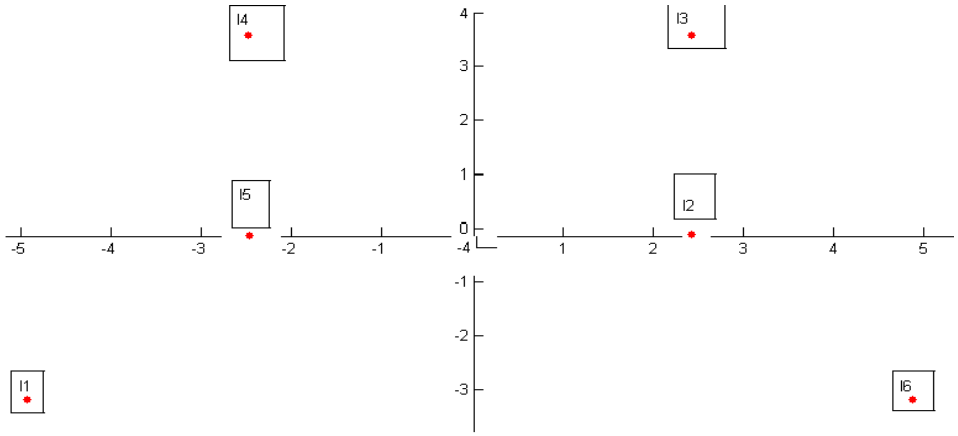
7. Calcul des composantes principales $C_k = X.M.U_k$

$$C_1 = X.M.U_1 = X.Id.U_1 = X.U_1 = \begin{pmatrix} +2 & -3 & -5 \\ -2 & +2 & 0 \\ 0 & +4 & +2 \\ +4 & 0 & +2 \\ +2 & -2 & 0 \\ -6 & -1 & +1 \end{pmatrix}.\frac{1}{\sqrt{6}}\begin{pmatrix} -2 \\ 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{6}}\begin{pmatrix} -12 \\ +6 \\ +6 \\ -6 \\ -6 \\ +12 \end{pmatrix} = \sqrt{6}\begin{pmatrix} -2 \\ +1 \\ +1 \\ -1 \\ -1 \\ +2 \end{pmatrix}$$

$$C_2 = X.M.U_2 = X.Id.U_2 = X.U_2 = \begin{pmatrix} +2 & -3 & -5 \\ -2 & +2 & 0 \\ 0 & +4 & +2 \\ +4 & 0 & +2 \\ +2 & -2 & 0 \\ -6 & -1 & +1 \end{pmatrix}.\frac{1}{\sqrt{3}}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{3}}\begin{pmatrix} -6 \\ 0 \\ +6 \\ +6 \\ 0 \\ -6 \end{pmatrix} = \sqrt{3}\begin{pmatrix} -2 \\ 0 \\ +2 \\ +2 \\ 0 \\ -2 \end{pmatrix}$$

8. Représentation graphique des individus :

$$I_1=\left(-2\sqrt{6},-2\sqrt{3}\right);I_2=\left(\sqrt{6},0\right);I_3=\left(\sqrt{6},2\sqrt{3}\right);I_4=\left(-\sqrt{6},2\sqrt{3}\right);I_5=\left(-\sqrt{6},0\right);I_6=\left(2\sqrt{6},-2\sqrt{3}\right)$$



9. Calcul des contributions :

- **Contribution relative de l'individu X_i à l'inertie expliquée de l'axe U_k :**

$$\rho_{ik}=\frac{P_i.\left(C_k^i\right)^2}{\sum_{i=1}^{n}P_i.\left(C_k^i\right)^2}=\frac{P_i.\left(C_k^i\right)^2}{Var\left(C_k\right)}=\frac{P_i.\left(C_k^i\right)^2}{\lambda_k}$$

- **Par rapport à l'axe U_1 : i=1…6**

$$\rho_{11}=\frac{P_1.\left(C_1^1\right)^2}{\lambda_1}=\frac{\frac{1}{6}.\left(-2\sqrt{6}\right)^2}{12}=\frac{1}{3}=0.33$$

$$\rho_{21}=0.08;\rho_{31}=0.08;\rho_{41}=0.08;\rho_{51}=0.08;\rho_{61}=0.33.$$

- **Par rapport à l'axe U_2 : i=1…6**

$$\rho_{12}=\frac{P_1.\left(C_2^1\right)^2}{\lambda_2}=\frac{\frac{1}{6}.\left(-2\sqrt{3}\right)^2}{8}=\frac{1}{4}=0.25;$$

$$\rho_{22}=0;\rho_{32}=0.25;\rho_{42}=0.25;\rho_{52}=0;\rho_{62}=0.25.$$

Remarque : Si $\rho_{ik}\approx 1$ alors le i^{ème} individu doit être retiré du tableau initial. Ensuite, il faut refaire l'ACP et l'ajouter à la fin comme individu supplémentaire.

- **Part d'inertie de X_i prise en compte par l'axe U_k :** $\cos^2\left(\theta_{ik}\right)=\frac{\left(C_k^i\right)^2}{\left\|X_i\right\|_M^2}$

- **Par rapport à l'axe U_1 : i=1…6**

$$\cos^2(\theta_{11}) = \frac{(C_1^1)^2}{\|X_1\|_M^2} = \frac{(-2\sqrt{6})^2}{(2 \quad -3 \quad -5).Id.\begin{pmatrix}2\\-3\\-5\end{pmatrix}} = \frac{24}{4+9+25} = \frac{24}{38} = 0.63$$

$\cos^2(\theta_{21}) = \frac{(C_1^2)^2}{\|X_2\|_M^2} = \frac{(\sqrt{6})^2}{4+4+0} = \frac{6}{8} = 0.75;\ \cos^2(\theta_{31}) = 0.3;\ \cos^2(\theta_{41}) = 0.3;\ \cos^2(\theta_{51}) = 0.75;$
$\cos^2(\theta_{61}) = 0.63;$

- **Par rapport à l'axe U_2 : i=1…6**

$$\cos^2(\theta_{12}) = \frac{(C_2^1)^2}{\|X_1\|_M^2} = \frac{(-2\sqrt{3})^2}{(2 \quad -3 \quad -5).Id.\begin{pmatrix}2\\-3\\-5\end{pmatrix}} = \frac{12}{4+9+25} = \frac{12}{38} = 0.32$$

$\cos^2(\theta_{22}) = \frac{(C_2^2)^2}{\|X_2\|_M^2} = \frac{(0)^2}{4+4+0} = 0;\ \cos^2(\theta_{32}) = 0.6;\ \cos^2(\theta_{42}) = 0.6;\ \cos^2(\theta_{52}) = 0;$
$\cos^2(\theta_{62}) = 0.32;$

10. Représentation des variables à l'aide du coefficient de corrélation

$$Cor(X^j, C_K) = \frac{Cov(X^j, C_k)}{\sigma_{X^j}.\sigma_{C_k}} = \frac{\sum_{i=1}^{n} P_i.X_i^j.C_k^i}{\sigma_{X^j}.\sqrt{\lambda_k}} = \frac{\frac{1}{N}(X^j)^t.C_k}{\sigma_{X^j}.\sqrt{\lambda_k}}$$

$$Cor(X^1 : N_1, C_1) = \frac{Cov(X^1, C_1)}{\sigma_{X^1}.\sigma_{C_1}} = \frac{\sum_{i=1}^{n} P_i.X_i^1.C_1^i}{\sigma_{X^1}.\sqrt{\lambda_1}} = \frac{\frac{1}{N}(X^1)^t.C_1}{\sigma_{X^1}.\sqrt{\lambda_1}} = \frac{\frac{1}{6}(2 \quad -2 \quad 0 \quad 4 \quad 2 \quad -6)*\sqrt{6}\begin{pmatrix}-2\\+1\\+1\\-1\\-1\\+2\end{pmatrix}}{\sqrt{64/6}*\sqrt{12}} = -\frac{\sqrt{3}}{2}$$

$$Cor\left(X^1 : N_1, C_2\right) = \frac{Cov\left(X^1, C_2\right)}{\sigma_{X^1}.\sigma_{C_2}} = \frac{\sum_{i=1}^{n} P_i.X_i^1.C_2^i}{\sigma_{X^1}.\sqrt{\lambda_2}} = \frac{\frac{1}{N}\left(X^1\right)^t.C_2}{\sigma_{X^1}.\sqrt{\lambda_2}} = \frac{\frac{1}{6}\begin{pmatrix}2 & -2 & 0 & 4 & 2 & -6\end{pmatrix} * \sqrt{3}\begin{pmatrix}-2\\0\\+2\\+2\\0\\-2\end{pmatrix}}{\sqrt{64/6} * \sqrt{8}} = \frac{1}{2}$$

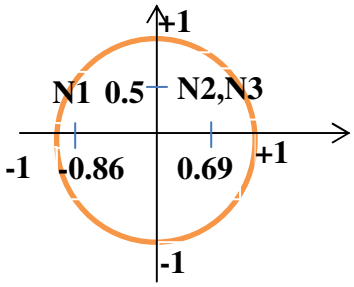
$$Cor\left(X^2 : N_2, C_1\right) = \frac{Cov\left(X^2, C_1\right)}{\sigma_{X^2}.\sigma_{C_1}} = \frac{\sum_{i=1}^{n} P_i.X_i^2.C_1^i}{\sigma_{X^2}.\sqrt{\lambda_1}} = \frac{\frac{1}{N}\left(X^2\right)^t.C_1}{\sigma_{X^2}.\sqrt{\lambda_1}} = \frac{\frac{1}{6}\begin{pmatrix}-3 & 2 & 4 & 0 & -2 & -1\end{pmatrix} * \sqrt{6}\begin{pmatrix}-2\\+1\\+1\\-1\\-1\\+2\end{pmatrix}}{\sqrt{34/6} * \sqrt{12}} = \sqrt{6/17} = 0.59$$

$$Cor\left(X^2 : N_2, C_2\right) = \frac{Cov\left(X^2, C_2\right)}{\sigma_{X^2}.\sigma_{C_2}} = \frac{\sum_{i=1}^{n} P_i.X_i^2.C_2^i}{\sigma_{X^2}.\sqrt{\lambda_2}} = \frac{\frac{1}{N}\left(X^2\right)^t.C_2}{\sigma_{X^2}.\sqrt{\lambda_2}} = \frac{\frac{1}{6}\begin{pmatrix}-3 & 2 & 4 & 0 & -2 & -1\end{pmatrix} * \sqrt{3}\begin{pmatrix}-2\\0\\+2\\+2\\0\\-2\end{pmatrix}}{\sqrt{34/6} * \sqrt{8}} = \frac{4}{\sqrt{34}} = 0.68$$

$$Cor\left(X^3 : N_3, C_1\right) = \frac{Cov\left(X^3, C_1\right)}{\sigma_{X^3}.\sigma_{C_1}} = \frac{\sum_{i=1}^{n} P_i.X_i^3.C_1^i}{\sigma_{X^3}.\sqrt{\lambda_1}} = \frac{\frac{1}{N}\left(X^3\right)^t.C_1}{\sigma_{X^3}.\sqrt{\lambda_1}} = \frac{\frac{1}{6}\begin{pmatrix}-5 & 0 & 2 & 2 & 0 & 1\end{pmatrix} * \sqrt{6}\begin{pmatrix}-2\\+1\\+1\\-1\\-1\\+2\end{pmatrix}}{\sqrt{34/6} * \sqrt{12}} = \frac{1}{2}$$

$$Cor\left(X^3 : N_3, C_2\right) = \frac{Cov\left(X^3, C_2\right)}{\sigma_{X^3}.\sigma_{C_2}} = \frac{\sum_{i=1}^{n} P_i.X_i^3.C_2^i}{\sigma_{X^3}.\sqrt{\lambda_2}} = \frac{\frac{1}{N}\left(X^3\right)^t.C_2}{\sigma_{X^3}.\sqrt{\lambda_2}} = \frac{\frac{1}{6}\begin{pmatrix}-5 & 0 & 2 & 2 & 0 & 1\end{pmatrix} * \sqrt{3}\begin{pmatrix}-2\\0\\+2\\+2\\0\\-2\end{pmatrix}}{\sqrt{34/6} * \sqrt{8}} = \frac{4}{\sqrt{34}} = 0.68$$

Cercle de corrélation



- La deuxième composante C_2 est positivement corrélée avec les trois variables (N1, N2 et N3). C_2 nous informe sur le résultat général de l'étudiant ($C_2 \Leftrightarrow$moyenne).
- C_1 est positivement corrélée avec N2, N3 et négativement corrélée avec N1. C1 nous informe sur la différence entre les résultats des deux derniers examens et le 1^{ier} examen.

Exemple sur l'analyse en composantes principales dans le cas des données hétérogènes :

Soit un ensemble de six individus dont on a mesuré le poids et la taille.

	Poids	**Taille**
I1	20	15
I2	5	2
I3	12	21
I4	21	13
I5	2	7
I6	12	20

1. Appliquer une Analyse en composante principale.
2. Déduire toutes les partitions possibles, en définissant le sens physique des classes.

- Le tableau centré $X_{\prec n,p \succ}$:
  - Calcul du centre de gravité : $g = \dfrac{\sum_{i=1}^{n} p_i . x_i}{\sum_{i=1}^{n} p_i}$

$P_i = \dfrac{1}{N}$ où N représente le nombre d'individus. Cela implique que $P_i = \dfrac{1}{6}$; $i = 1,.....,n;1...6$; $j = 1,....p;1...2$

$$g = \begin{pmatrix} \frac{1}{6}(20+5+12+21+2+12) \\ \frac{1}{6}(15+2+21+13+7+20) \end{pmatrix} = \begin{pmatrix} 12 \\ 13 \end{pmatrix}$$

	Poids	Taille
I1	20	15
I2	5	2
I3	12	21
I4	21	13
I5	2	7
I6	12	20
g	**12**	**13**

Tableau centré $X = \begin{pmatrix} 20-12 & 15-13 \\ 5-12 & 2-13 \\ 12-12 & 21-13 \\ 21-12 & 13-13 \\ 2-12 & 7-13 \\ 12-12 & 20-13 \end{pmatrix} = \begin{pmatrix} 8 & 2 \\ -7 & -11 \\ 0 & 8 \\ 9 & 0 \\ -10 & -6 \\ 0 & 7 \end{pmatrix}$

- Calcul de la matrice variance –covariance : $V = \frac{1}{N} X^t.X \Rightarrow V = \frac{1}{6}\begin{pmatrix} 294 & 153 \\ 153 & 274 \end{pmatrix}$.
- Détermination de la métrique :

  Les données sont hétérogènes $\Rightarrow M = D_{\frac{1}{\sigma_j^2}} \; j = 1.....P$

  $$M = \begin{pmatrix} 6/294 & 0 \\ 0 & 6/274 \end{pmatrix} \Rightarrow VM = \begin{pmatrix} 1 & 153/274 \\ 153/294 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0.56 \\ 0.52 & 1 \end{pmatrix}$$

- Recherche des axes principaux U_k de la matrice (VM) :
  - Calcul des valeurs propres λ_k de la matrice (VM) en utilisant la formule suivante :

    $dét(VM - \lambda I) = 0$
  - $dét(VM - \lambda I) = \begin{vmatrix} 1-\lambda & 0.56 \\ 0.52 & 1-\lambda \end{vmatrix} = 0 \Rightarrow \lambda^2 - 2\lambda + 0.71 = 0$

$$\Delta = b^2 - 4ac = (-2)^2 - 4.(1)(0.71) = 1.16 \rightarrow \sqrt{\Delta} = 6 \Rightarrow \begin{cases} \lambda_2 = \dfrac{-b+\sqrt{\Delta}}{2a} = \dfrac{2-1.08}{2} = 0.46 \\ \lambda_3 = \dfrac{-b-\sqrt{\Delta}}{2a} = \dfrac{2+1.08}{2} = 1.54 \end{cases}$$

$\lambda_1 = 1.54 \succ \lambda_2 = 0.46$

- **Calcul de la qualité de représentation**

$$Q_j = \frac{\sum_{i=1}^{j} \lambda_i}{\sum_{i=1}^{p} \lambda_i} \geq 80\% \Rightarrow Q_1 = \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{1.54}{1.54 + 0.46} = 0.77 = 77\% \prec 80\%$$

$Q_2 = \dfrac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2} = \dfrac{1.54 + 0.46}{1.54 + 0.46} = 1 = 100\% \geq 80\% \rightarrow$ **Il y'a deux axes principaux** U_1, U_2 **relatifs aux valeurs propres** λ_1, λ_2

- **Calcul des vecteurs propres** U_1, U_2 **de la matrice (VM) :** $VMU_k = \lambda_k U_k$

$$VMU_1 = \lambda_1 U_1 \Rightarrow \begin{pmatrix} 1 & 0.56 \\ 0.52 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 1.54 \begin{pmatrix} x \\ y \end{pmatrix} \Rightarrow \begin{cases} x + 0.56y = 1.54x \\ 0.52x + y = 1.54y \end{cases} \Rightarrow \{-0.54x + 0.5y = 0 \rightarrow x = 1.04y$$

$$\Rightarrow U_1^* = \begin{pmatrix} 1.04 \\ 1 \end{pmatrix}$$

$$\left\| U_1^* \right\|_M^2 = U_1^{*t}.M.U_1^* = U_1^{*t}.D_{\frac{1}{\sigma_j^2}}.U_1^* = (1.04 \quad 1). \begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix} \begin{pmatrix} 1.04 \\ 1 \end{pmatrix} = 0.04 \Rightarrow \left\| U_1^* \right\|_M = 0.2 \Rightarrow U_1 = \frac{U_1^*}{\left\| U_1^* \right\|_M} = \begin{pmatrix} 5.2 \\ 5 \end{pmatrix}$$

$$VMU_2 = \lambda_2 U_2 \Rightarrow \begin{pmatrix} 1 & 0.56 \\ 0.52 & 1 \end{pmatrix} \begin{pmatrix} x' \\ y' \end{pmatrix} = 0.46 \begin{pmatrix} x' \\ y' \end{pmatrix} \Rightarrow \begin{cases} x' + 0.56y' = 0.46x' \\ 0.52x' + y' = 0.46y' \end{cases} \Rightarrow \{0.54x' + 0.56y' = 0 \rightarrow x' = -1.04y'$$

$$\Rightarrow U_2^* = \begin{pmatrix} -1.04 \\ 1 \end{pmatrix}$$

$$\left\| U_2^* \right\|_M^2 = U_2^{*t}.M.U_2^* = U_2^{*t}.D_{\frac{1}{\sigma_j^2}}.U_2^* = (-1.04 \quad 1). \begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix} \begin{pmatrix} -1.04 \\ 1 \end{pmatrix} = 0.04 \Rightarrow \left\| U_2^* \right\|_M = 0.2 \Rightarrow U_1 = \frac{U_2^*}{\left\| U_2^* \right\|_M} = \begin{pmatrix} -5.2 \\ 5 \end{pmatrix}$$

- **Calcul des composantes principales** $C_k = X.M.U_k$

$$C_1 = X.M.U_1 = X.D_{\frac{1}{\sigma_j^2}}.U_1 = \begin{pmatrix} 8 & 2 \\ -7 & -11 \\ 0 & 8 \\ 9 & 0 \\ -10 & -6 \\ 0 & 7 \end{pmatrix} . \begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix} \begin{pmatrix} 5.2 \\ 5 \end{pmatrix} = \begin{pmatrix} 1.03 \\ -1.83 \\ 0.8 \\ 0.9 \\ -1.64 \\ 0.7 \end{pmatrix}$$

$$C_2 = X.M.U_2 = X.D_{\frac{1}{\sigma_j^2}}.U_2 = \begin{pmatrix} 8 & 2 \\ -7 & -11 \\ 0 & 8 \\ 9 & 0 \\ -10 & -6 \\ 0 & 7 \end{pmatrix} \cdot \begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix} \begin{pmatrix} -5.2 \\ 5 \end{pmatrix} = \begin{pmatrix} -0.63 \\ -0.37 \\ 0.8 \\ -0.9 \\ 0.44 \\ 0.7 \end{pmatrix}$$

- **Représentation graphique des individus :**

$I_1 = (1.03,-0.63); I_2 = (-1.83,-0.37); I_3 = (0.8,0.8); I_4 = (0.9,-0.9); I_5 = (-1.64,0.44); I_6 = (0.7,0.7)$

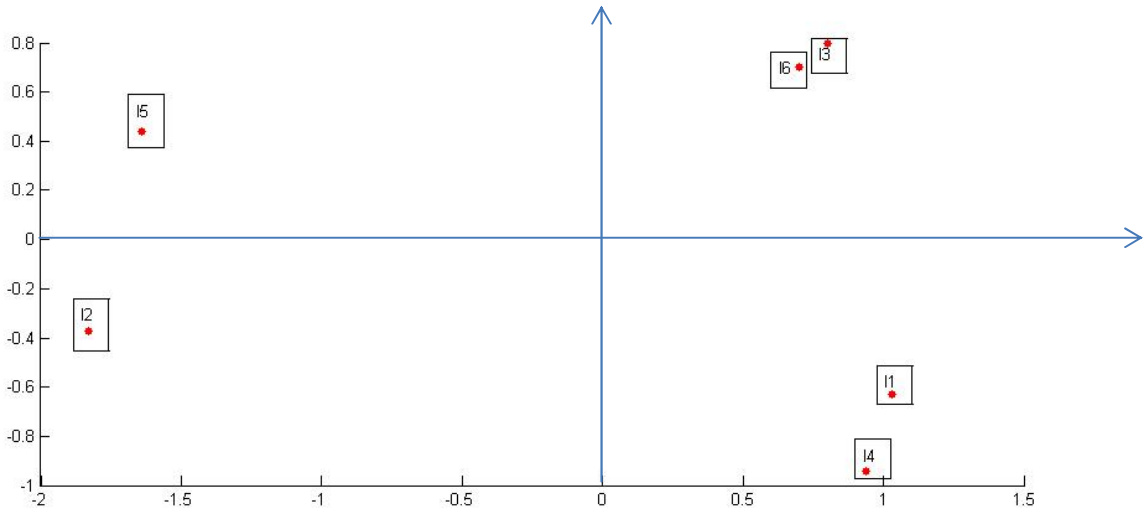


Fig.2.3 : Représentation graphique des individus

- **Calcul des contributions :**

$$C_1 = \begin{pmatrix} 1.03 \\ -1.83 \\ 0.8 \\ 0.9 \\ -1.64 \\ 0.7 \end{pmatrix} \quad C_2 = \begin{pmatrix} -0.63 \\ -0.37 \\ 0.8 \\ -0.9 \\ 0.44 \\ 0.7 \end{pmatrix}$$

- **Contribution relative de l'individu X_i à l'inertie expliquée de l'axe U_k :**

$$\rho_{ik} = \frac{P_i.(C_k^i)^2}{\sum_{i=1}^{n} P_i.(C_k^i)^2} = \frac{P_i.(C_k^i)^2}{Var(C_k)} = \frac{P_i.(C_k^i)^2}{\lambda_k}$$

- **Par rapport à l'axe U_1 : i=1…6**

$$\rho_{11} = \frac{P_1.(C_1^1)^2}{\lambda_1} = \frac{\frac{1}{6}.(1.03)^2}{1.54} = 0.11$$

$$\rho_{21} = 0.36; \rho_{31} = 0.07; \rho_{41} = 0.09; \rho_{51} = 0.29; \rho_{61} = 0.05.$$

- **Par rapport à l'axe U_2 : i=1…6**

$$\rho_{12} = \frac{P_1.(C_2^1)^2}{\lambda_2} = \frac{\frac{1}{6}.(-0.63)^2}{8} = 0.14;$$

$$\rho_{22} = 0.05; \rho_{32} = 0.23; \rho_{42} = 0.29; \rho_{52} = 0.07; \rho_{62} = 0.18.$$

- **Part d'inertie de X_i prise en compte par l'axe U_k :** $\cos^2(\theta_{ik}) = \frac{(C_k^i)^2}{\|X_i\|_M^2}$.

- **Par rapport à l'axe U_1 : i=1…6**

$$\cos^2(\theta_{11}) = \frac{(C_1^1)^2}{\|X_1\|_M^2} = \frac{(1.03)^2}{(8 \quad 2).\begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix}.\begin{pmatrix} 8 \\ 2 \end{pmatrix}} = 0.78$$

$$\cos^2(\theta_{21}) = \frac{(C_1^2)^2}{\|X_2\|_M^2} = \frac{(-1.83)^2}{(-7 \quad -11).\begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix}.\begin{pmatrix} -7 \\ -11 \end{pmatrix}} = 0.98 \ \cos^2(\theta_{31}) = 0.5;$$

$$\cos^2(\theta_{41}) = 0.54; \ \cos^2(\theta_{51}) = 0.99; \ \cos^2(\theta_{61}) = 0.5;$$

- **Par rapport à l'axe U_2 : i=1…6**

$$\cos^2(\theta_{12}) = \frac{(C_2^1)^2}{\|X_1\|_M^2} = \frac{(-0.63)^2}{(8 \quad 2).\begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix}.\begin{pmatrix} 8 \\ 2 \end{pmatrix}} = 0.29$$

$$\cos^2(\theta_{22}) = \frac{(C_2^2)^2}{\|X_2\|_M^2} = \frac{(-0.37)^2}{(-7 \quad -11).\begin{pmatrix} 0.02 & 0 \\ 0 & 0.02 \end{pmatrix}.\begin{pmatrix} -7 \\ -11 \end{pmatrix}} = 0.04;$$

$$\cos^2(\theta_{32}) = 0.5; \ \cos^2(\theta_{42}) = 0.54; \ \cos^2(\theta_{52}) = 0.07; \ \cos^2(\theta_{62}) = 0.5;$$

- **Représentation des variables à l'aide du coefficient de corrélation**

$$Cor(X^j, C_K) = \frac{Cov(X^j, C_k)}{\sigma_{X^j}.\sigma_{C_k}} = \frac{\sum_{i=1}^{n} P_i.X_i^j.C_k^i}{\sigma_{X^j}.\sqrt{\lambda_k}} = \frac{\frac{1}{N}(X^j)^t.C_k}{\sigma_{X^j}.\sqrt{\lambda_k}}$$

$$Cor(X^1 : Poids, C_1) = \frac{Cov(X^1, C_1)}{\sigma_{X^1}.\sigma_{C_1}} = \frac{\sum_{i=1}^{n} P_i.X_i^1.C_1^i}{\sigma_{X^1}.\sqrt{\lambda_1}} = \frac{\frac{1}{N}(X^1)^t.C_1}{\sigma_{X^1}.\sqrt{\lambda_1}} = \frac{\frac{1}{6}\begin{pmatrix}8 & -7 & 0 & 9 & -10 & 0\end{pmatrix} * \begin{pmatrix}1.03\\-1.83\\0.8\\0.9\\-1.64\\0.7\end{pmatrix}}{\sqrt{294/6} * \sqrt{1.54}} = 0.88$$

$$Cor(X^1 : Poids, C_2) = \frac{Cov(X^1, C_2)}{\sigma_{X^1}.\sigma_{C_2}} = \frac{\sum_{i=1}^{n} P_i.X_i^1.C_2^i}{\sigma_{X^1}.\sqrt{\lambda_2}} = \frac{\frac{1}{N}(X^1)^t.C_2}{\sigma_{X^1}.\sqrt{\lambda_2}} = \frac{\frac{1}{6}\begin{pmatrix}8 & -7 & 0 & 9 & -10 & 0\end{pmatrix} * \begin{pmatrix}-0.63\\-0.37\\0.8\\-0.9\\0.44\\0.7\end{pmatrix}}{\sqrt{294/6} * \sqrt{0.46}} = -0.54$$

$$Cor(X^2 : Taille, C_1) = \frac{Cov(X^2, C_1)}{\sigma_{X^2}.\sigma_{C_1}} = \frac{\sum_{i=1}^{n} P_i.X_i^2.C_1^i}{\sigma_{X^2}.\sqrt{\lambda_1}} = \frac{\frac{1}{N}(X^2)^t.C_1}{\sigma_{X^2}.\sqrt{\lambda_1}} = \frac{\frac{1}{6}\begin{pmatrix}2 & -11 & 8 & 0 & -6 & 7\end{pmatrix} * \begin{pmatrix}1.03\\-1.83\\0.8\\0.9\\-1.64\\0.7\end{pmatrix}}{\sqrt{274/6} * \sqrt{1.54}} = 0.86$$

$$Cor(X^2 : Taille, C_2) = \frac{Cov(X^2, C_2)}{\sigma_{X^2}.\sigma_{C_2}} = \frac{\sum_{i=1}^{n} P_i.X_i^2.C_2^i}{\sigma_{X^2}.\sqrt{\lambda_2}} = \frac{\frac{1}{N}(X^2)^t.C_2}{\sigma_{X^2}.\sqrt{\lambda_2}} = \frac{\frac{1}{6}\begin{pmatrix}2 & -11 & 8 & 0 & -6 & 7\end{pmatrix} * \begin{pmatrix}-0.63\\-0.37\\0.8\\-0.9\\0.44\\0.7\end{pmatrix}}{\sqrt{274/6} * \sqrt{0.46}} = 0.42$$

Les partitions possibles

$P_1 = \{\{I_1, I_4\}, \{I_3, I_6\}, \{I_2\}, \{I_5\}\}$

$C_1\ C_2\ C_3\ C_4$

C_1 : Poids et taille importants / Poids >taille.

C_2 : Poids et taille importants / Poids <taille.

C_3 : Poids et taille petits / Poids >taille.

C_4 : Poids et taille petits / Poids <taille.

$P_2 = \{\{I_1, I_2, I_4\}, \{I_3, I_5, I_6\}\}$

$C_1\ C_2$

C_1 : Poids >taille.

C_2 : Poids <taille.

$P_3 = \{\{I_1, I_3, I_4, I_6\}, \{I_2, I_5\}\}$

$C_1\ C_2$

C_1 : Poids et taille importants.

C_2 : Poids et taille petits.

$P_4 = \{\{I_1, I_4\}, \{I_3, I_6\}, \{I_2, I_5\}\}$

$C_1\ C_2\ C_3$

C_1 : Poids et taille importants / Poids >taille.

C_2 : Poids et taille importants / Poids <taille.

C_3 : Poids et taille petits.

$P_5 = \{\{I_1, I_3, I_4, I_6\}, \{I_2\}, \{I_5\}\}$

$C_1\ C_2\ C_3$

C_1 : Poids et taille importants.

C_2 : Poids et taille petits / Poids >taille.

C_3 : Poids et taille petits/ Poids< taille.

Exercice :

On a relevé dans trois magasins (M1, M2 et M3) d'un même quartier appartenant à des chaines différentes. Les prix affichés pour quatre produits vendus sous quatre marques différentes (A, B, C et D).

	M1	**M2**	**M3**
A	16	20	12
B	20	12	22
C	16	24	26
D	28	24	20

1. On veut faire effectuer l'analyse en composantes principales de ce tableau (Données homogènes).
   - Vérifier que $U_1^t = 1/\sqrt{3}(1 \quad 1 \quad 1)$ et $U_2^t = 1/\sqrt{6}(1 \quad 1 \quad -2)$ sont des vecteurs propres de cette ACP
2. Représenter le nuage des points produits dans le plan principal.
3. Représenter le produit supplémentaire E ayant les prix suivants : $E^t = (16 \quad 8 \quad 12)$
4. Représenter graphiquement les trois variables (M1, M2 et M3).

Solution :

1. U_1, U_2 **sont des vecteurs propres de VM** $\Rightarrow \exists \lambda_1 \; tq \quad VMU_1 = \lambda_1 U_1$; $\exists \lambda_2 \; tq \quad VMU_2 = \lambda_2 U_2$

- Le tableau centré $X_{\prec n,p \succ}$:
  - Calcul du centre de gravité : $g = \dfrac{\sum_{i=1}^{n} p_i . x_i}{\sum_{i=1}^{n} p_i}$

$P_i = \dfrac{1}{N}$ où N représente le nombre d'individus. Cela implique que $P_i = \dfrac{1}{4}$; $i = 1,.....,n; i = 1...'$; $j = 1,.....p; 1...3$

$$g = \begin{pmatrix} \frac{1}{4}(16+20+16+28) \\ \frac{1}{4}(20+12+24+24) \\ \frac{1}{4}(12+22+26+20) \end{pmatrix} = \begin{pmatrix} 20 \\ 20 \\ 20 \end{pmatrix}$$

	M1	M2	M3
A	16	20	12
B	20	12	22
C	16	24	26
D	28	24	20
g	**20**	**20**	**20**

Tableau centré $X = \begin{pmatrix} 16-20 & 20-20 & 12-20 \\ 20-20 & 12-20 & 22-20 \\ 16-20 & 24-20 & 26-20 \\ 28-20 & 24-20 & 20-20 \end{pmatrix} = \begin{pmatrix} -4 & 0 & -8 \\ 0 & -8 & 2 \\ -4 & 4 & 6 \\ 8 & 4 & 0 \end{pmatrix}$

- Calcul de la matrice variance –covariance : $V = \frac{1}{N} X^t.X \Rightarrow V = \begin{pmatrix} 24 & 4 & 2 \\ 4 & 24 & 2 \\ 2 & 2 & 26 \end{pmatrix}$.

- Détermination de la métrique :

Les données sont homogènes car elles possèdent la même unité de mesure

$\Rightarrow M = Id = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$

- U_1, U_2 **sont des vecteurs propres de VM** $\Rightarrow \exists \lambda_1 \; tq \quad VMU_1 = \lambda_1 U_1$; $\exists \lambda_2 \; tq \quad VMU_2 = \lambda_2 U_2$

$$\Rightarrow \exists \lambda_1 \; tq \quad VMU_1 = \lambda_1 U_1 \Rightarrow \begin{pmatrix} 24 & 4 & 2 \\ 4 & 24 & 2 \\ 2 & 2 & 26 \end{pmatrix} . \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \lambda_1 \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \Rightarrow \frac{30}{\sqrt{3}} = \frac{\lambda_1}{\sqrt{3}} \Rightarrow \lambda_1 = 30$$

$$\Rightarrow \exists \lambda_2 \; tq \quad VMU_2 = \lambda_2 U_2 \Rightarrow \begin{pmatrix} 24 & 4 & 2 \\ 4 & 24 & 2 \\ 2 & 2 & 26 \end{pmatrix} . \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix} = \lambda_2 \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix} \Rightarrow \frac{24}{\sqrt{6}} = \frac{\lambda_1}{\sqrt{6}} \Rightarrow \lambda_2 = 24$$

Le plan principal : On cherche à projeter les données dans un espace à deux dimensions U_1, U_2

- $Tr(VM) = \sum_{j=1}^{P} \lambda_j \Rightarrow 74 = 30 + 24 + \lambda_3 \Rightarrow \lambda_3 = 20 \; (\lambda_1 = 30 \succ \lambda_2 = 24 \succ \lambda_3 = 20)$

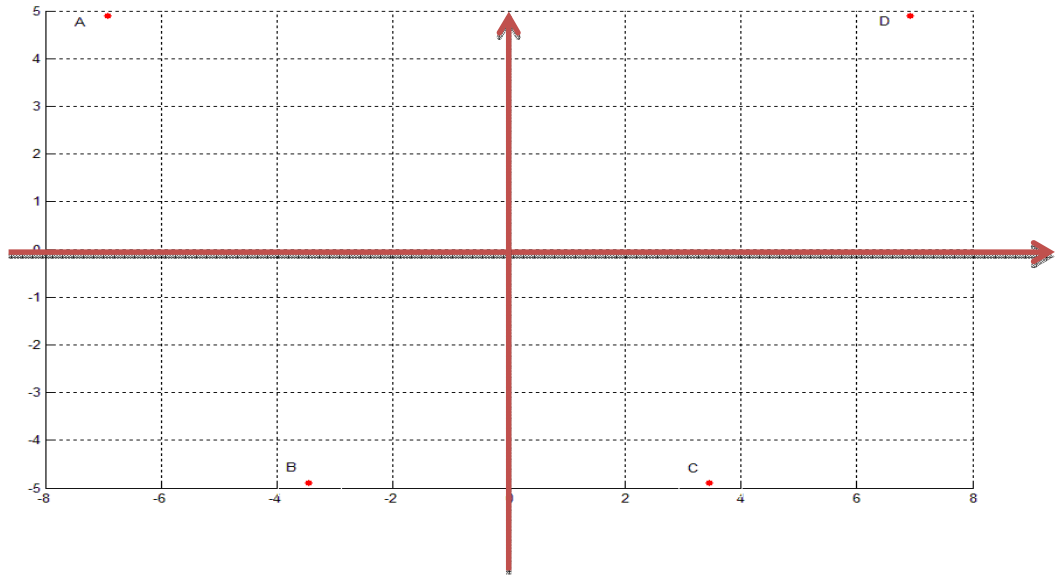
2. Coordonnées des produits (Individus) : $C_k = X.M.U_k$

$$C_1 = X.M.U_1 = X.Id.U_1 = X.U_1 = \begin{pmatrix} -4 & 0 & -8 \\ 0 & -8 & 2 \\ -4 & 4 & 6 \\ 8 & 4 & 0 \end{pmatrix}.\frac{1}{\sqrt{3}}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{3}}\begin{pmatrix} -12 \\ -6 \\ +6 \\ +12 \end{pmatrix} = \sqrt{3}\begin{pmatrix} -4 \\ -2 \\ +2 \\ +4 \end{pmatrix}$$

$$C_2 = X.M.U_2 = X.Id.U_2 = X.U_2 = \begin{pmatrix} -4 & 0 & -8 \\ 0 & -8 & 2 \\ -4 & 4 & 6 \\ 8 & 4 & 0 \end{pmatrix}.\frac{1}{\sqrt{6}}\begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix} = \frac{1}{\sqrt{6}}\begin{pmatrix} +12 \\ -12 \\ -12 \\ +12 \end{pmatrix} = \sqrt{6}\begin{pmatrix} +2 \\ -2 \\ -2 \\ +2 \end{pmatrix}$$

- **Représentation graphique des individus :**

$A = (-4\sqrt{3}, +2\sqrt{6}); B = (-2\sqrt{3}, -2\sqrt{6}); C = (2\sqrt{3}, -2\sqrt{6}); D = (4\sqrt{3}, 2\sqrt{6});$



3. Coordonnées de E=(16 8 12)^t

$$C_1 = X.M.U_1 = X.Id.U_1 = X.U_1 = (16-20 \quad 8-20 \quad 12-20).\frac{1}{\sqrt{3}}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = (-4 \quad -12 \quad -8)\frac{1}{\sqrt{3}}\begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -8\sqrt{3}$$

$$C_2 = X.M.U_2 = X.Id.U_2 = X.U_2 = (-4 \quad -12 \quad -8).\frac{1}{\sqrt{6}}\begin{pmatrix} 1 \\ 1 \\ -2 \end{pmatrix} = 0$$

$E = (-8\sqrt{3}, 0);$

4. Représentation des variables à l'aide du coefficient de corrélation

$$Cor\left(X^{j},C_{K}\right)=\frac{Cov\left(X^{j},C_{k}\right)}{\sigma_{X^{j}}.\sigma_{C_{k}}}=\frac{\sum_{i=1}^{n}P_{i}.X_{i}^{j}.C_{k}^{i}}{\sigma_{X^{j}}.\sqrt{\lambda_{k}}}=\frac{\frac{1}{N}\left(X^{j}\right)^{t}.C_{k}}{\sigma_{X^{j}}.\sqrt{\lambda_{k}}}$$

$$Cor\left(X^{1}:M_{1},C_{1}\right)=\frac{Cov\left(X^{1},C_{1}\right)}{\sigma_{X^{1}}.\sigma_{C_{1}}}=\frac{\sum_{i=1}^{n}P_{i}.X_{i}^{1}.C_{1}^{i}}{\sigma_{X^{1}}.\sqrt{\lambda_{1}}}=\frac{\frac{1}{N}\left(X^{1}\right)^{t}.C_{1}}{\sigma_{X^{1}}.\sqrt{\lambda_{1}}}=\frac{\frac{1}{4}\begin{pmatrix}-4 & 0 & -4 & -8\end{pmatrix}*\sqrt{3}\begin{pmatrix}-4\\-2\\+2\\+4\end{pmatrix}}{\sqrt{24}*\sqrt{30}}=-\frac{\sqrt{3}}{2\sqrt{5}}=0.39$$

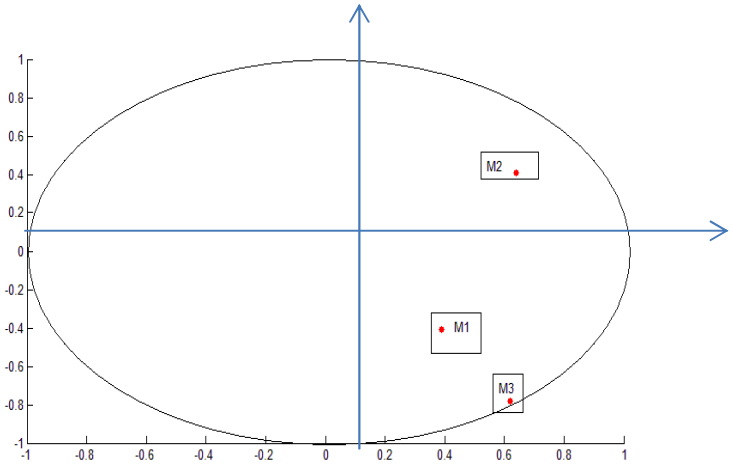
$$Cor\left(X^{1}:M_{1},C_{2}\right)=\frac{Cov\left(X^{1},C_{2}\right)}{\sigma_{X^{1}}.\sigma_{C_{2}}}=\frac{\sum_{i=1}^{n}P_{i}.X_{i}^{1}.C_{2}^{i}}{\sigma_{X^{1}}.\sqrt{\lambda_{2}}}=\frac{\frac{1}{N}\left(X^{1}\right)^{t}.C_{2}}{\sigma_{X^{1}}.\sqrt{\lambda_{2}}}=\frac{\frac{1}{4}\begin{pmatrix}-4 & 0 & -4 & -8\end{pmatrix}*\sqrt{6}\begin{pmatrix}+2\\-2\\-2\\+2\end{pmatrix}}{\sqrt{24}*\sqrt{24}}=\frac{-1}{\sqrt{6}}=-0.41$$

$$Cor\left(X^{2}:M_{2},C_{1}\right)=\frac{Cov\left(X^{2},C_{1}\right)}{\sigma_{X^{2}}.\sigma_{C_{1}}}=\frac{\sum_{i=1}^{n}P_{i}.X_{i}^{2}.C_{1}^{i}}{\sigma_{X^{2}}.\sqrt{\lambda_{1}}}=\frac{\frac{1}{N}\left(X^{2}\right)^{t}.C_{1}}{\sigma_{X^{2}}.\sqrt{\lambda_{1}}}=\frac{\frac{1}{4}\begin{pmatrix}0 & -8 & 4 & 4\end{pmatrix}*\sqrt{3}\begin{pmatrix}-4\\-2\\+2\\+4\end{pmatrix}}{\sqrt{24}*\sqrt{30}}=\frac{\sqrt{5}}{2\sqrt{3}}=0.64$$

$$Cor\left(X^{2}:N_{2},C_{2}\right)=\frac{Cov\left(X^{2},C_{2}\right)}{\sigma_{X^{2}}.\sigma_{C_{2}}}=\frac{\sum_{i=1}^{n}P_{i}.X_{i}^{2}.C_{2}^{i}}{\sigma_{X^{2}}.\sqrt{\lambda_{2}}}=\frac{\frac{1}{N}\left(X^{2}\right)^{t}.C_{2}}{\sigma_{X^{2}}.\sqrt{\lambda_{2}}}=\frac{\frac{1}{4}\begin{pmatrix}0 & -8 & 4 & 4\end{pmatrix}*\sqrt{6}\begin{pmatrix}+2\\-2\\-2\\+2\end{pmatrix}}{\sqrt{24}*\sqrt{24}}=\frac{1}{\sqrt{6}}=0.41$$

$$Cor\left(X^3 : N_3, C_1\right) = \frac{Cov\left(X^3, C_1\right)}{\sigma_{X^3}.\sigma_{C_1}} = \frac{\sum_{i=1}^{n} P_i.X_i^3.C_1^i}{\sigma_{X^3}.\sqrt{\lambda_1}} = \frac{\frac{1}{N}\left(X^3\right)^t.C_1}{\sigma_{X^3}.\sqrt{\lambda_1}} = \frac{\frac{1}{4}\begin{pmatrix}-8 & 2 & 6 & 0\end{pmatrix} * \sqrt{3}\begin{pmatrix}-4\\-2\\+2\\+4\end{pmatrix}}{\sqrt{26} * \sqrt{30}} = \frac{\sqrt{5}}{\sqrt{13}} = 0.62$$

$$Cor\left(X^3 : N_3, C_2\right) = \frac{Cov\left(X^3, C_2\right)}{\sigma_{X^3}.\sigma_{C_2}} = \frac{\sum_{i=1}^{n} P_i.X_i^3.C_2^i}{\sigma_{X^3}.\sqrt{\lambda_2}} = \frac{\frac{1}{N}\left(X^3\right)^t.C_2}{\sigma_{X^3}.\sqrt{\lambda_2}} = \frac{\frac{1}{4}\begin{pmatrix}-8 & 2 & 6 & 0\end{pmatrix} * \sqrt{6}\begin{pmatrix}+2\\-2\\-2\\+2\end{pmatrix}}{\sqrt{26} * \sqrt{24}} = \frac{-4}{\sqrt{26}}$$



Cercle de corrélation.

La première composante C_1 est positivement corrélée avec les trois variables (M1, M2 et M3). C_1 nous informe sur la quantité moyenne stockée dans les trois magasins (C_1≈moyenne).

C_2 est positivement corrélée avec M2 et négativement corrélée avec M1, M3. C1 nous informe sur la différence entre la quantité stockée dans le magasin M2 et les deux autres magasins M1, M3.

On peut aussi déduire que la Qte-moy(D)>Qte-moy(C)>Qte-moy(B)>Qte-moy(A).

5. Cordonnée de E :

$$C_1 = X.M.U_1 = X.Id.U_1 = X.U_1 = (16-20 \quad 8-20 \quad 12-20).\frac{1}{\sqrt{3}}\begin{pmatrix}1\\1\\1\end{pmatrix} = (-4 \quad -12 \quad -8)\frac{1}{\sqrt{3}}\begin{pmatrix}1\\1\\1\end{pmatrix} = -8\sqrt{3}$$

$$C_2 = X.M.U_2 = X.Id.U_2 = X.U_2 = (-4 \quad -12 \quad -8).\frac{1}{\sqrt{6}}\begin{pmatrix}1\\1\\-2\end{pmatrix} = 0 \Rightarrow E = (-8\sqrt{3},0);$$