Université des Sciences et de la Technologie Mohamed-Boudiaf d'Oran
Faculté des Mathématiques et Informatique
Département d'Informatique
Master 1 RSD: Module: Analyse de données

FICHE DE TP 2

Objectifs de la séance

À la fin de ce TP, l'étudiant doit être capable de :

- mettre en œuvre une ACP à partir d'un tableau de données numériques ;
- distinguer l'ACP non normée de l'ACP normée ;
- calculer les valeurs propres, les vecteurs propres et les pourcentages d'inertie ;
- projeter les individus dans le plan factoriel et interpréter le graphique ;
- programmer les étapes principales de l'ACP en Python.

Partie 1 — Préparation numérique

Soit un ensemble de six individus dont on a mesuré le poids et la taille.

	POIDS	TAILLE
I1	20	**15**
I2	5	**2**
I3	12	**21**
I4	21	**13**
I5	2	**7**
I6	12	**20**

On cherche à représenter les individus dans un espace de dimension réduite, tout en conservant le maximum d'information contenu dans les données.

Convention de calcul : pour l'application numérique, on utilise le dénominateur n=6 pour les variances et covariances. Dans la programmation, on conservera cette même convention afin de comparer les résultats.

Partie 1 — Application numérique de l'ACP

Effectuer les calculs suivants sur papier. Les résultats obtenus serviront de référence pour vérifier le programme Python.

1.1. Calcul des moyennes et centrage :

1. Calculer les moyennes des variables X et Y: $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} x_i$, $\bar{Y} = \frac{1}{n}\sum_{i=1}^{n} y_i$

2. Centrer les deux variables : $x_i^c = x_i - \bar{X}$, $y_i^c = x_i - \bar{Y}$,

3. Compléter le tableau des données centrées.

	x_i^c	y_i^c
I1	…	…
I2	…	…
I3	…	…
I4	…	…
I5	…	…
I6	…	…

1.2. Calcul de la matrice de covariance

1. Calculer les variances des deux variables : $Var(X) = \frac{1}{n}\sum_{i=1}^{n}(x_i^c)^2$, $Var(Y) = \frac{1}{n}\sum_{i=1}^{n}(y_i^c)^2$
2. Calculer ensuite leur covariance :$Cov(X,Y) = \frac{1}{n}\sum_{i=1}^{n} x_i^c\, y_i^c$
3. Construire la matrice de covariance : $C = \begin{pmatrix} Var(X) & Cov(X,Y) \\ Cov(X,Y) & Var(Y) \end{pmatrix}$

Question : que représentent les termes diagonaux et les termes hors diagonale de cette matrice ?

1.3. Détermination des valeurs propres et des axes principaux

Les axes principaux de l'ACP sont les directions associées aux valeurs propres de la matrice de covariance.

1. Déterminer les valeurs propres en résolvant : $\det(C - \lambda I) = 0$

2. Classer les valeurs propres par ordre décroissant : $\lambda_1 \geq \lambda_2$

1. Déterminer un vecteur propre associé à chacune des valeurs propres.
2. Vérifier que les deux vecteurs propres sont orthogonaux.

1.4. Calcul de l'inertie expliquée

Calculer l'inertie totale : $I_{tot} = \lambda_1 + \lambda_2$

Puis le pourcentage d'inertie expliqué par chaque axe : $P_k = \frac{\lambda_k}{\lambda_1+\lambda_2} \times 100$

Questions :

- Quel axe explique la plus grande part de la dispersion des données ?
- Quel pourcentage d'inertie est conservé par le premier axe ?
- Les deux axes permettent-ils de représenter toute l'inertie du tableau ? Justifier.

1.5. Projection des individus dans le plan factoriel

Les coordonnées factorielles de l'individu i sur l'axe k sont calculées par projection :

$$F_{ik} = x_i^c u_{k1} + y_i^c u_{k2}$$

Où $u_k = (u_{k1}, u_{k2})$ est le vecteur propre associé à l'axe k

Calculer les coordonnées des individus sur le premier axe.

1. Calculer leurs coordonnées sur le deuxième axe.
2. Compléter le tableau :

	F_{i1}	F_{i2}
I1	...	...
I2	...	...
I3	...	...
I4	...	...
I5	...	...
I6	...	...

3. Représenter les individus dans le plan factoriel (F_1, F_2)

Partie 2 — Implémentation de l'ACP en Python

À l'aide de Python et des bibliothèques NumPy et Matplotlib, écrire un programme permettant de reproduire les calculs de la première partie.

2.1. ACP non normée

Le programme doit :

1. saisir les données dans un tableau NumPy ;
2. calculer les moyennes et centrer les variables ;
3. calculer la matrice de covariance avec le dénominateur n ;
4. calculer les valeurs propres et les vecteurs propres ;
5. trier les valeurs propres par ordre décroissant ;
6. calculer les pourcentages d'inertie expliquée ;
7. projeter les individus sur les deux axes principaux ;
8. afficher les résultats numériques.

Vérification : comparer les moyennes, la matrice de covariance, les valeurs propres et les coordonnées factorielles obtenues par Python avec les résultats de la partie 1.

2.2. Tracé du plan factoriel

Tracer le nuage des individus dans le plan (F_1, F_2)

Le graphique doit contenir :

- les points représentant les individus ;
- les étiquettes $I_1 \ldots I_6$;
- les axes passant par l'origine ;

- un titre ;
- les noms des axes avec leurs pourcentages d'inertie expliquée.

2.3. ACP normée

Réaliser une deuxième ACP en centrant et en réduisant les variables : $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$

Où s_j désigne l'écart-type de la variable *j*, calculé avec la convention du dénominateur *n*.

Le programme doit :

1. calculer les variables centrées-réduites ;
2. construire la matrice de covariance des variables réduites ;
3. déterminer les valeurs propres et les vecteurs propres ;
4. calculer les coordonnées factorielles des individus ;
5. tracer le plan factoriel de l'ACP normée.

2.4. Comparaison des deux méthodes

Afficher et comparer :

- les valeurs propres de l'ACP non normée et de l'ACP normée ;
- les pourcentages d'inertie expliquée ;
- les deux plans factoriels.

Question : les deux ACP produisent-elles nécessairement les mêmes axes et les mêmes représentations ? Expliquer.