USTO-MB/FMI/Dept.Informatique/Master

Matière : AND 2026-2027

TD N°1

Distances, corrélations et codage disjonctif

Exercise 1 :

Soit le tableau suivant représente les clients et leurs achats dans un magasin :

ID	Âge	Nbre d'achat
1	25	3
2	30	5
3	22	2
4	35	8

a) Calculer la distance euclidienne entre les clients 1 et 2 sur la base de leurs caractéristiques âge et nbre d'achat.

b) Calculer la distance Manhattan entre client 3 et 4.

c) Construire le tableau de distance (euclidienne).

Solution:

a) Distance euclidienne entre clients 1 et 2

Distance euclidienne : $d(A,B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$

$$\begin{aligned} d(C1, C2) &= \sqrt{(25-30)^2 + (3-5)^2} \\ &= \sqrt{(-5)^2 + (-2)^2} \\ &= \sqrt{25+4} = \sqrt{29} \approx 5.385 \end{aligned}$$

b) Distance Manhattan entre clients 3 et 4

Distance Manhattan : $d(A,B) = |x_1 - x_2| + |y_1 - y_2|$

$$\begin{aligned} d(C3, C4) &= |22-35| + |2-8| \\ &= 13 + 6 = 19 \end{aligned}$$

c) Tableau de distances euclidiennes

Calcul des distances :

- $d(C1, C3) = \sqrt{(25-22)^2 + (3-2)^2} = \sqrt{9+1} = \sqrt{10} \approx 3.162$
- $d(C1, C4) = \sqrt{(25-35)^2 + (3-8)^2} = \sqrt{100+25} = \sqrt{125} \approx 11.402$
- $d(C2, C3) = \sqrt{(30-22)^2 + (5-2)^2} = \sqrt{64+9} = \sqrt{73} \approx 8.062$
- $d(C2, C4) = \sqrt{(30-35)^2 + (5-8)^2} = \sqrt{25+9} = \sqrt{34} \approx 5.831$
- $d(C3, C4) = \sqrt{(22-35)^2 + (2-8)^2} = \sqrt{169+36} = \sqrt{205} \approx 14.318$

	C1	**C2**	**C3**	**C4**
C1	0.000	5.385	3.162	11.402
C2	5.385	0.000	8.062	5.831
C3	3.162	8.062	0.000	14.318
C4	11.402	5.831	14.318	0.000

Exercise 2 :

On veut prédire si une boisson est thé ou café suivant les données suivantes :

Boisson	**Volume (ml)**	**Caféine (g)**
thé	250	0.025
thé	100	0.010
café	125	0.050
café	250	0.100

a) Calculer la corrélation entre volume et caféine.

b) Quel serait l'étiquette prédite pour une boisson de 125ml contenant 0.015 g de caféine.

Solution:

a) Corrélation entre volume et caféine

Coefficient de corrélation de Pearson :

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Calcul des moyennes :

$$\bar{x} = \frac{250 + 100 + 125 + 250}{4} = \frac{725}{4} = 181.25$$
$$\bar{y} = \frac{0.025 + 0.010 + 0.050 + 0.100}{4} = \frac{0.185}{4} = 0.04625$$

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$
250	0.025	68.75	-0.02125	-1.4609	4726.5625	0.0004516
100	0.010	-81.25	-0.03625	2.9453	6601.5625	0.0013141
125	0.050	-56.25	0.00375	-0.2109	3164.0625	0.0000141
250	0.100	68.75	0.05375	3.6953	4726.5625	0.0028891
Total				4.9688	19218.7500	0.0046689

$$r = \frac{4.9688}{\sqrt{19218.75 \times 0.0046689}}$$
$$= \frac{4.9688}{\sqrt{89.7835}} = \frac{4.9688}{9.4754} \approx 0.5244$$

Une corrélation positive modérée ($r > 0$: quand le volume de la boisson augmente, la quantité de caféine tend aussi à augmenter).

b) Prédiction pour (125ml, 0.015g)

Méthode des plus proches voisins :

Boisson	**Calcul de distance**	**Distance**
Thé (250,0.025)	$\sqrt{(125-250)^2 + (0.015-0.025)^2}$	125.0000
Thé (100,0.010)	$\sqrt{(125-100)^2 + (0.015-0.010)^2}$	25.0005
Café (125,0.050)	$\sqrt{(125-125)^2 + (0.015-0.050)^2}$	0.0350
Café (250,0.100)	$\sqrt{(125-250)^2 + (0.015-0.100)^2}$	125.0287

La distance la plus petite est 0.0350 avec le café. Donc l'étiquette prédite est **café**.

Exercise 3 :

Ines caractérise des mélodies. Elle considère comme variables les 7 notes do, ré, mi, fa, sol, la et si. Les trois mélodies qui l'intéressent sont :

- A : si si do ré ré do si la sol sol la
- B : do do do ré mi ré do mi ré ré do
- C : sol sol si la si la sol sol si si la

Sans passer par le codage disjonctif :

a) Quelle est la distance de Hamming entre A et B, A et C, B et C.

b) Quelle est la similarité de Jaccard entre A et B, A et C, B et C.

c) Quelles sont les notes similaires ?

Solution:

a) Distance de Hamming

La distance de Hamming compte le nombre de positions où les séquences diffèrent.

Position	1	2	3	4	5	6	7	8	9	10	11
A	si	si	do	ré	ré	do	si	la	sol	sol	la
B	do	do	do	ré	mi	ré	do	mi	ré	ré	do
Différence	×	×	×		×		×	×	×	×	×

Distance A-B = 9

Position	1	2	3	4	5	6	7	8	9	10	11
A	si	si	do	ré	ré	do	si	la	sol	sol	la
C	sol	sol	si	la	si	la	sol	sol	si	si	la
Différence	×	×	×	×	×	×	×	×	×	×	

Distance A-C = 10

Position	1	2	3	4	5	6	7	8	9	10	11
B	do	do	do	ré	mi	ré	do	mi	ré	ré	do
C	sol	sol	si	la	si	la	sol	sol	si	si	la
Différence	×	×	×	×	×	×	×	×	×	×	×

Distance B-C = 11

b) Similarité de Jaccard

Similarité de Jaccard = $\frac{|A \cap B|}{|A \cup B|}$

- **A et B** :

$$
\begin{aligned}
A &= \{\text{si, do, ré, la, sol}\} \\
B &= \{\text{do, ré, mi}\} \\
A \cap B &= \{\text{do, ré}\} \\
A \cup B &= \{\text{si, do, ré, la, sol, mi}\} \\
J(A,B) &= \frac{2}{6} = 0.333 \quad (33.3\%)
\end{aligned}
$$

- **A et C** :

$$
\begin{aligned}
A &= \{\text{si, do, ré, la, sol}\} \\
C &= \{\text{sol, si, la}\} \\
A \cap C &= \{\text{si, la, sol}\} \\
A \cup C &= \{\text{si, do, ré, la, sol}\} \\
J(A,C) &= \frac{3}{5} = 0.6 \quad (60\%)
\end{aligned}
$$

- **B et C** :

$$
\begin{aligned}
B &= \{\text{do, ré, mi}\} \\
C &= \{\text{sol, si, la}\} \\
B \cap C &= \{\} \\
B \cup C &= \{\text{do, ré, mi, sol, si, la}\} \\
J(B,C) &= \frac{0}{6} = 0 \quad (0\%)
\end{aligned}
$$

c) Notes similaires

- A et B partagent les notes : do, ré
- A et C partagent les notes : si, la, sol
- B et C ne partagent aucune note

La plus grande similarité est entre A et C (60%).

Exercise 4 :

Soit le tableau de données suivant :

Produit	**Couleur**	**Taille**
P1	Bleu	XL
P2	Blanc	L
P3	Bleu	M
P4	Blanc	M
P5	Bleu	L

a) Construire le tableau de codage disjonctif.

b) Construire le tableau de contingence.

c) Construire le tableau des fréquences, profil ligne et profil colonne.

Solution:

a) Tableau de codage disjonctif

Variable couleur : qualitative nominale $N : N \to (0,1)^{(k=2)}$ (bleu, blanc)

$N(Bleu) = \begin{pmatrix}1\\0\end{pmatrix}$ $N(Blanc) = \begin{pmatrix}0\\1\end{pmatrix}$

Variable taille : qualitative ordinale $O : O \to (0,1)^{(k=3)}$ (M, L, XL) $O(M) = \begin{pmatrix}1\\0\\0\end{pmatrix}$ $O(L) = \begin{pmatrix}1\\1\\0\end{pmatrix}$ $O(XL) = \begin{pmatrix}1\\1\\1\end{pmatrix}$

	Bleu	**Blanc**	**M**	**L**	**XL**
P1	1	0	1	1	1
P2	0	1	1	1	0
P3	1	0	1	0	0
P4	0	1	1	0	0
P5	1	0	1	1	0

b) Tableau de contingence

Tableau de contingence : (variable/variable) (taille/couleur) : K_{ij} avec $K = \sum_i \sum_j K_{ij} = 5$

Couleur	**Taille**	**M**	**L**	**XL**	$f_{i.}$
Bleu		1	1	1	3
Blanc		1	1	0	2
$f_{.j}$		2	2	1	5

c) Tableau des fréquences, profil ligne et profil colonne

Tableau des fréquences $f_{ij} = \frac{n_{ij}}{n}$

$$f_{i.} = \sum_{j=1}^{p} f_{ij} \quad \text{fréquence marginale ligne}$$

$$f_{.j} = \sum_{i=1}^{n} f_{ij} \quad \text{fréquence marginale colonne}$$

	M f_{i1}	**L** f_{i2}	**XL** f_{i3}	$f_{i.}$
Bleu (f_{1j})	1/5	1/5	1/5	3/5
Blanc (f_{2j})	1/5	1/5	0/5	2/5
$f_{.j}$	2/5	2/5	1/5	1

Profils lignes : $F_J^i = \frac{f_{ij}}{f_{i.}}$

$F_J^i = \frac{f_{ij}}{f_{i.}}$	**M** F_1^i	**L** F_2^i	**XL** F_3^i	$f_{i.}$
Bleu (F_J^1)	1/3	1/3	1/3	3/5
Blanc (F_J^2)	1/2	1/2	0	2/5
$f_{.j}$	2/5	2/5	1/5	

Nuage $N(I) = \{(F_J^i, f_{i.}), i = 1, 2\} = \left\{ \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \end{bmatrix}, 3/5 \right\}; \left\{ \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix}, 2/5 \right\}$

Profils colonnes : $F_I^j = \frac{f_{ij}}{f_{.j}}$

$F_I^j = \frac{f_{ij}}{f_{.j}}$	**M** F_I^1	**L** F_I^2	**XL** F_I^3	$f_{i.}$
Bleu (F_I^1)	1/2	1/2	1/1	3/5
Blanc (F_I^2)	1/2	1/2	0	2/5
$f_{.j}$	2/5	2/5	1/5	

Nuage $N(J) = \{(F_I^j, f_{.j}), j = 1, 2, 3\} = \left\{ \begin{bmatrix} 1/2 \\ 1/2 \end{bmatrix}, 2/5 \right\}; \left\{ \begin{bmatrix} 1/2 \\ 1/2 \end{bmatrix}, 2/5 \right\}; \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, 1/5 \right\}$