Université des Sciences et de la Technologie Mohamed-Boudiaf d'Oran
Faculté des Mathématiques et Informatique
Département d'Informatique
Master 1 RSD: Module: Analyse de données

FICHE DE TP 1

Objectifs de la séance

1. Évaluer la dispersion d'une variable unique(Variance)
2. Analyser le sens et l'intensité de la relation linéaire entre deux variables (Covariance et corrélation de Pearson)
3. Visualiser des données à l'aide d'un nuage de points.
4. Mesurer la proximité géométrique entre des individus (Distance Euclidienne et Distance de Manhattan).

1. Rappels Théoriques Essentiels :

Soient deux variables numériques *X* et *Y* observées sur un échantillon d'individus :

- **Variance(S^2) :** Moyenne des écarts au carré par rapport à la moyenne. Elle exprime la dispersion des données.
- **Covariance (cov_{xy}) :** indique si *X* et *Y* évoluent conjointement dans le même sens (>0) ou en sens inverse (<0).
- **Corrélation de Pearson(*r*) :** Normalise la covariance entre -1 et 1 pour mesurer la force du lien linéaire.
- **Distance Euclidienne :** Distance géométrique directe ("à vol d' oiseau ")

$$d_{Eucl}(A,B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

- **Distance de Manhattan :** Somme des écarts absolus (déplacement en grille)

$$d_{Manh}(A,B) = |x_1 - x_2| + |y_1 - y_2|$$

2. Énoncer de l'exercice d'application

On étudie un échantillon de 5 étudiants. Les deux variables mesurées sont :
X : Nombre d'heure d'étude par semaine.
Y : Nombre obtenue à l'examen (sur 20).

ÉTUDIANT	HEURE D'ETUDE(*X*)	NOTE SUR 20(*Y*)
E1	5	10
E2	10	15
E3	2	8
E4	12	18
E5	6	12

3. Travail a réalisé

Partie A : Calculs manuels (Compréhension des mécanismes)

1. **Moyennes** : Calculer les moyennes respectives $\bar{X}$ et$\bar{Y}$.
2. **Dispersion et Liaison :** À l'aide d'un tableau intermédiaire, calculer la variance de X, la variance de Y, puis la covariance cov_{xy}**.**
3. **Intensité :** Calculer le coefficient de corrélation de Pearson r. les heures d'étude influencent-elles fortement la note ?
4. **Distances :** Calculer manuellement la distance Euclidienne et la distance de Manhattan entre l'étudiant E1 et l'étudiant E3.
5. **Analyse de profil :** en utilisant la distance Euclidienne, déterminer si l'étudiant E1a un profil plus proche de E2 ou de E3.

Partie B : Implémentation Machine (python)

Écrivez et exécuter un script Python effectuant les actions suivantes :

1. Créez le jeu de données sous forme de DataFrame Pandas.
2. Calculez automatiquement la variance de *X*, la covariance et la corrélation entre *X* et *Y*.
3. Générez le nuage de points (avec la droite de tendance linéaire) à l'aide de matplotlib ou seaborn.
4. Calculez les matrices complètes des distances Euclidiennes et de Manhattan à l'aide de la bibliothèque scipy.

Partie c : Questions d'interprétation et réflexion

1. **Interprétation graphique :** décrivez la forme générale du nuage de points obtenu à l'écran. Comment ce graphique confirme-t.il visuellement vos calculs de covariance et de corrélation ?
2. **Propriétés mathématiques** : si l'enseignant décide de doubler toutes les notes (passage sur 40), la variance de *Y* va-t-elle changer ? qu'en est-il du coefficient de corrélation ?
3. **Sensibilité des distances :** pourquoi la distance euclidienne est-elle qualifiée de "plus sensible aux valeurs extrêmes (grands écarts) "par rapport à la distance de Manhattan ?
4. **Causalité :** "une forte corrélation implique obligatoirement un lien de cause à effet". Expliquez pourquoi cette affirmation est fausse en donnant un exemple classique.