

الجزائريـــــــة الديمقراطيـــــة الشعبيـــة
وزارة التعليـــــم العـــــالي و البحـــــث العلـــمي
جامعة وهران للعلوم والتكنولوجيا محمد بوضياف
كلية الريـــاضيـــات و الإعـــلام الآلـــي
République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur Et de la Recherche Scientifique
Université des Sciences et de la Technologie d'Oran Mohamed BOUDIAF
Faculté des Mathématiques et Informatique
Département D'Informatique

Machine Learning Course

By Dr. Asmaa Ourdighi

Lecture 2

Chapitre 2: Prétraitement des données

1. **Gestion des valeurs manquantes et outliers**
2. Normalisation, discrétisation, encodage
3. Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Le prétraitement constitue une étape fondamentale de la chaîne d'apprentissage automatique :



Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

> *« Garbage in, garbage out. »* — Principe fondamental du Machine Learning

Idée centrale : un algorithme d'apprentissage ne corrige pas automatiquement la qualité des données**. Il exploite les régularités présentes dans celles-ci.** Une mauvaise qualité des données peut donc conduire à un modèle biaisé, instable ou difficile à généraliser.

pourquoi *une donnée doit être diagnostiquée,* ***comment*** *choisir une stratégie de traitement et* ***quelles conséquences*** *ce choix peut avoir sur l'apprentissage.*

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Pourquoi le prétraitement est-il nécessaire ?

Problème général

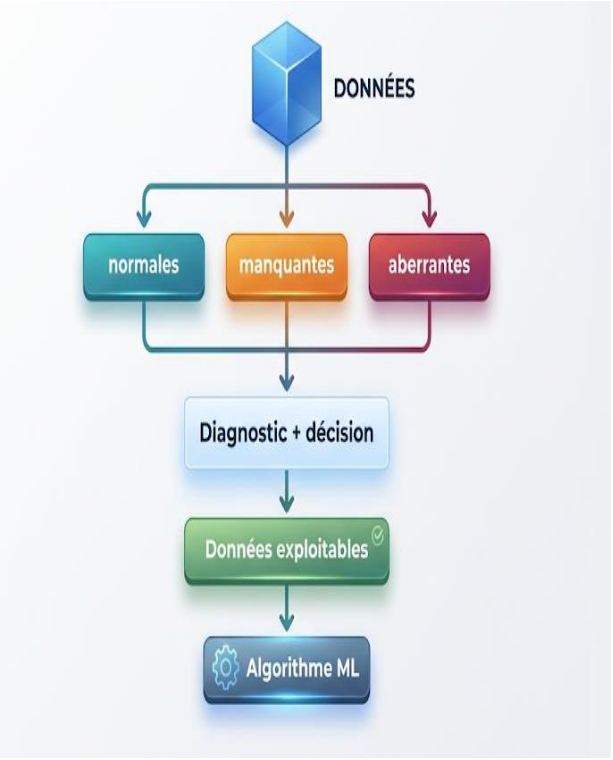
Considérons un ensemble de données « dataset», où x_i représente les variables(features) explicatives et y_i la cible(Label) :

$$D = \{(x_i, yi)\}_{i = 1..n}$$

Un algorithme d'apprentissage cherche une fonction qui minimise une fonction de perte sur les données d'apprentissage :

$$\hat{y} = f_{\vartheta}(x)$$

Si certaines observations sont absentes, **incohérentes ou extrêmement atypiques**, le modèle peut apprendre une relation qui ne représente pas correctement le phénomène étudié.



Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Niveaux de prétraitement

Dans un pipeline classique, on peut distinguer :
Cette section est consacrée au premier niveau : **le nettoyage des données**.

Niveau	Objectif	Exemples
Nettoyage	Améliorer la qualité des observations	NaN, outliers, doublons, incohérences
Transformation	Rendre les variables compatibles avec l'algorithme	Standardisation, normalisation, encodage
Sélection / réduction	Contrôler la représentation des données	Sélection de variables, PCA, feature engineering

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Valeurs manquantes

Définition

Une valeur manquante correspond à une **information non observée** pour une variable donnée. On peut représenter une observation par :

$$x_i = (x_{i1}, xi_2, \ldots, x_{ip})$$

et introduire un indicateur de manque :

$R_{ij} = 1$ *si* x_{ij} *est observé*

$R_{ij} = 0$ *si* x_{ij} *est manquant*

Le problème n'est donc pas seulement « combien de valeurs manquent ? », mais également :

La vraie question

Pourquoi ces valeurs manquent-elles ?

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Pourquoi les valeurs manquantes sont-elles problématiques ?

Problème 1 — Compatibilité algorithmique. De nombreux algorithmes classiques ne peuvent pas traiter directement des NaN (régression logistique, SVM, KNN, nombreux réseaux de neurones).

Problème 2 — Biais statistique. Supprimer systématiquement les observations incomplètes peut modifier la composition de l'échantillon.

Problème 3 — Perte d'information. La suppression de lignes réduit le nombre d'observations disponibles pour l'apprentissage.

Problème 4 — Distorsion de la distribution. Une mauvaise imputation peut modifier la moyenne, la variance, les corrélations et donc la structure apprise par le modèle.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Mécanismes de données manquantes : MCAR, MAR et MNAR

La théorie de Rubin distingue trois mécanismes fondamentaux.

1. MCAR: Missing Completely At Random

Le manque ne dépend ni de la valeur manquante ni des autres variables observées.

$$P(R \mid X_{obs}, X_{mis}) = P(R)$$

Exemple. Une panne aléatoire d'un capteur entraîne la perte de certaines mesures, indépendamment des caractéristiques des individus.

Manque —► indépendant des données

Une suppression ou une imputation simple peut être acceptable si la proportion de données manquantes reste limitée.

2. MAR: Missing At Random

La probabilité de manque dépend de **variables observées**.

$$P(R \mid X_{obs}, X_{mis}) = P(R \mid X_{obs})$$

Exemple. Les jeunes renseignent moins souvent leur salaire. Le manque du salaire dépend alors de l'âge, qui est observé.

Âge ——► probabilité de manque

|

▼

Salaire

Les méthodes multivariées peuvent exploiter les relations entre variables.

2.1 — Valeurs manquantes et valeurs aberrantes

3. MNAR: Missing Not At Random

Le mécanisme de manque dépend de **la valeur elle-même** ou d'une information non observée.

Exemple. Les personnes ayant les revenus les plus élevés sont moins susceptibles de déclarer leur salaire.

Valeur réelle du salaire



probabilité de manque

Le MNAR est particulièrement difficile à établir à partir des données seules : la variable qui expliquerait le manque n'est précisément pas observée.

Une connaissance du domaine, une modélisation spécifique ou une collecte complémentaire peut être nécessaire.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

3. MNAR: Missing Not At Random

Le mécanisme de manque dépend de **la valeur elle-même** ou d'une information non observée.

Exemple. Les personnes ayant les revenus les plus élevés sont moins susceptibles de déclarer leur salaire.

Valeur réelle du salaire

↓

probabilité de manque

Le MNAR est particulièrement difficile à établir à partir des données seules : la variable qui expliquerait le manque n'est précisément pas observée.

Une connaissance du domaine, une modélisation spécifique ou une collecte complémentaire peut être nécessaire.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Mécanisme	Description	Traitement recommandé
MCAR — Missing Completely At Random	La probabilité de manquer ne dépend d'aucune variable.	Imputation simple (moyenne / médiane) ou suppression.
MAR — Missing At Random	La probabilité dépend d'autres variables observées.	Imputation multivariée (KNN, MICE).
MNAR — Missing Not At Random	La probabilité dépend de la valeur manquante elle-même.	Modélisation explicite du manque, collecte complémentaire, ou suppression prudente.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Diagnostic des données manquantes

Avant tout traitement, il faut répondre à trois questions :

Combien de valeurs sont manquantes ?

Où sont-elles situées ?

Pourquoi pourraient-elles manquer ?

Quantification

Pour une variable X_j, le taux de données manquantes est :

$$r_j = \frac{(\sum_{i=1}^{n}(R_{ij} = 0))}{n}$$

- *Illustration computationnelle*

```
resume = pd.DataFrame({"manquants": df.isna().sum(),
   "pourcentage": df.isna().mean() * 100})
```

Le code sert ici à illustrer le concept de diagnostic ; la notion importante est le taux r_j, pas la mémorisation de la syntaxe.

Une matrice de présence / absence permet d'observer la structure du manque :

Variable	A	B	C	D	E
Observation 1	●	●	○	●	●
Observation 2	●	○	○	●	●
Observation 3	●	●	●	●	○
Observation 4	○	○	●	●	●

● observé ○ manquant

- Manques **dispersés** peuvent être compatibles avec MCAR ;
- Motifs récurrents peuvent indiquer une **dépendance entre le manque et d'autres variables** ;
- Un bloc de valeurs manquantes doit être **étudié avant toute imputation**.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Stratégies de traitement des valeurs manquantes

Il n'existe pas de méthode universelle.

Stratégie	Idée	Avantage	Limite
Suppression	Retirer lignes / colonnes	Simple	**Perte d'information**
Moyenne	Remplacer par la moyenne	Rapide	Réduit la variance
Médiane	Remplacer par la médiane	Robuste	Ignore les relations entre variables
Mode	Catégorie la plus fréquente	Adapté au catégoriel	Peut renforcer la catégorie dominante
KNN **K-Nearest Neighbors**	Utiliser des observations similaires	Exploite les relations locales	Sensible à l'échelle
MICE **Multiple Imputation by Chained Equations**	Modéliser chaque variable à partir des autres	Riche et multivarié	**Plus complexe**

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Suppression

Deux possibilités principales.

Suppression des observations

$D' = \{x_i \in D : x_i \text{ est complet}\}$

Elle est simple mais peut introduire un biais si les observations supprimées ne sont pas représentatives.

Suppression d'une variable

Une variable très fortement incomplète peut parfois être retirée si elle apporte peu d'information exploitable.

Attention

« Beaucoup de valeurs manquantes » ne signifie pas automatiquement « variable inutile ». La décision dépend du contexte, de la cible et de l'information portée par la variable.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Imputation simple

1. Moyenne

$$x_{ij}^{imp} = \bar{x}_j$$

La méthode est simple mais **sensible aux valeurs extrêmes**.

2. Médiane

$$x_{ij}^{imp} = Med(X_j)$$

La médiane est plus robuste aux distributions **asymétriques et aux outliers**. Données :

45 47 49 51 53 2000

Moyenne ⟶ fortement déplacée **moyenne vaut environ 374**

$$\bar{x} = \frac{45 + 47 + 49 + 51 + 53 + 2000}{6} = \frac{2245}{6} \approx 374{,}17$$

Médiane ⟶ reste proche du centre réel **médiane vaut 50** .

$$Méd = (49 + 51)/2 = 50$$

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Variable catégorielle

Pour une variable catégorielle, on peut utiliser :

→ la modalité la plus fréquente ;
→ une modalité dédiée « Inconnu » ;
→ une stratégie fondée sur d'autres variables.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

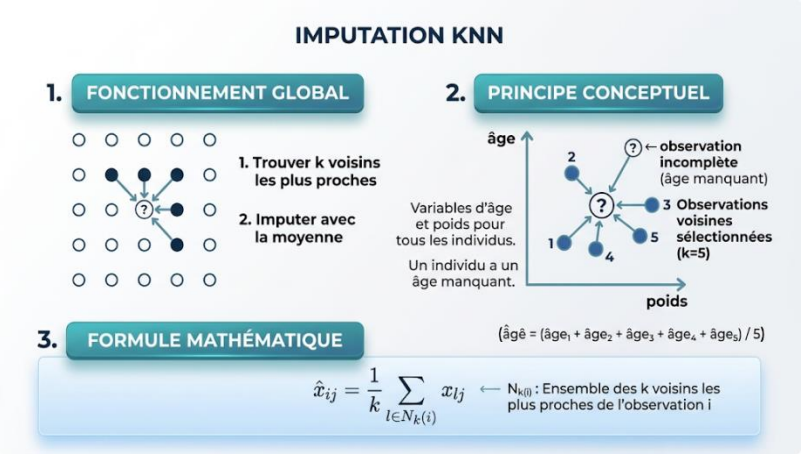
Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

KNNImputer

Le principe consiste à rechercher les observations les plus proches de l'observation incomplète. Pour une valeur manquante, on exploite les k voisins les plus proches :

$$\hat{x}_{ij} = \frac{1}{k} \sum_{l \in N_k(i)} x_{lj}$$



Symbole	Sens
$\hat{x}_{ij}$	Valeur **estimée** (imputée) pour l'observation i sur la variable j
k	Nombre de voisins retenus (ex. 5)
$N_k(i)$	Ensemble des k observations **les plus proches** de l'observation i
l	Indice d'un voisin
x_{lj}	Valeur **observée** de la variable j chez le voisin l

⚠ ⚠ Limite fondamentale

KNN dépend d'une notion de distance. Si une variable varie entre 0 et 1 et une autre entre 0 et 100 000, la seconde peut dominer la distance. La mise à l'échelle doit donc être considérée avant KNN.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

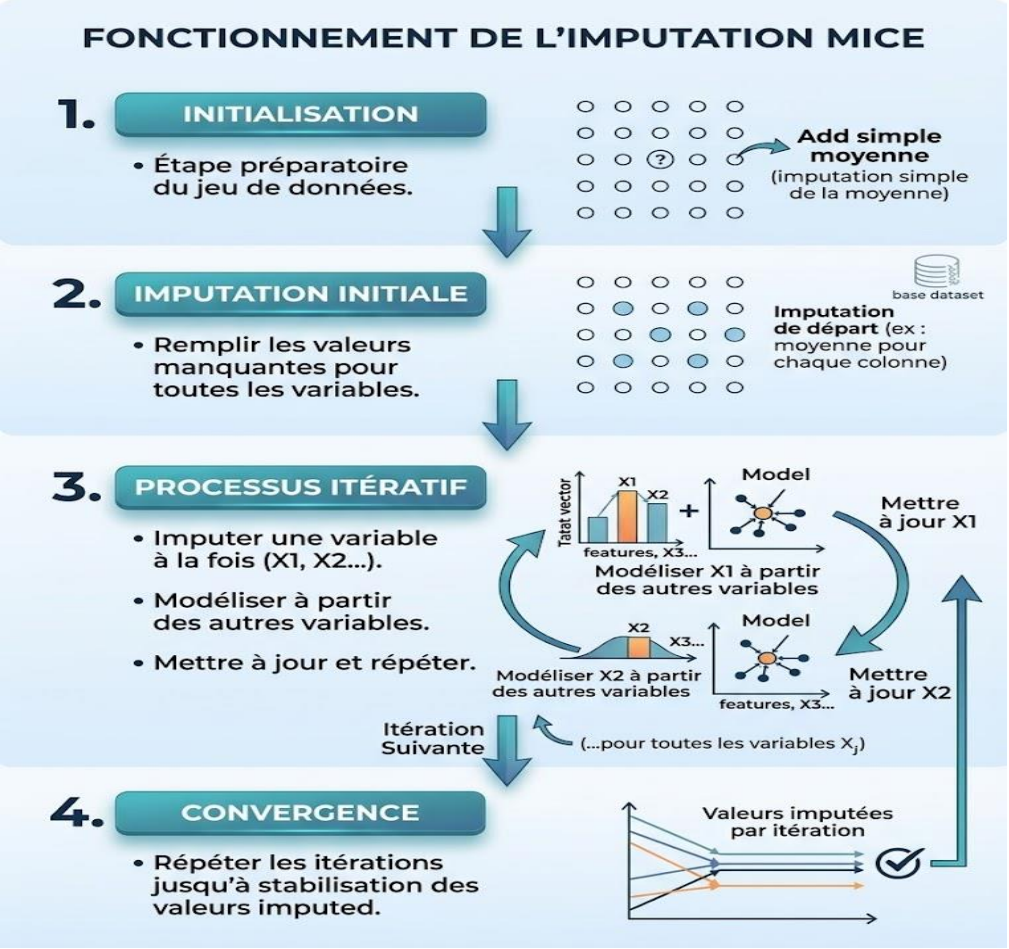
Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

MICE — Iterative Imputation

MICE (Multivariate Imputation by Chained Equations) considère les variables manquantes conjointement. Principe simplifié :



L'intérêt principal est de préserver davantage les relations entre variables lorsque le mécanisme est compatible avec une hypothèse MAR.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

MICE — Iterative Imputation

Six employés, deux variables. Deux valeurs manquent : le **salaire de l'employé 4** et l'**âge de l'employé 5**.

- **Étape 0 : initialisation par la moyenne**

Moyenne des âges observés : (25+30+35+40+50)/5 = **36** → âge de l'employé 5 = 36

Moyenne des salaires observés : (30+38+44+56+62)/5 = **46** → salaire de l'employé 4 = 46

Ce remplissage est volontairement grossier:

→ **l'employé 5, qui gagne 56 k, reçoit un âge de 36,**

→ **alors que l'employé 3 (35 ans) gagne 44 k.**

#	Âge	Salaire (k)
1	25	30
2	30	38
3	35	44
4	40	?
5	?	56
6	50	62

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

MICE — Iterative Imputation

Itération 1, variable Âge

On apprend maintenant **Âge = a + b × Salaire** sur les 5 lignes où l'âge est observé (1, 2, 3, 4, 6), en utilisant le salaire corrigé de l'employé 4 (52,2) :

- $\hat{A}ge \approx 1{,}09 + 0{,}77 \times salaire$ Prédiction pour l'employé 5 (56 k) : 1,09 + 0,77 × 56 ≈ **44,3**. L'âge passe de 36 (moyenne) à **44,3**.

Itération 2 : on recommence avec les valeurs mises à jour

La régression du salaire est réajustée avec l'âge 44,3 au lieu de 36 :

- $salaire \approx -0{,}87 + 1{,}27 \times \hat{A}ge \Rightarrow employé\ 4 \approx 52{,}0$ Puis celle de l'âge, avec le salaire 52,0 :
- Âge ≈ 1,04 + 0,77 × $salaire \Rightarrow employé\ 5 \approx 44{,}4$

#	Âge	Salaire (k)
1	25	30
2	30	38
3	35	44
4	40	?
5	?	56
6	50	62

$$b = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} \qquad a = \bar{y} - b\,\bar{x}$$

- b est la **pente** : de combien l'âge augmente quand le salaire augmente de 1.
- a est l'**ordonnée à l'origine**. La formule garantit que la droite passe par le point moyen $(\bar{x}, \bar{y})$.

	Initialisation	Itération 1	Itération 2
Salaire de l'employé 4	46	52,2	52,0
Âge de l'employé 5	36	44,3	44,4

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Comment comparer les imputations ?

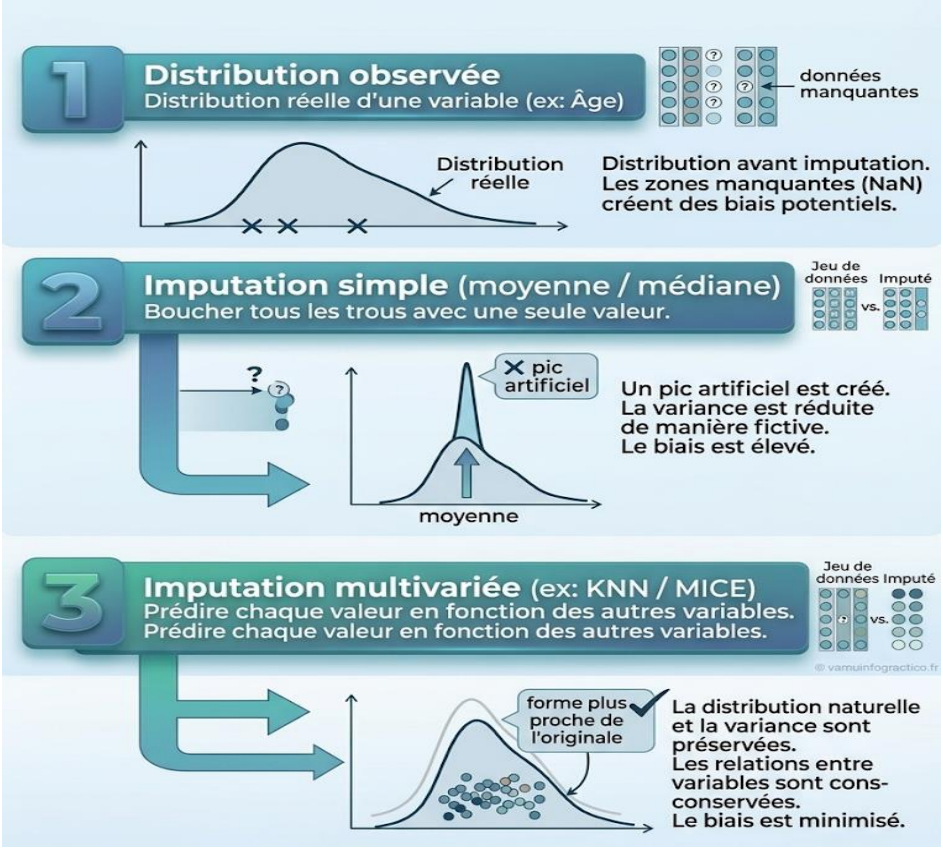
Une bonne imputation ne doit pas seulement « remplir les trous ». Elle doit autant que possible préserver :

→ la distribution ;

→ la variance ;

→ les relations entre variables ;

→ les structures utiles pour la prédiction.



Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Data leakage : principe fondamental

Le prétraitement doit respecter la séparation entre apprentissage et évaluation.

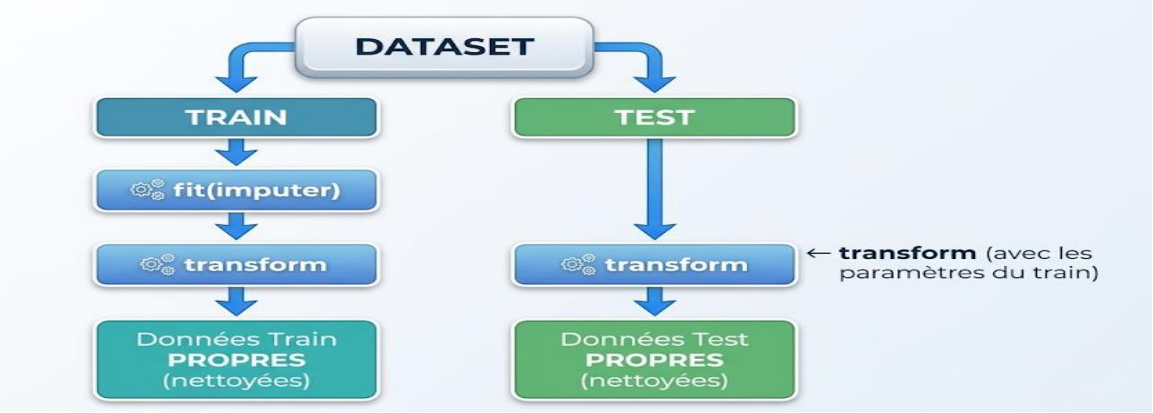


Figure — Le test ne sert jamais à estimer les paramètres du prétraitement

Si la médiane est calculée sur le dataset complet avant la séparation, une information provenant du test influence indirectement l'entraînement. **C'est une fuite de données.**

Règle

fit sur train → transform train et test

Bonne pratique. Utiliser un Pipeline permet de conserver cette discipline pendant la validation croisée.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

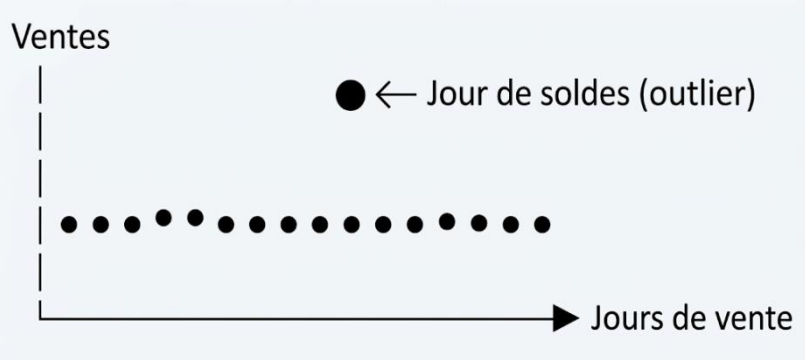
Valeurs aberrantes: Outliers

,

Définition

Un outlier est une observation qui s'écarte fortement du comportement habituel des données. Mais **un outlier n'est pas nécessairement une erreur**. Il peut représenter :

une erreur de saisie ;
une erreur de mesure ;
une observation rare mais légitime ;
un événement important à détecter.



En cybersécurité, au contraire, un comportement atypique peut être précisément **la cible** de la détection.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Impact des outliers sur les algorithmes

Les méthodes ne réagissent pas toutes de la même manière.
L'objectif n'est donc pas de supprimer tous les outliers, mais de **comprendre leur origine et leur influence**.

Modèles généralement sensibles	Modèles généralement moins sensibles
Régression linéaire ; régression logistique ; KNN ; SVM ; k-means ; modèles utilisant des distances ou des erreurs quadratiques.	Arbres de décision ; Random Forest ; Gradient Boosting et modèles apparentés.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Détection visuelle

Histogramme

Permet d'observer la forme globale de la distribution.



Boxplot

Le boxplot repose sur les quartiles

Le boxplot repose sur les quartiles : Q1 (25e percentile), Q2 (médiane), Q3 (75e percentile) et IQR = Q3 − Q1. Les valeurs situées au-delà des bornes de Tukey sont considérées comme des outliers potentiels :$[\, Q_1 - 1{,}5 \cdot IQR \; ; \;\; Q_3 + 1{,}5 \cdot IQR \,]$



Chapitre 2: Prétraitement des données

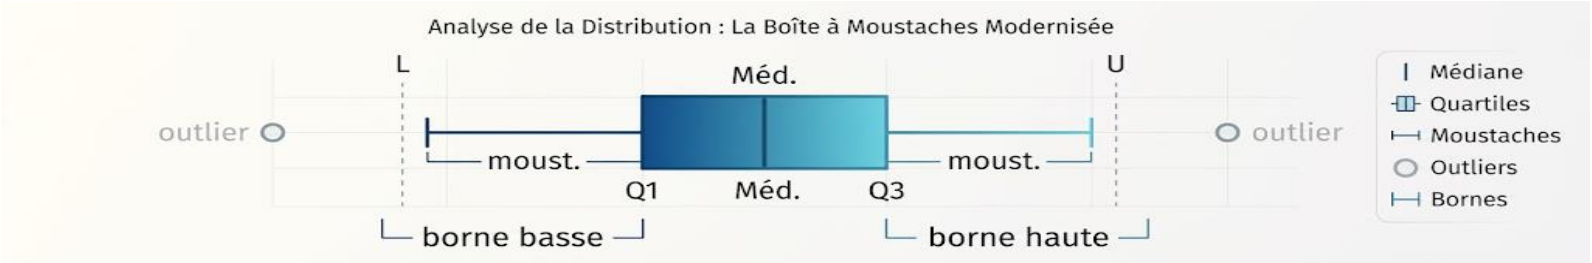
Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Détection par IQR



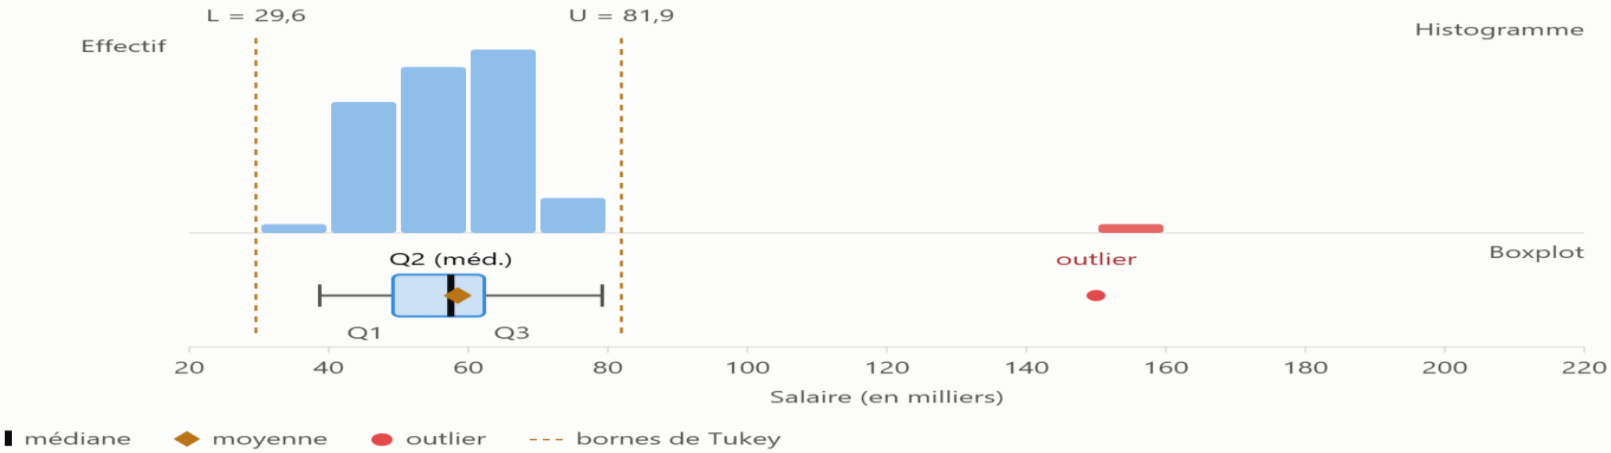
Médiane (Q_2) : La ligne située à l'intérieur de la boîte. Elle sépare le jeu de données en deux parties égales (50 % des observations sont au-dessus, 50 % en dessous).
1er Quartile (Q_1) : Le bord inférieur de la boîte. 25 % des données sont inférieures à cette valeur.
3ème Quartile (Q_3) : Le bord supérieur de la boîte. 75 % des données sont inférieures à cette valeur (donc 25 % sont supérieures).

→ **Écart Interquartile (IQR)** : La hauteur de la boîte, calculée par $IQR = Q_3 - Q_1$. Elle contient les **50 % centraux** des données.

→ **Bornes de Tukey :** L = Q1 − 1,5·IQR et U = Q3 + 1,5·IQR

→ ***Whiskers*** : Les lignes qui s'étendent au-dessus et en dessous de la boîte. Elles atteignent généralement la valeur minimale et maximale située dans la limite de $1{,}5 \times IQR$ à partir des quartiles (Données de la distribution).

→ ***Outliers***: Les points représentés au-delà des moustaches (données inférieures à $Q_1 - 1{,}5 \times IQR$ ou supérieures à $Q_3 + 1{,}5 \times IQR$).



Médiane	Moyenne	IQR (Q3 − Q1)	Bornes [L ; U]
57,5	**58,5**	**13,1**	**[29,6 ; 81,9]**

Le point 150 dépasse la borne haute U = 81,9 : le boxplot le dessine comme outlier potentiel, et la moyenne est tirée vers lui alors que la médiane reste stable.

Le boxplot repose sur les quartiles : Q1 (25e percentile), Q2 (médiane), Q3 (75e percentile) et IQR = Q3 − Q1. Les valeurs situées au-delà des bornes de Tukey sont considérées comme des outliers potentiels :$[\ Q_1 - 1{,}5 \cdot IQR\ ;\ \ Q_3 + 1{,}5 \cdot IQR\ ]$

Rangs	Valeurs
1 – 10	38,7 · 42,8 · 42,8 · 44,9 · 45,2 · 45,3 · 45,7 · 46,5 · 47,4 · 47,6
11 – 20	48,5 · 48,5 · 48,7 · 48,9 · 49,1 · **49,2** · 50,7 · 51,1 · 52,5 · 53,0
21 – 30	53,5 · 53,9 · 54,5 · 54,6 · 55,6 · 55,7 · 56,0 · 56,2 · 56,4 · 57,0
31 – 40	**57,5** · 58,7 · 58,8 · 59,1 · 59,8 · 60,1 · 60,5 · 60,8 · 60,9 · 61,1
41 – 50	61,4 · 61,5 · 61,8 · 61,9 · 62,3 · **62,3** · 62,7 · 63,0 · 64,0 · 64,3
51 – 60	64,6 · 65,4 · 65,6 · 66,4 · 67,4 · 67,8 · 70,6 · 70,9 · 77,1 · 79,2
61	**150,0** ← le point extrême

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

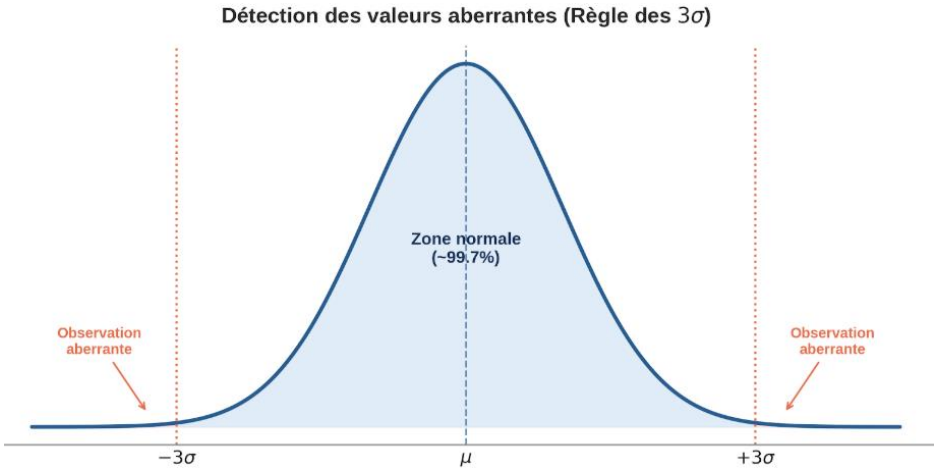
Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Détection statistique : Z-score

Le Z-score mesure la distance d'une observation à la moyenne : $z_i = \frac{(x_i - \mu)}{\sigma}$

Une règle courante considère comme suspectes les observations vérifiant : $|z_i| > 3$



Limite

Le Z-score dépend de la moyenne et de l'écart-type, **eux-mêmes sensibles** aux valeurs extrêmes : les outliers peuvent se masquer mutuellement.

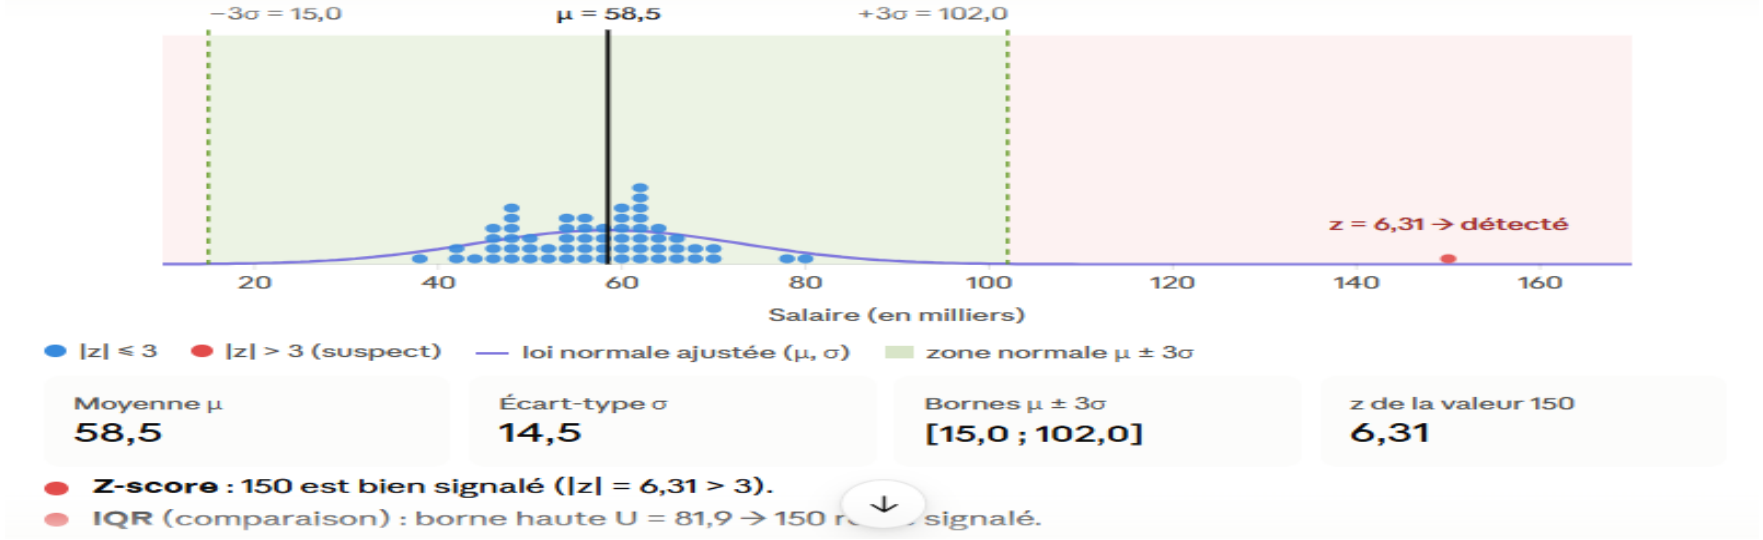
Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes



Rangs	Valeurs
1 – 10	38,7 · 42,8 · 42,8 · 44,9 · 45,2 · 45,3 · 45,7 · 46,5 · 47,4 · 47,6
11 – 20	48,5 · 48,5 · 48,7 · 48,9 · 49,1 · 49,2 · 50,7 · 51,1 · 52,5 · 53,0
21 – 30	53,5 · 53,9 · 54,5 · 54,6 · 55,6 · 55,7 · 56,0 · 56,2 · 56,4 · 57,0
31 – 40	57,5 · 58,7 · 58,8 · 59,1 · 59,8 · 60,1 · 60,5 · 60,8 · 60,9 · 61,1
41 – 50	61,4 · 61,5 · 61,8 · 61,9 · 62,3 · 62,3 · 62,7 · 63,0 · 64,0 · 64,3
51 – 60	64,6 · 65,4 · 65,6 · 66,4 · 67,4 · 67,8 · 70,6 · 70,9 · 77,1 · 79,2
61	**150,0** ← le point extrême

Moyenne μ	**58,49**
Écart-type σ	**14,51**
Bornes μ ± 3σ	**[14,97 ; 102,01]**
z de la valeur 150	(150 − 58,49) / 14,51 ≈ **6,31**
z de 38,7 (la plus petite valeur)	(38,7 − 58,49) / 14,51 ≈ −1,36
z de 79,2	(79,2 − 58,49) / 14,51 ≈ +1,43

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser

Au lieu de chercher ce qui est "normal", on cherche ce qu'il est facile d'isoler.

- **Découpage aléatoire** : Le réseau découpe les données au hasard.
- **Isolement rapide** : Une observation isolée rapidement est suspecte.

Point Normal vs Point Atypique

Critère	Point Normal (Inlier)	Point Atypique (Anomalie / Outlier)
Emplacement	Noyé au milieu du groupe	Isolé, éloigné des autres
Nombre de découpages	**Élevé** (ex : 10 découpages)	**Faible** (ex : 2-3 découpages)
Profondeur h(x)	**Grande**	**Faible**
Score d'anomalie s	$s \approx 0{,}5$ ou moins	$s \to 1$

$$s(x) = 2^{-E[h(x)] / c(n)}$$

h(x) : Profondeur (nombre de séparations nécessaires pour isoler le point x).
E(h(x)) : Profondeur moyenne de x observée dans tous les arbres de la forêt.
c(n) : Profondeur moyenne théorique pour un ensemble de n points (facteur de normalisation).

Chapitre 2: Prétraitement des données

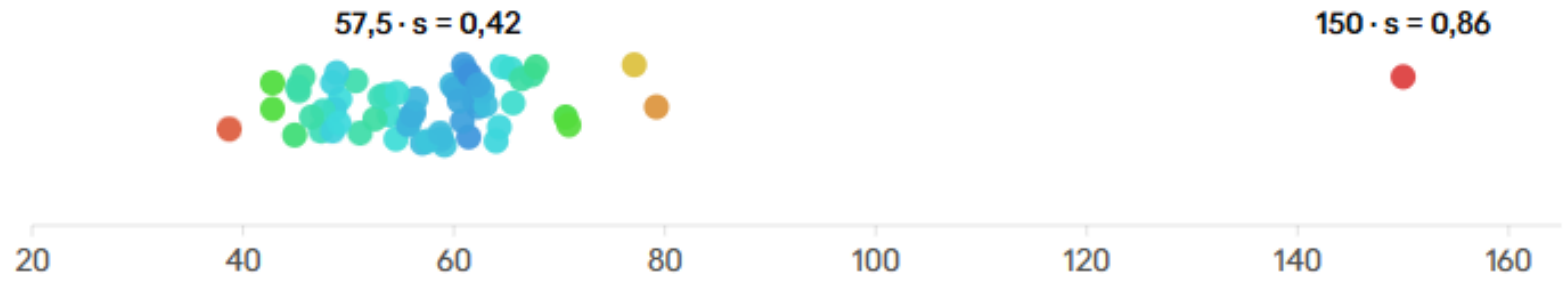
Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser



Rangs	Valeurs
1 – 10	38,7 · 42,8 · 42,8 · 44,9 · 45,2 · 45,3 · 45,7 · 46,5 · 47,4 · 47,6
11 – 20	48,5 · 48,5 · 48,7 · 48,9 · 49,1 · 49,2 · 50,7 · 51,1 · 52,5 · 53,0
21 – 30	53,5 · 53,9 · 54,5 · 54,6 · 55,6 · 55,7 · 56,0 · 56,2 · 56,4 · 57,0
31 – 40	57,5 · 58,7 · 58,8 · 59,1 · 59,8 · 60,1 · 60,5 · 60,8 · 60,9 · 61,1
41 – 50	61,4 · 61,5 · 61,8 · 61,9 · 62,3 · 62,3 · 62,7 · 63,0 · 64,0 · 64,3
51 – 60	64,6 · 65,4 · 65,6 · 66,4 · 67,4 · 67,8 · 70,6 · 70,9 · 77,1 · 79,2
61	**150,0** ← le point extrême

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser

Pour appliquer l'algorithme **Isolation Forest** avec **100 arbres** (t = 100) sur ce jeu de données de n = 61 observations (portant sur des valeurs comprises entre 38,7 et 150,0), voici la démarche étape par étape :

Étape 1 : Choisir la taille d'échantillon et la profondeur maximale

1.Taille d'échantillon (n) :Le jeu de données contient n = 61 observations (60 observations normales regroupées entre 38,7 et 79,2, et 1 valeur extrême à 150,0).

2.Profondeur maximale par arbre (h_{max}) : Elle est limitée par la hauteur théorique d'un arbre binaire :

$$h_{max} = \lceil \log_2(n) \rceil = \lceil \log_2(61) \rceil = 6$$

Étape 2 : Construire la forêt (100 arbres d'isolation)

Pour chacun des t = 100 arbres :

Sélectionner un sous-échantillon des données (ou utiliser l'ensemble des 61 points).

Découper récursivement l'intervalle :

Choisir aléatoirement une valeur de coupure v entre la valeur minimale $p_{\min}$ et la valeur maximale $p_{\max}$ courante.

Séparer les données en deux sous-groupes ($x < v$ et $x \geq v$).

Répéter jusqu'à ce que :

Le point soit complètement isolé, **ou** La profondeur maximale (h_{max}= 6) soit atteinte.

Remarque visuelle : Comme la valeur 150,0 est très éloignée de la plage principale (38,7 – 79,2), presque n'importe quelle coupure aléatoire entre 79,2 et 150,0 isolera le point 150,0 en **1 seul découpage** ($h \approx 1$ à 2).

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser



Arbre 1

1er découpage : Tirage au hasard de $v_1 = 110{,}0$ sur $[38{,}7\ ;\ 150{,}0]$.

Gauche (x < 110,0) : 60 points (38,7 à 79,2).

Droite ($x \geq 110{,}0$) : **150,0 → ISOLÉ immédiatement ! (Profondeur h = 1)**.

Découpages suivants pour le groupe de gauche :

$v_2 = 50{,}0$ → Gauche : 15 points, Droite : 45 points.

Le processus continue sur les sous-groupes jusqu'à isoler chaque point ou atteindre $h_{\max} = 6$.

Résultat pour 55,6 : Isolé à la profondeur **h = 5**.

Arbre 2

1er découpage : Tirage au hasard de $v_1 = 85{,}2$ sur $[38{,}7\ ;\ 150{,}0]$.

Gauche (x < 85,2) : 60 points (38,7 à 79,2).

Droite ($x \geq 85{,}2$) : **150,0 → ISOLÉ immédiatement ! (Profondeur h = 1)**.

2e découpage (sur le groupe de gauche) : Tirage de $v_2 = 60{,}0$ sur $[38{,}7\ ;\ 79{,}2]$.

Gauche (x < 60,0) : 38 points.

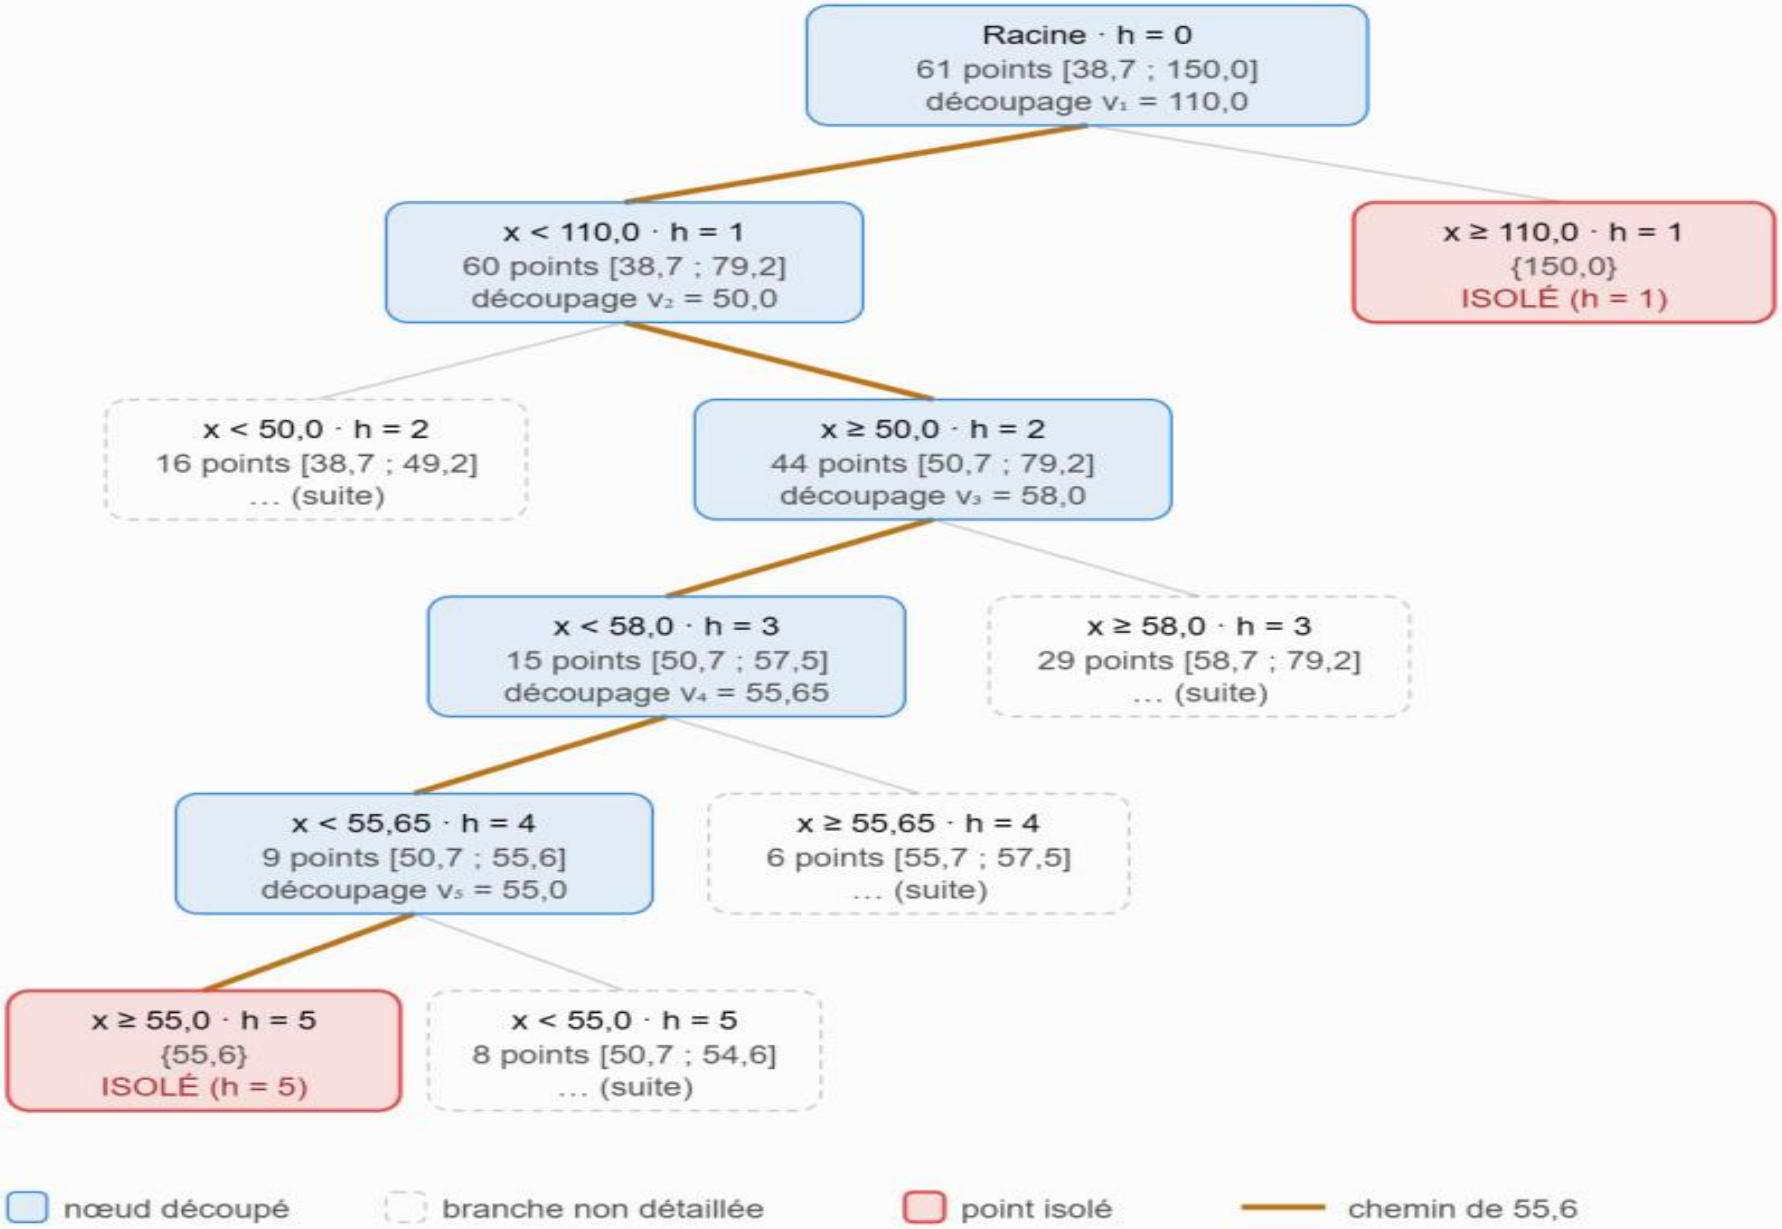
Droite ($x \geq 60{,}0$) : 22 points.

Résultat pour 55,6 : Isolé à la profondeur **h = 6** ($h_{\max}$ atteinte).

. . . .

. .

Arbre 100



$h_max = [\log_2 61] = 6$ · v_1 et v_2 viennent de l'énoncé ; v_3, v_4, v_5 sont choisis pour illustrer.
Profondeur h = nombre de découpages nécessaires pour isoler le point.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser

Étape 3 : Calculer la longueur moyenne du chemin E[h(x)]

Une fois les 100 arbres générés, on fait passer chaque donnée x à travers les 100 arbres pour mesurer sa profondeur $h_{i(x)}$:

Pour chaque arbre $i \in \{1, \dots, 100\}$, relever la profondeur $h_i(x)$ atteinte par le point.

Calculer la **profondeur moyenne** sur la forêt :

$$E[h(x)] = \frac{1}{100}\sum_{i=1}^{100} h_i(x)$$

Pour calculer la longueur du chemin $h_i(x)$d'une observation x dans un arbre donné i, la formule dépend du cas dans lequel se trouve la feuille où atterrit le point x.

$h_i(x)$= e + c(m)

Où :

e est le **nombre d'arêtes traversées** (la profondeur atteinte dans l'arbre depuis la racine).

m est la **taille du sous-groupe (nombre de points)** restants dans la feuille finale où se trouve x.

c(m) est l'estimation de la longueur moyenne restante.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser

Étape 4 : Normaliser avec la constante c(n)

La longueur moyenne théorique d'une recherche infructueuse dans un arbre binaire de recherche (BST) pour n = 61 points est calculée par :

$$c(n) = 2\ln(n-1) + 0{,}5772156649 - 2\frac{n-1}{n}$$

Pour n = 61 :

$$c(61) \approx 2\ln(60) + 0{,}5772 - 2\frac{60}{61} \approx 8{,}188 + 0{,}577 - 1{,}967 \approx 6{,}80$$

(Si l'on tient compte de l'approximation logarithmique stricte, $c(61) \approx 7{,}38$).

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Isolation Forest: isoler plutôt que modéliser

Étape 5 : Calculer le score d'anomalie s(x)

Pour chaque point x, évaluer son score grâce à la formule :

$$s(x) = 2^{-\frac{\mathrm{E[h(x)]}}{c(n)}}$$

Application aux données du tableau :

Pour le point extrême (x = 150,0) :

En moyenne sur les 100 arbres, sa profondeur est très faible : $E[h(150{,}0)] \approx 1{,}4$.

Score :

$$s(150{,}0) = 2^{-\frac{1{,}4}{7{,}38}} = 2^{-0{,}19} \approx 0{,}88$$

Verdict : Le score est proche de 1, confirmant que **150,0 est une anomalie majeure**.

Pour un point normal (ex : x = 55,6) :

Le point se trouvant au milieu d'un groupe dense, il nécessite beaucoup de découpages pour être isolé : $E[h(55{,}6)] \approx 9{,}2$.

Score :

$$s(55{,}6) = 2^{-\frac{9{,}2}{7{,}38}} = 2^{-1{,}25} \approx 0{,}42$$

Verdict : Le score est nettement inférieur à 0,5, confirmant qu'il s'agit d'une **observation normale**.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Comparaison des trois méthodes

Méthode	Nature	Avantage	Limite
Z-score	Univariée	Simple et rapide	Sensible aux outliers
IQR	Univariée	Robuste	Ne considère pas directement les relations multivariées
Isolation Forest	Multivariée	Détecte des combinaisons atypiques	Paramétrage et interprétation plus complexes

À retenir

Les méthodes ne répondent pas exactement à la même question. Il est donc possible qu'elles **ne détectent pas les mêmes observations**

Chapitre 2: Prétraitement des données

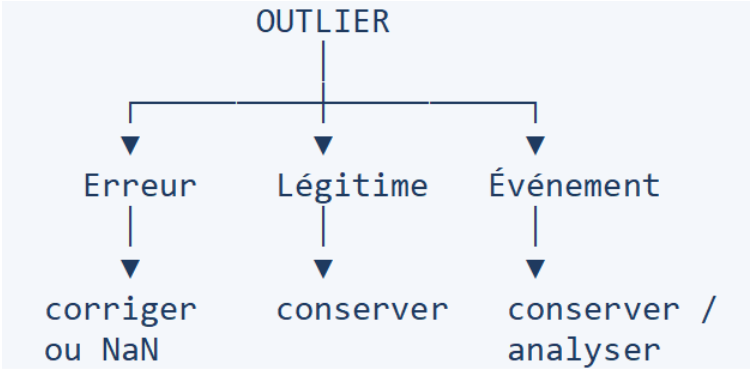
Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

2.1 — Valeurs manquantes et valeurs aberrantes

Que faire d'un outlier ?



→**La détection n'est pas la décision.** Avant toute suppression, il faut déterminer la nature de l'outlier :

→**Conserver** Si l'observation est réelle et pertinente.

→**Corriger** Si l'erreur est identifiable : mauvaise unité, erreur de saisie, mesure impossible.

→**Remplacer par NaN puis imputer** Lorsque la valeur est clairement invalide mais qu'une correction exacte n'est pas possible.

→**Supprimer** Seulement lorsque l'observation est clairement erronée et non récupérable, ou lorsque sa suppression est méthodologiquement justifiée.

→**Capping / Winsorisation** Limiter une valeur à une borne définie : $x' = min(max(x, L), U)$ Cela conserve l'observation mais réduit son influence.

→**Transformation logarithmique** Pour une variable positive fortement asymétrique : $x' = log(1 + x)$ La transformation comprime les grandes valeurs.

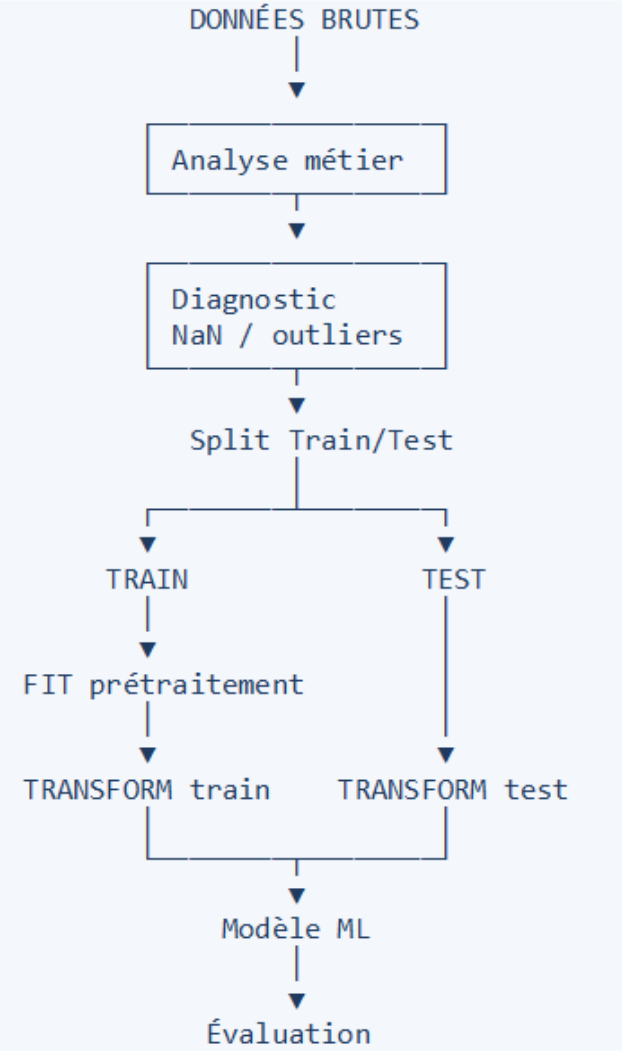
Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Pipeline académique recommandé



Erreurs méthodologiques fréquentes

1 — Imputer avant le split Cela peut créer une fuite d'information.

2 — Utiliser systématiquement la moyenne La moyenne est sensible aux distributions asymétriques et aux valeurs extrêmes.

3 — Supprimer toutes les lignes incomplètes La perte de données peut être importante et non aléatoire.

4 — Appliquer KNN sans considérer l'échelle Les distances peuvent être dominées par les variables de grande amplitude.

5 — Supprimer automatiquement les outliers Un outlier peut être une observation réelle ou précisément la classe d'intérêt.

6 — Choisir un seuil sans justification Les seuils 3σ, 1,5·IQR ou la contamination d'Isolation Forest sont des choix méthodologiques, pas des vérités universelles.

7 — Ne pas documenter les décisions

Un projet reproductible doit indiquer :

la méthode utilisée ;

les paramètres ;

le nombre d'observations affectées ;

la justification du choix.

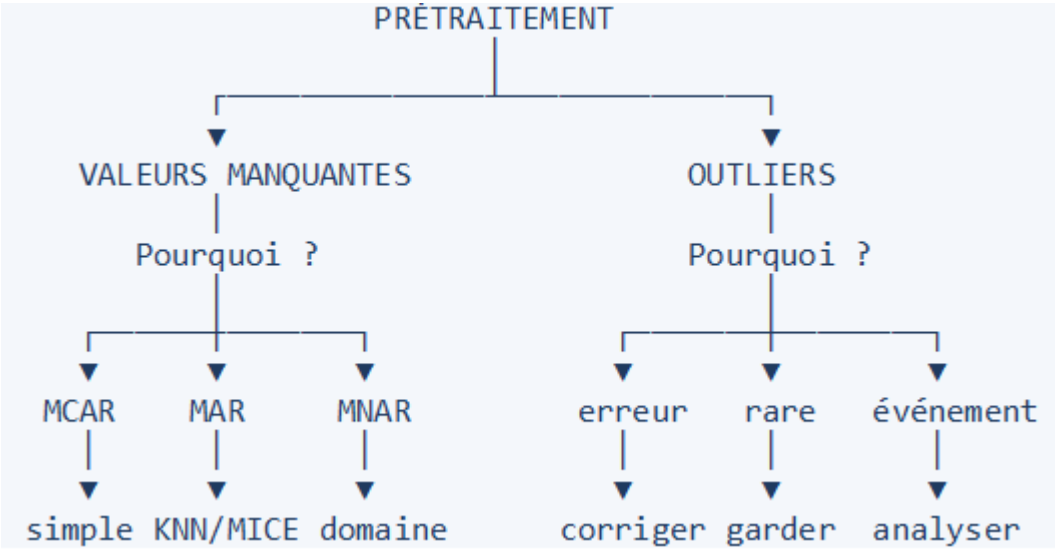
Chapitre 2: Prétraitement des données

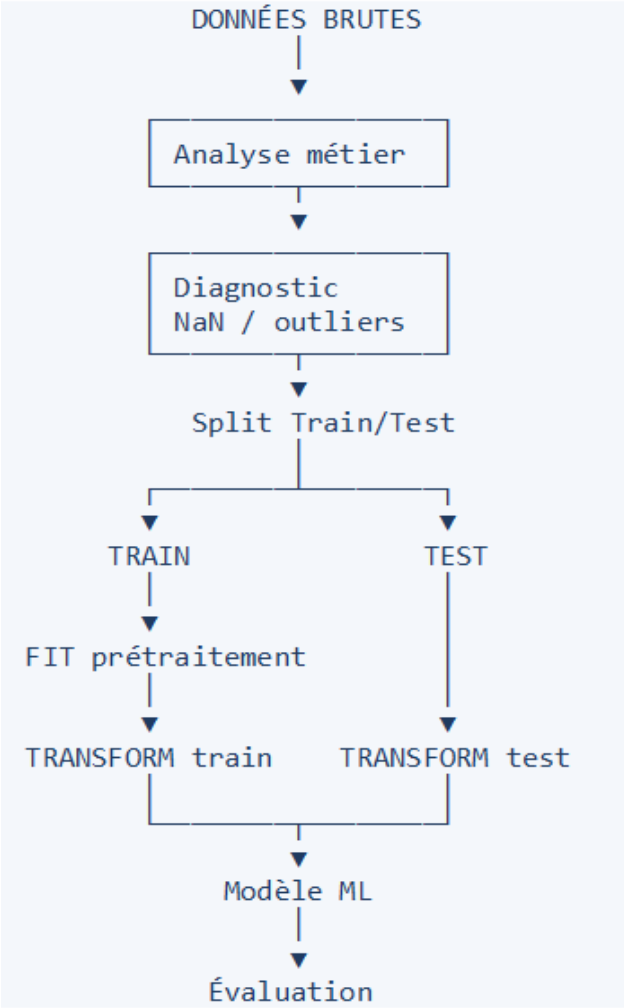
Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Synthèse conceptuelle





Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Problème des jeux de données déséquilibrés (Imbalanced Datasets)

Un modèle peut avoir 99,5 % d'exactitude… sans rien détecter

99,5 %

d'exactitude pour le modèle « tout est normal »

0 / 50

fraudes détectées sur 10 000 transactions



Transactions normales : 99,5 % · Fraudes : 0,5 % (la classe rare, seule vraiment utile)

Problème des jeux de données déséquilibrés (Imbalanced Datasets)

Mesurer autrement : au-delà de l'exactitude (Accuracy)

Métrique	Formule	Lecture
Exactitude	(TP + TN) / total	Trompeuse si classes déséquilibrées
Précision	TP / (TP + FP)	Parmi les alertes, combien sont justes ?
Rappel	TP / (TP + FN)	Parmi les positifs, combien détectés ?
F1	2·P·R / (P + R)	Compromis précision–rappel
AUPRC	Aire sous la courbe P–R	Robuste au déséquilibre

Notre exemple : TP = 0, donc rappel = 0 %, alors que l'exactitude vaut 99,5 %.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Trois leviers pour corriger le déséquilibre

Les données

- Sous-échantillonnage
- Sur-échantillonnage
- SMOTE (points synthétiques)

L'algorithme

- Poids de classes (class_weight)
- Perte pondérée, focal loss
- Ensembles équilibrés

La décision

- Seuil de décision ajusté
- Calibration des probabilités
- Coût des erreurs : FN ≠ FP

Aucune méthode universelle : on compare les options sur une validation adaptée.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Rééchantillonnage : principe, avantage, limite

Méthode	Principe	Avantage	Limite
Sous-échantillonnage	Retirer des exemples majoritaires	Rapide, jeu plus petit	Perte d'information
Sur-échantillonnage	Dupliquer des exemples minoritaires	Aucune donnée perdue	Risque de sur-apprentissage
SMOTE	Créer des points synthétiques entre voisins minoritaires	Diversifie la classe rare	Sensible au bruit et aux outliers

À appliquer uniquement sur l'ensemble d'entraînement.

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Rééquilibrer avant le split

Faux

1. SMOTE sur tout le jeu
2. Découpage train / test
3. Des points synthétiques proches du test se retrouvent dans l'entraînement : **fuite de données**, scores gonflés

Juste

1. Découpage stratifié
2. Rééquilibrage du **train seul**
3. Évaluation sur un test **intact**, avec le déséquilibre réel

En validation croisée, le rééchantillonnage reste à l'intérieur de chaque pli (pipeline imblearn).

Chapitre 2: Prétraitement des données

Gestion des valeurs manquantes et outliers

Normalisation, discrétisation, encodage

Problème des jeux de données déséquilibrés (Imbalanced Datasets).

Synthèse

In a survey, younger respondents are less likely to report their salary, while age is fully observed. Which missing-data mechanism does this describe?

a. MCAR (Missing Completely At Random)
b. MNAR (Missing Not At Random)
c. Missing by design
d. MAR (Missing At Random)

Why is the IQR rule generally more robust than the Z-score rule for detecting outliers?

a. It can only be applied to categorical variables.
b. It assumes that the data are uniformly distributed.
c. It always flags fewer observations than the Z-score.
d. It relies on quartiles, which are barely affected by extreme values, unlike the mean and standard deviation.

A dataset contains age (20–60) and salary (30,000–120,000). Why should the features be scaled before applying KNN or an SVM?

a. Scaling converts categorical variables into numeric ones.
b. Scaling automatically removes missing values.
c. Distance-based algorithms would be dominated by the feature with the largest numeric range (salary).
d. Scaling is mandatory for decision trees to work.