الجزائريـــــــة الديمقراطيـــــة الشعبيـــة
وزارة التعليـــــم العـــــالي و البحـــــث العلـــمي
جامعة وهران للعلوم والتكنولوجيا محمد بوضياف
كلية الريـــاضيـــات و الإعـــلام الآلـــي
République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur Et de la Recherche Scientifique
Université des Sciences et de la Technologie d'Oran Mohamed BOUDIAF
Faculté des Mathématiques et Informatique
Département D'Informatique

Machine Learning Course

By Dr. Asmaa Ourdighi

Lecture 3

Chapitre 3: Régression

1. Régression linéaire (simple et multiple)
2. Regularisation (Ridge, Lasso)

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Introduction

La **régression** est une famille de méthodes d'apprentissage supervisé qui modélise la relation entre une variable cible **quantitative** et une ou plusieurs variables explicatives. Contrairement à la classification, où la cible appartient à un ensemble de catégories, la régression prédit une **valeur numérique continue**.

Exemples d'applications

→ prix d'une maison à partir de sa surface
→ consommation énergétique d'un bâtiment
→ salaire à partir de caractéristiques professionnelles
→ température à partir de variables météorologiques
→ ventes d'un produit
→ variable biologique ou médicale.
→ . .

On cherche à apprendre une fonction :

$$f : R^p \rightarrow R$$

$$\hat{y} = f(x_1, x_2, \dots, x_p)$$

où y est la valeur réelle de la cible, ŷ la valeur prédite, $x^1, \dots, x_p$ les variables explicatives et p leur nombre. Un jeu de données comporte n observations : $D = \{(x^i, y^i)\}, i = 1, \dots, n.$

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Le terme **linéaire** signifie que la prédiction est une combinaison linéaire des variables explicatives. Pour décrire correctement ce que le modèle suppose, on ne se contente pas d'une fonction : on écrit un **modèle probabiliste**, où la cible est la somme d'une partie systématique et d'une erreur aléatoire :

$$y_i = \beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip} + \varepsilon_i$$

forme matricielle : $y = X\beta + \varepsilon$

Le terme $\boldsymbol{\varepsilon_i}$ (l'erreur, ou le bruit) regroupe tout ce que les variables explicatives n'expliquent pas : variables omises, erreurs de mesure, variabilité propre du phénomène. Les paramètres β sont **inconnus** : on les estime à partir des données. Les estimations sont notées avec un chapeau ($\hat{\beta}$).

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Comprendre le modèle statistique

1. Le modèle combine une partie expliquée et une partie inexpliquée.

$$y_i = \beta_0 + \beta_1 x_{i1} + \ldots + \beta_p x_{ip} + \varepsilon_i$$

Partie expliquée par le modèle

$$\hat{y}_i = \widehat{\beta_0} + \widehat{\beta_1} x_{i1} + \ldots + \widehat{\beta_p} x_{ip}$$

C'est la prédiction calculée à partir des variables d'entrée.

Partie non expliquée

$$\varepsilon_i = y_i - \hat{y}_i$$

Elle représente les facteurs non pris en compte, les erreurs de mesure et la variabilité du phénomène. En pratique, on observe le résidu $e_i = y_i - \hat{y}_i$, qui sert à l'estimer.

Exemple : prédire le prix d'un logement

x_1: surface du logement.

x_2 : nombre de chambres.

y : prix réellement observé.

$\hat{y}$: prix prédit par le modèle.

Si le prix réel est de 12 millions DA et le prix prédit de 11 millions DA, le résidu vaut +1 million DA.

À retenir : les coefficients β sont inconnus ; l'apprentissage consiste à en calculer des estimations $\hat{\beta}$ à partir des données.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Quelles hypothèses faut-il comprendre ?

Les hypothèses décrivent les conditions dans lesquelles le modèle et ses estimations peuvent être interprétés correctement.

→ H1. Linéarité	La relation moyenne est représentable par une combinaison linéaire des variables.
→ H2. Exogénéité	Les erreurs ne sont pas systématiquement liées aux variables explicatives.
→ H3. Variance constante	La dispersion des erreurs reste approximativement stable.
→ H4. Indépendance	Les erreurs ne présentent pas de dépendance systématique entre observations.
→ H5. Rang plein	Les variables explicatives ne sont pas des combinaisons exactes les unes des autres.
→ H6. Normalité	Les erreurs suivent approximativement une loi normale. Cette hypothèse est surtout utile pour certains tests et intervalles de confiance, et non une condition générale pour faire des prédictions.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Quelles hypothèses faut-il comprendre ?

H1 — La linéarité : est-ce qu'une droite convient ?

Imaginez que, globalement, plus la surface augmente, plus le prix augmente de façon approximativement régulière.

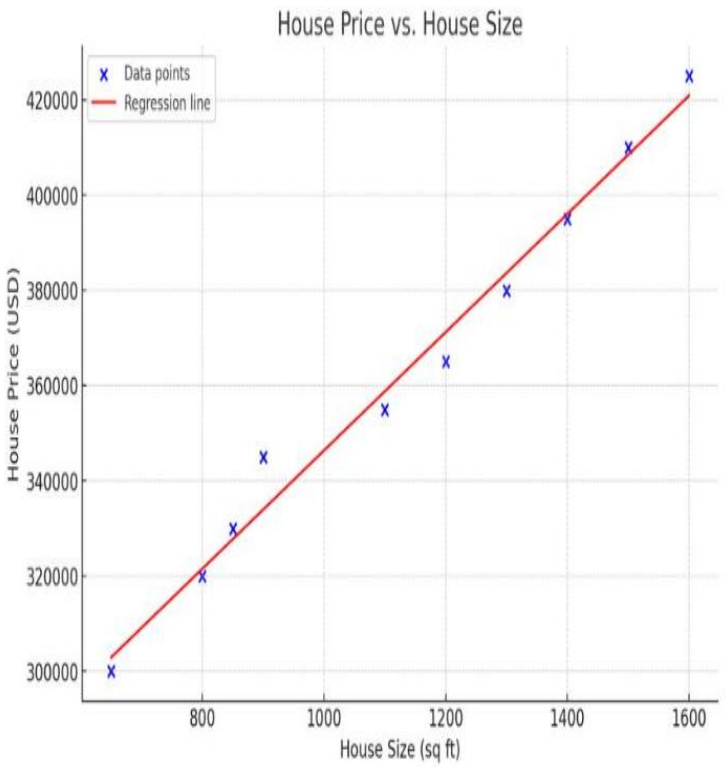
Le modèle peut apprendre une relation comme :

$$Prix = 2 + 0{,}1 \times Surface$$

(Prix en millions de DA, surface en m² ; exemple fictif.)

Pour 50 m² : prix prédit = 7 millions DA.

Pour 80 m² : prix prédit = 10 millions DA.



Que signifie l'hypothèse ?

On suppose que la relation moyenne entre la surface et le prix **peut être représentée par cette forme linéaire**.

Si, au contraire, le prix augmente très rapidement au-delà d'une certaine surface, une simple droite risque de mal représenter la relation.

Le modèle doit avoir une forme adaptée au phénomène étudié.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Quelles hypothèses faut-il comprendre ?

H2 — L'exogénéité : manque-t-il une information importante ?

Imaginons deux logements de même surface :

- Logement A : situé dans un quartier ordinaire.
- Logement B : situé dans un quartier très recherché.

Leurs prix peuvent être différents, même si leurs surfaces sont identiques.
Si notre modèle utilise uniquement la surface, il ignore l'effet du quartier.

Mais attention : omettre une variable ne crée pas automatiquement un biais. Le problème apparaît notamment lorsque le facteur omis influence le prix et est lié à la surface.

Si l'on veut interpréter correctement les coefficients, il faut se demander si des facteurs importants oubliés faussent les relations apprises.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

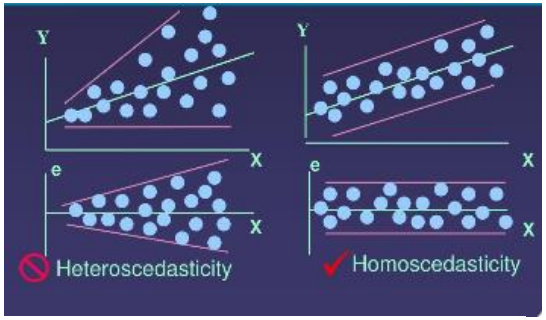
Quelles hypothèses faut-il comprendre ?

H3 — L'homoscédasticité : les erreurs sont-elles aussi dispersées ?

Supposons que le modèle fasse des prédictions pour de petits et de grands logements

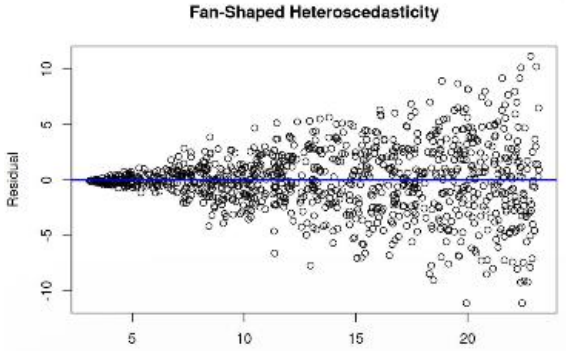
Cas A : dispersion stable

Les erreurs restent approximativement de même ampleur, quelle que soit la surface.



Cas B : dispersion croissante

Les erreurs sont petites pour les logements de petite surface, mais beaucoup plus dispersées pour les grands logements.



L'hypothèse H3 correspond au premier cas : **la variance des erreurs reste constante**.

Cette hypothèse concerne surtout la fiabilité des calculs d'incertitude et des tests statistiques. Sa violation ne signifie pas nécessairement que les prédictions sont mauvaises.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Quelles hypothèses faut-il comprendre ?

H4 — L'indépendance : les erreurs sont-elles liées entre elles ?

Imaginons que vous prédisiez le prix moyen des logements chaque mois.

Si le modèle sous-estime les prix en janvier, il pourrait aussi les sous-estimer en février, car une tendance du marché n'a pas été prise en compte.

Les erreurs de deux mois successifs sont alors liées.

L'hypothèse d'indépendance signifie que les erreurs ne présentent pas ce type de dépendance systématique.

Cette hypothèse est particulièrement importante pour les séries temporelles. Pour des observations ordinaires, elle dépend aussi de la manière dont les données ont été collectées.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Quelles hypothèses faut-il comprendre ?

H5 — Le rang plein : les variables donnent-elles des informations distinctes ?

Supposons que le modèle reçoive deux colonnes :
Les deux colonnes représentent exactement la même information : la deuxième est toujours égale à la première multipliée par 10 000.
Le modèle ne peut pas déterminer séparément l'effet de chacune de ces deux variables : elles sont parfaitement redondantes.

Surface en m^2	Surface en cm^2
50	500 000
80	800 000
100	1 000 000

Les variables explicatives ne doivent pas être des combinaisons linéaires exactes les unes des autres si l'on veut estimer leurs coefficients de manière unique par la méthode classique des moindres carrés.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Quelles hypothèses faut-il comprendre ?

H6 — La normalité : les erreurs suivent-elles une forme particulière ?

Après les prédictions, on examine les erreurs. On suppose, dans le modèle statistique classique, qu'elles suivent approximativement une distribution en forme de cloche, appelée loi normale.

Cela ne signifie pas que les prix des logements eux-mêmes doivent suivre une loi normale. C'est l'hypothèse sur les erreurs du modèle.

La normalité est surtout utile pour certains tests statistiques et intervalles de confiance, notamment dans les petits échantillons. Elle n'est pas nécessaire pour entraîner une régression par moindres carrés.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Que faut-il vérifier en Machine Learning ?

Le niveau d'exigence dépend de l'objectif.

Objectif 1: Prédire

Exemple : prévoir le prix d'un logement jamais présenté au modèle.

→ Priorité : évaluer les erreurs sur des données de test indépendantes de l'apprentissage et vérifier la capacité de généralisation.

Hypothèses à examiner : H1 et H5, pour vérifier que le modèle est adapté et que ses coefficients peuvent être estimés de manière unique.

À noter : H2, H3, H4 et H6 ne sont pas toutes indispensables pour obtenir de bonnes prédictions.

Modèle statistique

Que faut-il vérifier en Machine Learning ?

Objectif 2: Interpréter

Exemple : comprendre l'association entre la surface et le prix, toutes les autres variables incluses étant maintenues constantes.

→ Priorité : vérifier la spécification du modèle et les variables omises susceptibles de fausser les coefficients. Une interprétation causale demande des conditions supplémentaires.

Hypothèses principales : H1, H2 et H5.

H1 : relation moyenne correctement spécifiée.
H2 : absence de lien systématique entre les variables explicatives et l'erreur.
H5 : absence de multicolinéarité parfaite.

À noter : une interprétation causale nécessite des conditions supplémentaires.
Un modèle de régression peut identifier des associations utiles pour prédire, mais il ne démontre pas automatiquement des relations de cause à effet.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Que faut-il vérifier en Machine Learning ?

Objectif 3: Tirer des conclusions statistiques

Exemple : déterminer si l'association observée est statistiquement significative. Par exemple, tester si le coefficient associé à la surface est statistiquement différent de zéro.

→ Priorité : examiner les hypothèses nécessaires à la validité des tests, des écarts-types et des intervalles de confiance.

→ **Hypothèses classiques : H1, H2, H3, H4, H5 et H6**, selon le cadre statistique considéré.H1, H2 et H5 : modèle correctement spécifié, exogénéité et coefficients identifiables.H3 et H4 : conditions usuelles pour calculer des écarts-types et réaliser des tests fiables. H6 : normalité des erreurs, notamment utile pour les tests exacts dans les petits échantillons.

Les hypothèses n'ont pas toutes le même rôle. En Machine Learning, la généralisation est prioritaire ; en statistique inférentielle, la validité des tests et des intervalles de confiance est essentielle.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Modèle statistique

Une hypothèse violée n'a pas toujours la même conséquence : elle peut affecter la qualité des prédictions, l'estimation des coefficients ou la fiabilité des conclusions statistiques.

Les hypothèses de la régression linéaire ne sont pas toutes nécessairement vraies dans les données réelles. Ce sont des conditions que l'on suppose, que l'on vérifie autant que possible ou dont on évalue les conséquences.

La distinction essentielle à retenir

En Machine Learning : on cherche principalement à prédire correctement de nouvelles observations. On évalue donc la généralisation du modèle.

En statistique : on cherche souvent à interpréter les coefficients, tester des hypothèses ou construire des intervalles de confiance. Les hypothèses deviennent alors plus importantes.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

1- Régression linéaire simple

La régression simple utilise **une seule variable explicative** x :

$\hat{y} = \beta_0 + \beta_1 x$

β_0 est l'**ordonnée à l'origine** (valeur prédite pour x = 0) et β_1 la **pente** : variation moyenne prédite de y quand x augmente d'une unité.

Avec $\hat{y} = 20 + 3x$, la prédiction vaut 20 pour x = 0 et augmente de 3 par unité de x.

Attention : β_0 n'a de sens concret que si x = 0 appartient au domaine observé.

Exemple: prix d'une maison

Surface x (m²)	50	70	90	110	130
Prix y (k€)	120	150	180	210	240



Ces cinq points sont parfaitement alignés : la droite passe par tous ($\hat{\beta}_1 = 30/20 = 1{,}5$ k€ par m², $\hat{\beta}_0 = 45$). C'est un **cas d'école** : tous les résidus sont nuls et $R^2 = 1$. Dans la réalité, les points ne sont jamais alignés ; l'objectif n'est **pas** de passer par tous les points, mais de trouver la droite qui minimise globalement l'écart entre valeurs observées et prédites.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

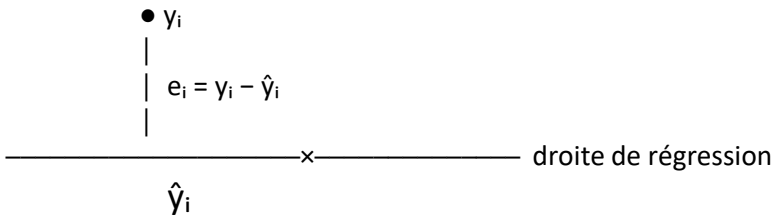
1- Régression linéaire simple

Résidus

Pour chaque observation, l'écart entre la valeur réelle et la valeur prédite est le **résidu** :

$e_i = y_i - \hat{y}_i$

Ne pas confondre le résidu e_i (calculé sur l'échantillon) avec l'erreur ε_i(inobservable, définie dans le modèle). Un résidu positif signifie que le modèle **sous-estime** la valeur, un résidu négatif qu'il la **surestime**.



Exemple : si la vraie relation est **y = 2 + 3x** et que, pour x = 1, on observe y = 6, **l'erreur vaut ε = 6 − 5 = 1**. Mais si votre droite estimée est **ŷ = 2,4 + 2,8x**, la prédiction est 5,2 et **le résidu vaut e = 0,8**. Vous ne connaissez en pratique que ce second chiffre.

	Erreur ε_i	Résidu e_i
Référence	Vraie droite (β_0, β_1)	Droite estimée (b_0, b_1)
Nature	Variable aléatoire du modèle	Valeur calculée sur l'échantillon
Observable ?	Non	Oui
Propriétés	Hypothèses ($E(\varepsilon_i)=0$, $Var=\sigma^2$)	$\Sigma e_i = 0$ par construction (avec constante)

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire simple

Estimation par moindres carrés ordinaires (OLS)

Critère

Comment déterminer β_0 et β_1 ? La méthode des **moindres carrés ordinaires** (*Ordinary Least Squares*) minimise la somme des carrés des résidus (RSS ou SSE) :

→ $J(\beta_0, \beta_1) = \Sigma_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$

→ $(\hat{\beta_0}, \hat{\beta_1}) = argmin\ J(\beta_0, \beta_1)$

Pourquoi le carré ?

→ il évite que erreurs positives et négatives **s'annulent** ;

→ il **pénalise davantage les grandes erreurs** (ce qui rend la méthode **sensible aux outliers**) ;

→ J est **dérivable et convexe** : le minimum se calcule analytiquement ;

→ il correspond au **maximum de vraisemblance** si les erreurs sont gaussiennes.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire simple

Établir la solution (régression simple)

On annule les dérivées partielles de J :

$$\partial J/\partial \beta_0 = -2 \Sigma (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\partial J/\partial \beta_1 = -2 \Sigma x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

La première équation donne $\boldsymbol{\Sigma\, e_i = 0}$: les résidus sont de somme nulle, et la droite passe par le point moyen ($\bar{x}$, $\bar{y}$). En la résolvant :

$$\hat{\beta}_1 = \Sigma (x_i - \bar{x})(y_i - \bar{y}) \;/\; \Sigma (x_i - \bar{x})^2$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Liens avec la corrélation

$$\hat{\beta}_1 = r \cdot (s_y / s_x)$$

$$R^2 = r^2 \quad \textit{(en régression simple)}$$

où r est le coefficient de corrélation de Pearson entre x et y, s_x et s_y leurs écarts-types. La pente est donc la corrélation « convertie » dans les unités de y par unité de x.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire simple

Exemple chiffré avec bruit

Six observations, cette fois **non alignées** ($\bar{x} = 21/6 = 3{,}5$; $\bar{y} = 42{,}4/6 \approx 7{,}067$; $\Sigma(x_i - \bar{x})(y_i - \bar{y}) = 34$; $\Sigma(x_i - \bar{x})^2 = 17{,}5$) :

$$\hat{\beta}_1 = 34 / 17{,}5 \approx 1{,}943$$

$$\hat{\beta}_0 = 7{,}067 - 1{,}943 \times 3{,}5 \approx 0{,}267$$

$$\hat{y} = 0{,}267 + 1{,}943\, x$$

x	y	$\hat{y}$	$e = y - \hat{y}$	e^2
1	2,3	2,210	+0,090	0,008
2	3,9	4,152	−0,252	0,064
3	6,4	6,095	+0,305	0,093
4	7,7	8,038	−0,338	0,114
5	10,3	9,981	+0,319	0,102
6	11,8	11,924	−0,124	0,015

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire simple

Exemple chiffré avec bruit

Les résidus sont de somme nulle. On en déduit :

→ **RSS ≈ 0,396**,
→ **MSE = RSS/n ≈ 0,066**,
→ **RMSE ≈ 0,257**,
→ **MAE ≈ 0,238**,
→ **$R^2 = 1 - 0{,}396/66{,}453 \approx 0{,}994$**.

Prédiction pour x = 7 : $\hat{y} \approx 13{,}87$ (une extrapolation, car x = 7 sort du domaine observé 1 à 6).

x	y	$\hat{y}$	$e = y - \hat{y}$	e^2
1	2,3	2,210	+0,090	0,008
2	3,9	4,152	−0,252	0,064
3	6,4	6,095	+0,305	0,093
4	7,7	8,038	−0,338	0,114
5	10,3	9,981	+0,319	0,102
6	11,8	11,924	−0,124	0,015

RSS (*Residual Sum of Squares*, somme des carrés des résidus)

$$RSS = \Sigma e_i^2 = \Sigma (y_i - \hat{y}_i)^2$$

C'est la quantité que la méthode des moindres carrés minimise. Plus elle est petite, mieux la droite colle aux données. Ici : RSS ≈ 0,396.

MSE (*Mean Squared Error*, erreur quadratique moyenne)

$$MSE = RSS / n$$

C'est la moyenne des carrés des résidus. Ici : 0,396 / 6 ≈ 0,066 (donc n = 6 observations). Son unité est celle de y **au carré**, ce qui la rend peu intuitive.

RMSE (*Root Mean Squared Error*)

$$RMSE = \sqrt{MSE}$$

La racine carrée remet l'erreur dans l'**unité de y**. Ici : √0,066 ≈ 0,257. On peut dire qu'en moyenne, la prédiction s'écarte d'environ 0,26 unité de la valeur réelle. Le RMSE pénalise davantage les gros écarts (à cause du carré).

MAE (*Mean Absolute Error*, erreur absolue moyenne)

$$MAE = (1/n) \Sigma |e_i|$$

C'est la moyenne des écarts en valeur absolue. Ici : ≈ 0,238. Elle est dans l'unité de y et moins sensible aux valeurs extrêmes que le RMSE. On a toujours MAE ≤ RMSE, et un grand écart entre les deux signale la présence de quelques gros résidus.

R^2 (coefficient de détermination)

$$R^2 = 1 - RSS / TSS, \text{ avec } TSS = \Sigma (y_i - \bar{y})^2$$

1. Estimation de la droite $\hat{y} = b_0 + b_1 x$

x	y	$x - \bar{x}$	$(x - \bar{x})^2$	$(x - \bar{x})(y - \bar{y})$
1	2,3	−2,5	6,25	11,9167
2	3,9	−1,5	2,25	4,7500
3	6,4	−0,5	0,25	0,3333
4	7,7	0,5	0,25	0,3167
5	10,3	1,5	2,25	4,8500
6	11,8	2,5	6,25	11,8333
21	**42,4**	**0**	**17,5**	**34,0**

$b_1 = Sxy / Sxx$

34 / 17,5

≈ 1,9429

$b_0 = \bar{y} - b_1\bar{x}$

7,0667 − 1,9429×3,5

≈ 0,2667

$\bar{x} = 21/6 = 3,5$ $\bar{y} = 42,4/6 \approx 7,0667$

Droite estimée : $\hat{y} = 0,2667 + 1,9429\ x$

2. Valeurs prédites et résidus

x	y	ŷ	e = y – ŷ	e²
1	2,3	2,210	+0,090	0,008
2	3,9	4,152	–0,252	0,064
3	6,4	6,095	+0,305	0,093
4	7,7	8,038	–0,338	0,114
5	10,3	9,981	+0,319	0,102
6	11,8	11,924	–0,124	0,015
Σ			**0**	**0,396**

ŷ = 0,2667 + 1,9429 x (ex. x = 1 : ŷ = 2,210)



3. Indicateurs d'erreur

RSS **≈ 0,396**

$\Sigma e_i^2 = 0{,}008+0{,}064+0{,}093+0{,}114+0{,}102+0{,}015$

MSE **≈ 0,066**

RSS / n = 0,396 / 6

RMSE **≈ 0,257**

√MSE = √0,066 (même unité que y)

MAE **≈ 0,238**

$\Sigma|e_i| / n = 1{,}429 / 6$

4. Coefficient de détermination R^2

y	$y - \bar{y}$	$(y - \bar{y})^2$
2,3	−4,7667	22,7211
3,9	−3,1667	10,0278
6,4	−0,6667	0,4444
7,7	0,6333	0,4011
10,3	3,2333	10,4544
11,8	4,7333	22,4044
	0	**66,453**

$\bar{y} \approx 7{,}0667 \rightarrow TSS = \Sigma(y_i - \bar{y})^2 \approx 66{,}453$

$R^2 = 1 - RSS / TSS$

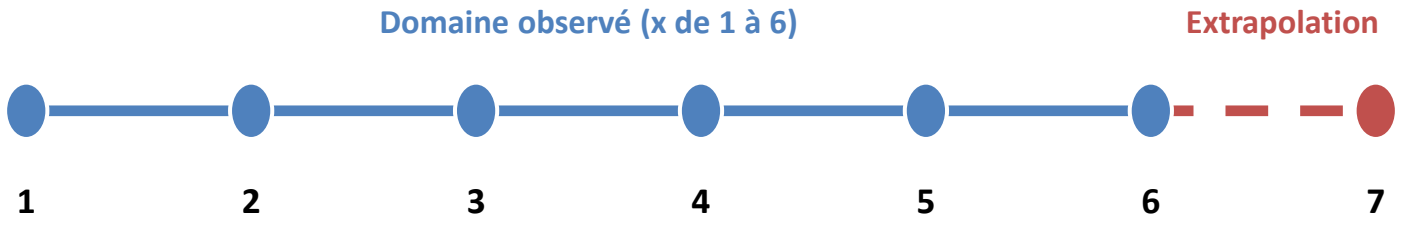
$1 - 0{,}396 / 66{,}453$

0,994

99,4 % de la variance de y est expliquée par le modèle

5. Prédiction pour x = 7

$$\hat{y} = 0{,}2667 + 1{,}9429 \times 7 \approx 13{,}87$$



x = 7 sort du domaine observé : on suppose, sans pouvoir le vérifier, que la relation linéaire reste valable. Prédiction moins fiable, même avec $R^2 = 0{,}994$.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire multiple

Modèle et interprétation

Quand plusieurs facteurs influencent la cible, on utilise la **régression multiple** :

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p$$

Exemple : prix = $\beta_0 + \beta_1 \cdot$surface + $\beta_2 \cdot$chambres + $\beta_3 \cdot$âge + $\beta_4 \cdot$distance. Si le modèle appris est $\hat{y} = 50 + 2{,}5 \cdot x_1 + 10 \cdot x_2 - 0{,}8 \cdot x_3$ (x_1 surface en m², x_2 chambres, x_3 âge) :

- **+1 m²** est associé à +2,5 unités de prix, **toutes les autres variables étant maintenues constantes** ;
- **+1 chambre** est associée à +10 unités, toutes choses égales par ailleurs ;
- **+1 an** d'âge est associé à −0,8 unité, toutes choses égales par ailleurs.

La mention « toutes choses égales par ailleurs » est essentielle : un coefficient de régression multiple est un effet **conditionnel**, qui diffère en général du coefficient obtenu avec cette variable seule.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire multiple

Modèle et interprétation

Écriture matricielle

Avec n observations et p variables, on regroupe les données dans la **matrice de conception** X (de taille n × (p+1)) ; la première colonne de 1 représente l'intercept :

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

$\hat{y} = X\beta$ *(vecteur des n prédictions)*

Fonction objectif et équations normales

$J(\beta) = \| y - X\beta \|^2_2 = (y - X\beta)^T(y - X\beta)$

$\nabla J(\beta) = -2\, X^T(y - X\beta)$

Le minimum est atteint quand le gradient s'annule, ce qui donne les **équations normales** :

$X^T X \beta = X^T y$

$\hat{\beta} = (X^T X)^{-1} X^T y$

La matrice hessienne de J est $2 \cdot X^T X$, **semi-définie positive** : J est convexe, donc tout point critique est un minimum global. Il est **unique** si $X^T X$ est définie positive.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire multiple

Modèle et interprétation

Conditions d'existence et calcul en pratique

En pratique, on ne calcule pas explicitement l'inverse de X^TX. On résout le problème par **décomposition QR** ou **SVD** (c'est ce que font `numpy.linalg.lstsq` et scikit-learn), plus stables numériquement ; ou par optimisation itérative lorsque p ou n sont très grands.

⍰ ⍰ Quand la formule OLS est-elle applicable ?

- $n \geq p + 1$: au moins autant d'observations que de paramètres (idéalement $n \gg p$).
- X de rang $p + 1$: aucune colonne n'est combinaison linéaire des autres. Sinon X^TX n'est pas inversible : c'est la multicolinéarité parfaite (par exemple une surface en m^2 et la même surface en pieds carrés).
- En cas de forte multicolinéarité (sans être parfaite), X^TX est presque singulière : le calcul est instable et la variance des coefficients explose.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire multiple

Modèle et interprétation

Surface x_1 (m^2)	Chambres x_2	Prix y (k€)
50	2	120
70	3	155
90	3	178
110	4	215
130	4	238

$$X^TX = \begin{bmatrix} 5 & 450 & 16 \\ 450 & 44500 & 1540 \\ 16 & 1540 & 54 \end{bmatrix}, \quad X^Ty = \begin{bmatrix} 906 \\ 87460 \\ 3051 \end{bmatrix}$$

La résolution de $X^TX\,\beta = X^Ty$ donne :

$$\widehat{\beta_0} \approx 35{,}97 \quad \widehat{\beta_1} \approx 1{,}163 \quad \widehat{\beta_2} \approx 12{,}67$$

Soit **ŷ ≈ 35,97 + 1,163·surface + 12,67·chambres** : +1 m² est associé à environ +1 163 €, et une chambre de plus à environ +12 670 €, à surface constante. **Pour 100 m² et 3 chambres, ŷ ≈ 190,3 k€.** Les résidus valent (+0,53 ; −0,40 ; −0,67 ; +0,40 ; +0,13), RSS ≈ 1,067 et R^2 ≈ 0,9999.

1. Construction des matrices X et y

Données (n = 5)

Surface	Chambre	Prix
50	2	120
70	3	155
90	3	178
110	4	215
130	4	238

X (1 | surface | chambres)

1	50	2
1	70	3
1	90	3
1	110	4
1	130	4

y (prix)

120
155
178
215
238

À partir du tableau de données (n = 5 observations) :
- La constante (biais) correspond à une colonne de 1.
- La première variable est la surface x_1.
- La deuxième variable est le nombre de chambres x_2.
- Le vecteur cible est le prix y.

La colonne de 1 correspond à la constante β0 ; la 2e colonne à la surface x1 ; la 3e au nombre de chambres x2.

2. Calcul de X^TX

X^TX

5	450	16
450	44 500	1 540
16	1 540	54

$$X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 50 & 70 & 90 & 110 & 130 \\ 2 & 3 & 3 & 4 & 4 \end{bmatrix}$$

$$X = \begin{bmatrix} 1 & 50 & 2 \\ 1 & 70 & 3 \\ 1 & 90 & 3 \\ 1 & 110 & 4 \\ 1 & 130 & 4 \end{bmatrix}, \quad y = \begin{bmatrix} 120 \\ 155 \\ 178 \\ 215 \\ 238 \end{bmatrix}$$

Matrice 3 × 3 symétrique

En effectuant le produit matriciel X^TX :

- $(X^TX)_{1,1} = 1 + 1 + 1 + 1 + 1 = 5$
- $(X^TX)_{1,2} = 50 + 70 + 90 + 110 + 130 = 450$
- $(X^TX)_{1,3} = 2 + 3 + 3 + 4 + 4 = 16$
- $(X^TX)_{2,2} = 50^2 + 70^2 + 90^2 + 110^2 + 130^2 = 2500 + 4900 + 8100 + 12100 + 16900 = 44500$
- $(X^TX)_{2,3} = 50(2) + 70(3) + 90(3) + 110(4) + 130(4) = 100 + 210 + 270 + 440 + 520 = 1540$
- $(X^TX)_{3,3} = 2^2 + 3^2 + 3^2 + 4^2 + 4^2 = 4 + 9 + 9 + 16 + 16 = 54$

3. Calcul de $X^T y$

$X^T y$

906

87 460

3 051

B. Calcul de $X^T y$

- $(X^T y)_1 = 120 + 155 + 178 + 215 + 238 = 906$
- $(X^T y)_2 = 50(120) + 70(155) + 90(178) + 110(215) + 130(238) = 6000 + 10850 + 16020 + 23650 + 30940 = 87460$
- $(X^T y)_3 = 2(120) + 3(155) + 3(178) + 4(215) + 4(238) = 240 + 465 + 534 + 860 + 952 = 3051$

4. Résolution du système

Nous devons résoudre le système $X^T X\hat{\beta} = X^T y$:

$$\begin{bmatrix} 5 & 450 & 16 \\ 450 & 44500 & 1540 \\ 16 & 1540 & 54 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 906 \\ 87460 \\ 3051 \end{bmatrix}$$

$\hat{\beta} = (X^T X)^{-1} X^T y$

$(X^T X)^{-1} = 1/3\,000 \times$

31 400	340	−19 000
340	14	−500
−19 000	−500	20 000

Déterminant de X'X = 6 000

$\hat{\beta}0$	215 800 / 6 000	**≈ 35,97**
$\hat{\beta}1$	6 980 / 6 000	**≈ 1,163**
$\hat{\beta}2$	76 000 / 6 000	**≈ 12,67**

Modèle final

$$\hat{y} = 35{,}97 + 1{,}163 \times \text{surface} + 12{,}67 \times \text{chambres}$$

35,97

Constante β̂0

Prix de base du modèle

+1,163

par m² supplémentaire

à nombre de chambres fixé

+12,67

par chambre en plus

à surface fixée

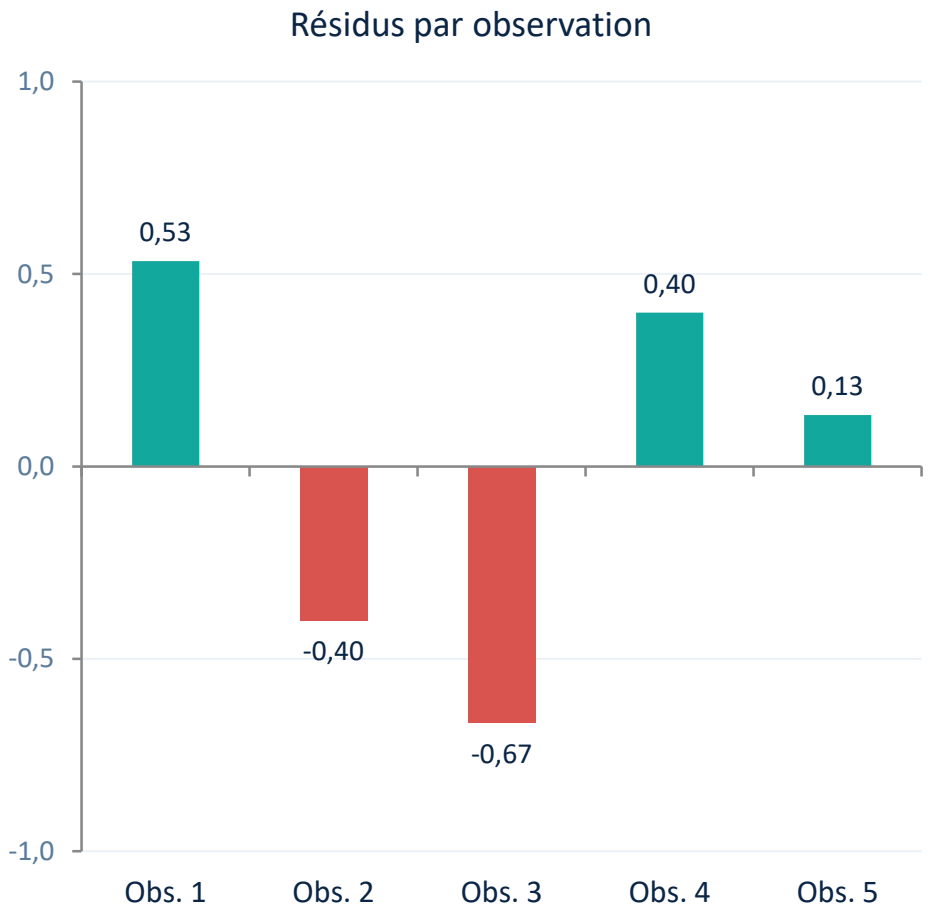
1. Calcul des résidus $e_i = y_i - \hat{y}_i$

Obs.	Surface	Chambres	y	$\hat{y}$	$e = y_i - \hat{y}_i$
1	50	2	120	119,4667	+0,5333
2	70	3	155	155,4000	−0,4000
3	90	3	178	178,6667	−0,6667
4	110	4	215	214,6000	+0,4000
5	130	4	238	237,8667	+0,1333

Exemple,
observation 1
$\hat{y}1 = 35,9667 + 1,1633 \times 50 + 12,6667 \times 2 = 119,4667$
observation 2
$\hat{y}2 = 35,9667 + 1,1633 \times 70 + 12,6667 \times 3 = 155,4000$
observation 2
$\hat{y}2 = 35,9667 + 1,1633 \times 90 + 12,6667 \times 3 = 178,6667$
,,,,,,,,,

$\Sigma e_i = 0$
propriété des résidus

2. Somme des carrés des résidus (RSS)



$RSS = \Sigma e_i^2$

$0{,}5333^2$	**0,2844**
$(-0{,}4000)^2$	**0,1600**
$(-0{,}6667)^2$	**0,4444**
$0{,}4000^2$	**0,1600**
$0{,}1333^2$	**0,0178**

RSS ≈ 1,067

3. Variation totale (TSS)

y	$y - \bar{y}$	$(y - \bar{y})^2$
120	−61,2	**3 745,44**
155	−26,2	**686,44**
178	−3,2	**10,24**
215	+33,8	**1 142,44**
238	+56,8	**3 226,24**

$\bar{y} = 906 / 5$

181,2

$TSS = \Sigma (y_i - \bar{y})^2$

8 810,8

La TSS mesure la dispersion de y autour de sa moyenne, sans tenir compte du modèle.

4. Coefficient de détermination R^2

$$R^2 = 1 - RSS / TSS = 1 - 1{,}0667 / 8\,810{,}8$$

0,0001211

RSS / TSS

part de variation non expliquée

0,9999

R^2

qualité d'ajustement

99,99 %

de la variance de y

expliquée par le modèle

Coefficient de détermination R^2

R^2 mesure la **qualité de l'ajustement** d'un modèle de régression linéaire. Concrètement, il indique la proportion de la variance de la variable cible (y) expliquée par les variables explicatives (x).

Interprétation des valeurs

→ **R^2=1(ou 100%)** : Le modèle explique parfaitement les données (toutes les prédictions tombent exactement sur les points).

→ **$R^2 = 0$** : Le modèle n'explique aucune variation des données (il ne fait pas mieux que de prédire systématiquement la moyenne $\bar{y}$).

→ **Dans l'exemple précédent ($R^2 \approx 0,9999$)** : Le modèle explique **99,99 %** de la variation du prix en fonction de la surface et du nombre de chambres, ce qui indique un ajustement quasi parfait.

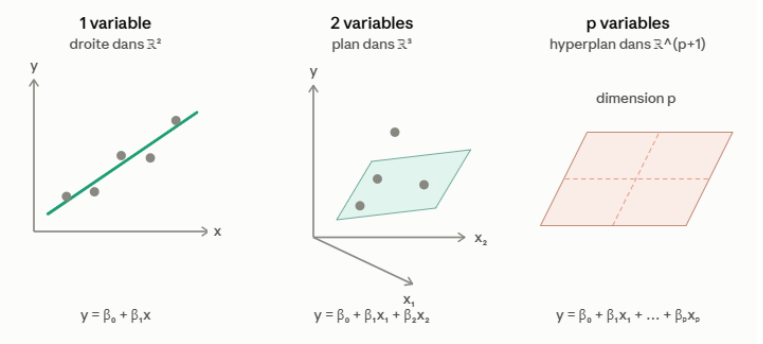
Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Régression linéaire multiple

Interprétation géométrique

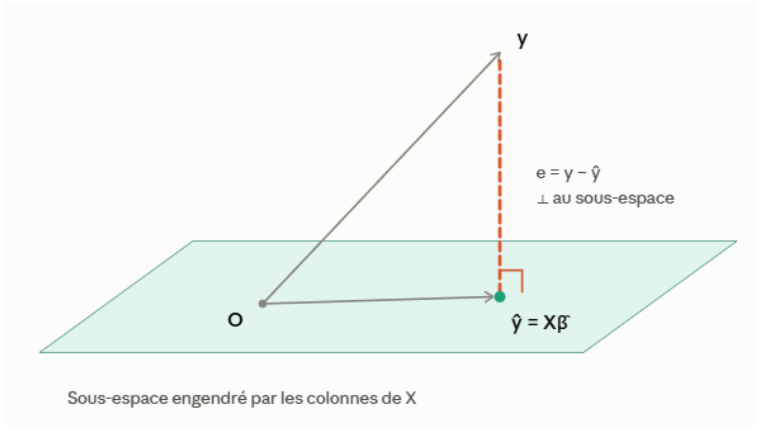


Droite, plan, hyperplan

1 variable explicative —► droite (dans $\mathbb{R}^2$)
2 variables explicatives —► plan (dans $\mathbb{R}^3$)
p variables explicatives —► hyperplan (dans $\mathbb{R}^{p+1}$)

Projection orthogonale

Il existe une seconde lecture, plus profonde : y est un vecteur de $\mathbb{R}^n$, et les colonnes de X engendrent un sous-espace de $\mathbb{R}^n$. **ŷ est la projection orthogonale de y sur ce sous-espace** : c'est le point de ce sous-espace le plus proche de y.



On en tire que le résidu est **orthogonal** aux colonnes de X (c'est exactement l'équation normale $X^T e = 0$), et que la projection s'écrit :

$\hat{y} = H\,y$ avec $H = X\,(X^TX)^{-1}\,X^T$

(H : matrice « chapeau », symétrique, idempotente, trace(H) = p + 1)

Chapitre 3: Régression

Régression linéaire (simple et multiple)

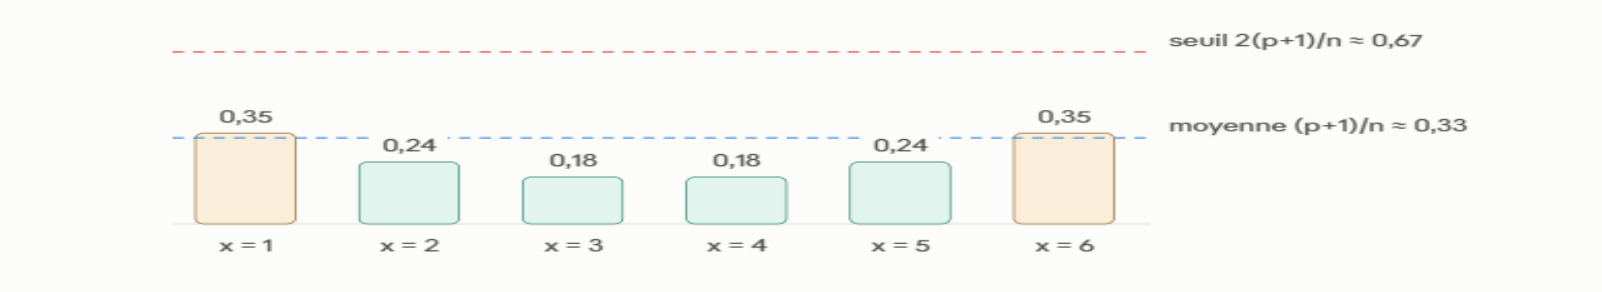
Regularisation (Ridge, Lasso)

Régression linéaire multiple

Interprétation géométrique

Levier

Le **levier** h_{ii} est le i-ème élément diagonal de H : il mesure l'influence potentielle de la valeur y_i sur sa propre prédiction ($\hat{y}_i = \Sigma_j H_{ij} y_j$). Il est élevé pour les observations dont les variables explicatives sont éloignées de la moyenne. La moyenne des leviers vaut $\frac{p+1}{n}$; on regarde de près ceux qui dépassent environ $2(p+1)/n$ (repère indicatif).



Le levier est le plus élevé aux extrémités (x = 1 et x = 6), les points les plus éloignés de la moyenne $\bar{x}$ = 3,5. Leur valeur 0,35 est un peu au-dessus de la moyenne des leviers, (p+1)/n = 2/6 ≈ 0,33, et très en dessous du seuil indicatif 2(p+1)/n ≈ 0,67. Aucune observation n'est donc préoccupante ici. Les leviers somment toujours à p + 1 = 2, ce qui est cohérent avec trace(H) = p + 1.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Propriétés statistiques de l'estimateur OLS

Non-biais et variance

Sous H1, H2 et H5, l'estimateur est **non biaisé** : $E[\hat{\beta}] = \beta$. Sous H3 et H4 en plus, sa matrice de variance-covariance est :

$$Var(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$$

La variance σ^2 de l'erreur est inconnue ; on l'estime par :

$$\hat{\sigma}^2 = s^2 = RSS / (n - p - 1)$$

Le dénominateur n − p − 1 (degrés de liberté résiduels) rend cet estimateur non biaisé.
Remarque : la variance de $\hat{\beta}$ augmente quand les colonnes de X sont corrélées, ce qui explique les effets de la multicolinéarité.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Propriétés statistiques de l'estimateur OLS

Théorème de Gauss–Markov

Sous H1 à H5 (**sans** hypothèse de normalité), l'estimateur OLS est le **meilleur estimateur linéaire non biaisé** (BLUE : *Best Linear Unbiased Estimator*) : parmi tous les estimateurs linéaires en y et non biaisés, il a la plus petite variance.
Cela ne veut pas dire qu'aucun estimateur biaisé ne fait mieux en erreur quadratique : c'est précisément le point de départ de la régularisation (Ridge, Lasso).

Lien avec le maximum de vraisemblance

Si $\varepsilon_i \sim N(0, \sigma^2)$, la log-vraisemblance s'écrit, à une constante près, $-RSS / (2\sigma^2)$.
Maximiser la vraisemblance revient donc à minimiser RSS : OLS et maximum de vraisemblance coïncident sous erreurs gaussiennes. C'est la justification probabiliste du carré. Avec une autre loi d'erreur (par exemple Laplace), on obtiendrait une autre perte (valeur absolue).

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Pourquoi régulariser ? Le surapprentissage

un modèle doit bien prédire des données qu'il n'a jamais vues, pas seulement « réciter » celles de l'entraînement.

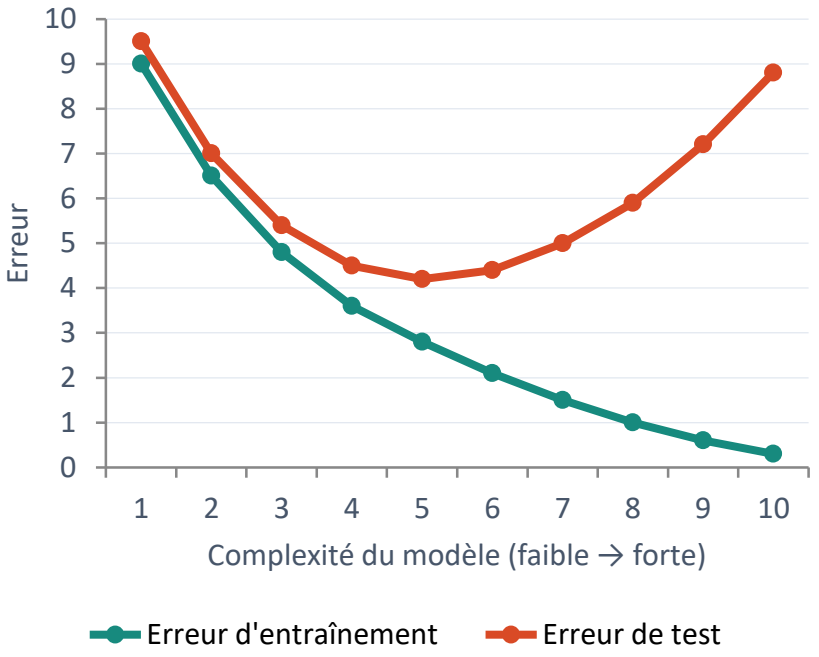
→ **Sous-apprentissage** (modèle trop simple) : erreur élevée en entraînement ET en test.

→ **Bon compromis** : erreur de test minimale.

→ **Surapprentissage** (modèle trop flexible) : erreur d'entraînement très faible, mais erreur de test qui remonte : le modèle a appris le bruit.

Limiter la complexité en pénalisant les coefficients trop grands. C'est la régularisation.

Figure schématique : l'erreur de test fait un « U »



Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Rappel : régression linéaire et erreur MSE

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{ip}$$

$\hat{y}_i$ est la prédiction pour l'observation i. β_0 est l'interception. β_j est le poids de la variable j : de combien la prédiction varie quand x_j augmente d'une unité, les autres variables restant fixes.

$$MSE(\beta) = (1/n)\ \Sigma_i\ (y_i - \hat{y}_i)^2$$

Pour chaque observation, on calcule l'écart (le résidu) entre réalité et prédiction. On l'élève au carré pour que les erreurs positives et négatives ne s'annulent pas et que les grosses erreurs pèsent plus. Puis on fait la moyenne.

i	y_i	$\hat{y}_i$	Résidu $y_i - \hat{y}_i$	Carré
1	3	4	−1	1
2	5	5	0	0
3	8	7	+1	1

$$MSE = (1 + 0 + 1) / 3 \approx 0{,}67$$

Exemple à 3 observations : un résidu **négatif** signifie qu'on a **surestimé**, un résidu **positif** qu'on a **sous-estimé**.

Sans régularisation, on choisit les β qui minimisent la MSE. Problème : avec beaucoup de variables ou des variables corrélées, ces β deviennent instables et très sensibles au bruit de l'échantillon.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Principe : ajustement + pénalité

$$J(\beta) = MSE(\beta) + \lambda \times Pénalité(\beta)$$

Erreur d'ajustement

Mesure à quel point le modèle colle aux données d'entraînement. On veut la réduire.

Pénalité

Mesure la « taille » des coefficients. Avoir de gros coefficients devient coûteux : le modèle doit les justifier.

$\lambda \geq 0$: le curseur

$\lambda = 0$: régression ordinaire. λ très grand : coefficients écrasés vers 0, donc sous-apprentissage.

Ridge : $MSE + \lambda \Sigma_j \beta_j^2$

Pénalité L2 = somme des carrés. Les gros coefficients sont très coûteux.

Lasso : $MSE + \lambda \Sigma_j |\beta_j|$

Pénalité L1 = somme des valeurs absolues. Coût proportionnel à la taille.

Remarque : β_0 (l'interception) n'est pas pénalisé, sinon on tirerait artificiellement le niveau moyen des prédictions vers 0.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

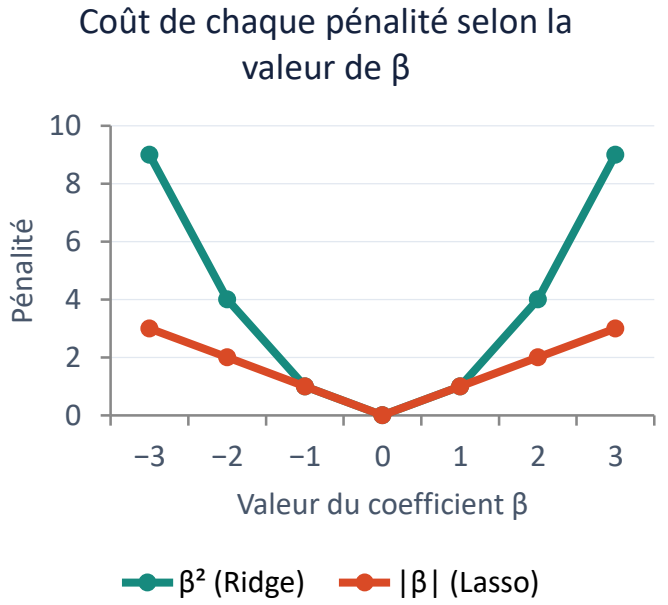
Regularisation (Ridge, Lasso)

Calculer les pénalités L2 et L1

Coefficients	Ridge (L2)	Lasso (L1)
(3,2 ; −2,2 ; 1,1)	$3{,}2^2 + (-2{,}2)^2 + 1{,}1^2$ = 10,24 + 4,84 + 1,21 = 16,29	3,2 + 2,2 + 1,1 = 6,5
(2,5 ; −1,7 ; 0,8)	6,25 + 2,89 + 0,64 = 9,78	2,5 + 1,7 + 0,8 = 5,0

- **Le carré punit les gros coefficients** : doubler un coefficient (2 → 4) multiplie son coût Ridge par 4 (4 → 16).
- **La valeur absolue est proportionnelle** : doubler un coefficient double simplement son coût Lasso.
- **Conséquence**: Ridge s'acharne sur les plus gros coefficients, alors que Lasso exerce la même pression quelle que soit la taille, jusqu'à atteindre 0.

Attention : une pénalité **plus petite ne veut pas dire un meilleur modèle** ; il faut aussi regarder l'erreur d'ajustement.



La courbe L2 est lisse en 0 ; la courbe L1 forme une pointe en 0.

C'est cette pointe qui permettra à Lasso d'obtenir des coefficients exactement nuls.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Pourquoi Lasso annule-t-il des coefficients ?

L'idée de base

Pour chaque coefficient β, deux forces s'exercent :

→ la **MSE** tire β vers la valeur qui colle le mieux aux données (appelons-la **b**, la valeur donnée par les MCO) ,

→ la **pénalité** tire β vers 0.

Tout se joue sur la **façon dont la pénalité tire** quand β devient petit.

Ridge : une force qui s'affaiblit

La pénalité est β^2. Plus β est **petit, plus la force qui le pousse vers 0** est **faible** (c'est proportionnel à β).

C'est comme un ressort : très tendu, il tire fort, presque au repos, il ne tire presque plus.

Quand β est proche de 0, la pénalité n'a donc plus assez de force pour finir le travail. β devient **très petit, mais jamais exactement 0**.



Lasso : une force constante

La pénalité est |β|. Elle pousse vers 0 avec **la même force, que β soit grand ou minuscule**. C'est comme quelqu'un qui pousse une voiture avec une force fixe : elle va jusqu'à 0 et s'y arrête.

Si la poussée de la pénalité est plus forte que la traction de la MSE, β arrive à 0 et y **reste**.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Pourquoi Lasso annule-t-il des coefficients ?

Pourquoi voudrait-on β = 0 ?

Un coefficient nul signifie que la variable est retirée du modèle. C'est utile pour plusieurs raisons :

1. **Éliminer les variables inutiles.** Si une variable n'apporte rien (par exemple le numéro de porte pour prédire le prix d'un logement), elle ne fait que du bruit. La supprimer rend le modèle plus fiable.
2. **Éviter le surapprentissage.** Moins de variables, c'est moins de risque que le modèle apprenne le hasard des données d'entraînement.
3. **Obtenir un modèle simple à interpréter.** Parmi 50 variables, Lasso peut n'en garder que 8. On comprend alors mieux ce qui compte vraiment.
4. **Gérer les variables redondantes.** Si deux variables disent presque la même chose, Lasso tend à en garder une et à annuler l'autre.

Ridge *rétrécit* tous les coefficients, tandis que Lasso *rétrécit et sélectionne*, car son fondement mathématique l'amène à poser certains coefficients exactement à zéro.

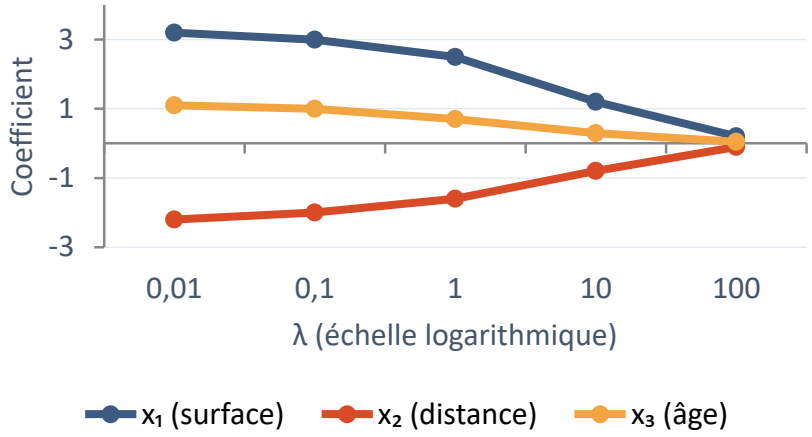
Chapitre 3: Régression

Régression linéaire (simple et multiple)

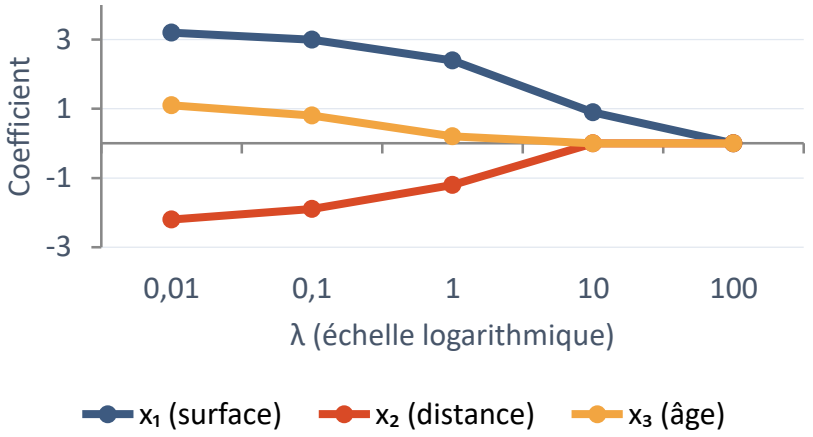
Regularisation (Ridge, Lasso)

Effet de λ sur les coefficients

Ridge : contraction progressive



Lasso : contraction + coefficients nuls



Ridge : **tous les coefficients diminuent ensemble**, régulièrement, et se rapprochent de 0 sans l'atteindre pour un λ fini. Aucune variable n'est éliminée.

Lasso : **certains coefficients tombent à 0 exactement** et y restent. Ici x_3 sort en premier, puis x_2. Plus λ augmente, plus le modèle est parcimonieux.

λ = 0 : régression ordinaire. λ trop grand : tout tend vers 0 (sous-apprentissage). Courbes schématiques, valeurs fictives.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Standardiser sans fuite d'information

Pourquoi standardiser ? La pénalité compare des valeurs de coefficients, mais la **taille d'un coefficient dépend de l'unité de sa variable** : une surface en m² ou en cm² donne des β très différents (×10 000). Une variable exprimée en petites unités a un petit coefficient, donc elle est à peine pénalisée : la pénalité devient injuste. **On met donc toutes les variables sur la même échelle.**

$$z_j = (x_j - \mu_j) / \sigma_j$$

μ_j : moyenne, σ_j : écart-type, calculés sur l'entraînement.

1

Séparer

Découper en entraînement et test (ou en plis de validation croisée).

2

Apprendre μ et σ

Les calculer sur l'entraînement uniquement.

3

Appliquer

Utiliser les mêmes μ et σ sur le test, sans les recalculer.

4

Ajuster

Entraîner Ridge ou Lasso ; choisir λ par validation croisée.

5

Évaluer

Mesurer l'erreur sur le test, une seule fois.

Fuite de données : standardiser avant de séparer laisse filtrer de l'information du test vers l'entraînement ; l'évaluation devient trop optimiste.

Chapitre 3: Régression

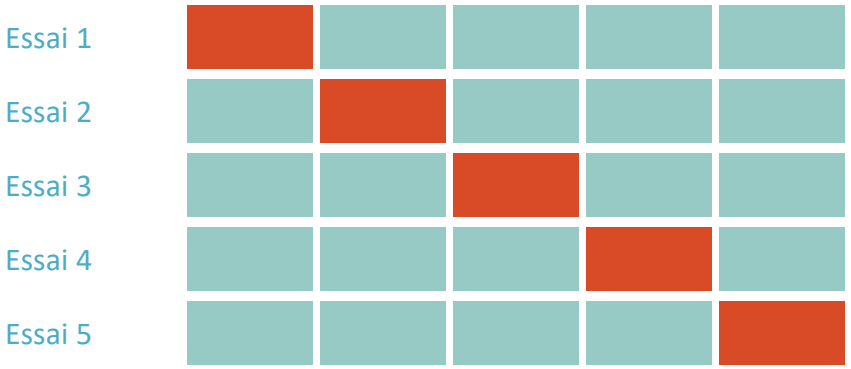
Régression linéaire (simple et multiple)

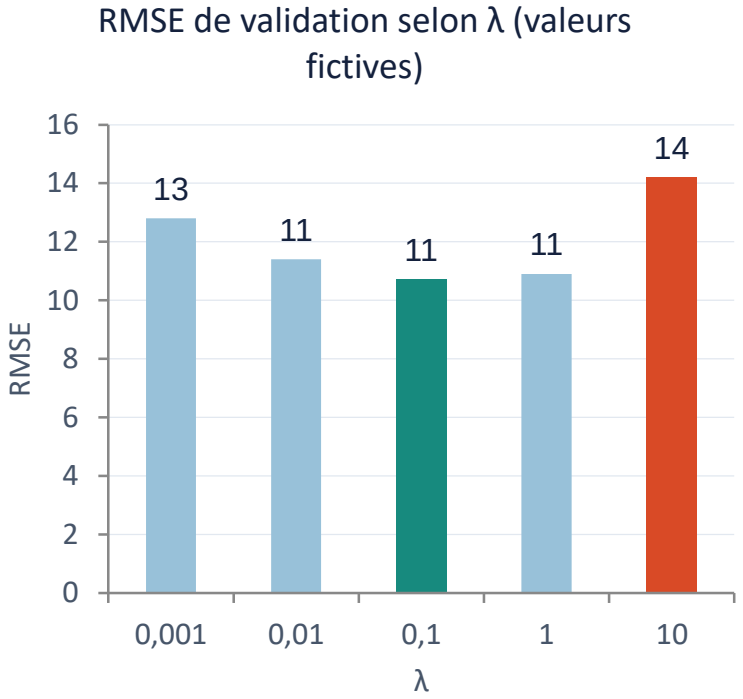
Regularisation (Ridge, Lasso)

Choisir λ par validation croisée

On découpe l'entraînement en K = 5 plis. Pour chaque λ candidat, on entraîne 5 fois sur 4 plis (bleu) et on mesure l'erreur sur le pli restant (rouge). On moyenne les 5 erreurs.

Donc pour chaque λ:





$$\text{Erreur_CV}(\lambda) = (1/K)\ \Sigma_k\ \text{Erreur}_k(\lambda)$$

On retient le λ qui minimise l'erreur CV. Le jeu de test reste intact : s'il servait à choisir λ, il deviendrait un jeu de validation et l'estimation finale serait optimiste.

λ = 0,1 donne la meilleure erreur (vert). **λ = 10** pénalise trop : les coefficients sont écrasés et le modèle sous-apprend (rouge). **λ faible** : modèle presque non régularisé, sensible au bruit.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

Ridge ou Lasso : comment choisir ?

Critère	Ridge (L2)	Lasso (L1)
Effet sur les coefficients	Contracte tous les coefficients, rarement exactement jusqu'à 0.	Contracte et met certains coefficients exactement à 0.
Sélection de variables	Non : toutes les variables sont conservées.	Oui, intégrée : modèle parcimonieux.
Variables corrélées	Répartit le poids entre elles : solution stable.	Tend à en choisir une seule, parfois de façon instable.
À privilégier si	Beaucoup de variables utiles et corrélées ; objectif surtout prédictif.	On pense que peu de variables comptent ; on veut un modèle simple à lire.

Chapitre 3: Régression

Régression linéaire (simple et multiple)

Regularisation (Ridge, Lasso)

À retenir et pièges à éviter

Ridge : MSE + $\lambda \Sigma_j \beta_j^2$

Contracte et stabilise les coefficients ; ne sélectionne pas de variables.

Lasso : MSE + $\lambda \Sigma_j |\beta_j|$

Contracte et sélectionne : certains coefficients deviennent exactement nuls.

λ : le réglage clé

Choisi par validation croisée sur l'entraînement, jamais en optimisant le test.

Erreurs fréquentes

Oublier de standardiser des variables d'unités différentes.

Standardiser **avant de séparer les données** (fuite).

Choisir **λ en optimisant le score de test**.

Croire que Ridge sélectionne des variables, ou que Lasso garde toujours les mêmes avec des variables corrélées.

Prendre un coefficient pénalisé ou une sélection Lasso pour une preuve de causalité: « quelles variables aident le mieux à prédire y ? »et non pas« quelles variables font changer y ? »

Exple: « Le modèle montre que la surface est un **bon prédicteur** du prix », mais pas « la surface **provoque** le prix »

La régularisation améliore la généralisation ; elle ne corrige ni des données de mauvaise qualité