

الجزائريـــــــة الديمقراطيـــــة الشعبيـــة
وزارة التعليـــــم العـــــالي و البحـــــث العلـــمي
جامعة وهران للعلوم والتكنولوجيا محمد بوضياف
كلية الريـــاضيـــات و الإعـــلام الآلـــي
République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur Et de la Recherche Scientifique
Université des Sciences et de la Technologie d'Oran Mohamed BOUDIAF
Faculté des Mathématiques et Informatique
Département D'Informatique

Machine Learning Course

By Dr. Asmaa Ourdighi

Lecture 5

Chapitre 5: Clustering

1. Mesures de similarité
2. k-means, CAH
3. DBSCAN

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

.

Introduction

Clustering et apprentissage non supervisé

Définition

Le **clustering (classification automatique)** regroupe des observations en clusters de sorte que les objets d'un même groupe **soient très semblables entre eux (cohésion)** et **très différents de ceux des autres groupes (séparation).**

Il ne s'appuie sur **aucune étiquette** : c'est de **l'apprentissage non supervisé**. **Utilité : explorer, résumer, segmenter des données dont on ignore la structure.**

Clustering vs classification supervisée.

→ **En classification supervisée, on dispose d'exemples étiquetés (X, y)** : le modèle apprend à prédire y pour de nouvelles données, et on mesure l'erreur avec les vraies étiquettes.

→ **En clustering, on n'a que X : les groupes sont découverts, pas prédits, et leur validité s'évalue par des critères internes (silhouette, inertie) ou par l'interprétation métier.**

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

Introduction

Clustering et apprentissage non supervisé

Vocabulaire

Cluster : groupe d'observations similaires.

Distance d(x,y) : nombre ≥ 0 mesurant l'éloignement.

Dissimilarité : généralisation de la distance (sans inégalité triangulaire obligatoire).

Similarité s(x,y) : grande si les objets se ressemblent ; on passe de l'une à l'autre par d = 1 − s.

Interprétation et limites

Le résultat dépend du **choix des variables**, de **la distance** et de **l'algorithme** : plusieurs clusterings « corrects » existent.

Erreur fréquente: croire que les clusters ont forcément un sens réel.

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

Introduction

Clustering et apprentissage non supervisé

Supervisé : données étiquetées, but = prédire.

Non supervisé : pas d'étiquettes, but = découvrir.

Propriétés d'une distance : $d \geq 0$; $d(x,y)=0 \Leftrightarrow x=y$; symétrie ; inégalité triangulaire.

L'inégalité triangulaire est une propriété fondamentale d'une distance. Elle signifie que : La distance directe entre deux points est toujours inférieure ou égale à la somme des distances en passant par un troisième point.

$$d(x,z) \leq d(x,y) + d(y,z)$$

Piège : toujours choisir variables et mesure avant l'algorithme.

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

Distances numériques : équations

Euclidienne (L2)

$$d(x, y) = \sqrt{\Sigma_i (x_i - y_i)^2}$$

x_i, y_i : i-ème coordonnée de x et y. Segment droit ; pénalise fortement les grands écarts, **sensible aux outliers.**

Manhattan (L1)

$$d(x,y) = \Sigma_i |x_i - y_i|$$

Somme des écarts absolus (trajet sur grille). **Plus robuste que L2 aux valeurs extrêmes**.

Minkowski (Lp)

$$d(x, y) = (\Sigma_i |x_i - y_i|^p)^{\frac{1}{p}}$$

$p \geq 1$: paramètre de la norme. p=1 Manhattan, p=2 Euclidienne, $p \to \infty$ Tchebychev (max des écarts).

Mahalanobis

$$d_{M(x,y)} = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$

Σ : matrice de covariance des données. Tient compte des échelles et des corrélations ; avec Σ = I on retrouve L2. Limite : Σ doit être inversible et bien estimée.

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

.

Distances numériques : équations

Similarité cosinus

$$\cos(x,y) = (x \cdot y) / (\|x\| \cdot \|y\|)$$

x·y : produit scalaire ; ||x|| : norme. Valeur dans [−1;1] ; distance = 1 − cos. Compare l'orientation, pas la longueur : **idéal pour les textes (TF-IDF).**

Distance de Hamming

$$d_H(x,y) = \Sigma_i \, 1[x_i \neq y_i]$$

1[·] vaut 1 si la condition est vraie, 0 sinon : nombre de positions différentes. Pour **des variables binaires ou catégorielles ; ex. d_H(10110, 11100) = 2.**

Jaccard

$$J(A,B) = |A \cap B| / |A \cup B|$$

Part d'éléments communs entre ensembles ; distance 1 − J. **Limite : ignore les éléments absents des deux ensembles.**

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

Normalisation et échelle des variables

Problème

Les distances additionnent des écarts exprimés dans des unités différentes. **Une variable de grande amplitude** (salaire en milliers d'euros) **écrase une variable de faible amplitude** (âge en années) et décide à elle seule des clusters.

Solutions (équations)

→ Standardisation (z-score) : $z = (x - \mu)/\sigma$, avec μ la moyenne et σ l'écart-type de la variable (moyenne 0, écart-type 1).

→ Min-max : $x' = (x - \min)/(\max - \min)$, ramené dans [0,1].

→ Mahalanobis fait aussi ce travail implicitement.

Attention, Mahalanobis n'est pas une méthode de normalisation au même sens que les deux précédentes.

C'est une mesure de distance qui tient compte :

- Des échelles des variables.
- De leur variance.
- Des corrélations entre les variables.

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

Normalisation et échelle des variables

Exemple

A = (25 ans, 30 000 €), B = (30 ans, 31 000 €).

Brut : $d = \sqrt{5^2 + 1000^2} \approx 1000{,}01$: l'âge ne compte pas !

Min-max (âge 20–60, salaire 20 000–60 000) :

A′ = (0,125 ; 0,25), B′ = (0,25 ; 0,275), d = √(0,125² + 0,025²) ≈ 0,127 : les deux variables comptent.

Limites

Le min-max est sensible aux outliers (min/max extrêmes) ; le z-score est préférable. Ne pas normaliser des variables de même unité dont l'échelle porte un sens. Attention aux variables catégorielles (encodage).

Règle d'or : normaliser avant tout algorithme à distance.

→ **Concerné :** k-means, CAH, DBSCAN, kNN.

→ **Non concerné :** cosinus (déjà normalisé par les normes).

K-means : définition et principe

Définition

K-means (k-moyennes) **partitionne n observations en exactement K clusters disjoints**. **Chaque cluster C_k** est résumé par **son centroïde μ_k, la moyenne de ses points**. C'est un **algorithme itératif**, rapide, adapté aux **données numériques**.

Principe

On **cherche les K centres tels que chaque point soit proche du centre de son groupe.** On alterne deux opérations :

→ affecter chaque point au centre le plus proche,

→ puis déplacer chaque centre au barycentre de ses points.

K-means : définition et principe

Centroïde

Le **centroïde de C_k est le point moyen** : chacune de ses coordonnées est **la moyenne des coordonnées des points du cluster**. C'est la position qui minimise la somme des carrés des distances au cluster.

Interprétation et limites

Un cluster compact autour de son centre a une faible inertie. **Le centroïde n'est pas forcément une observation réelle** ; la moyenne est sensible aux valeurs aberrantes (k-medoids est une alternative).

Chapitre 4: Clustering

Introduction: Clustering et apprentissage non supervisé

Mesures de similarité

k-means, CAH

DBSCAN

K-means : définition et principe

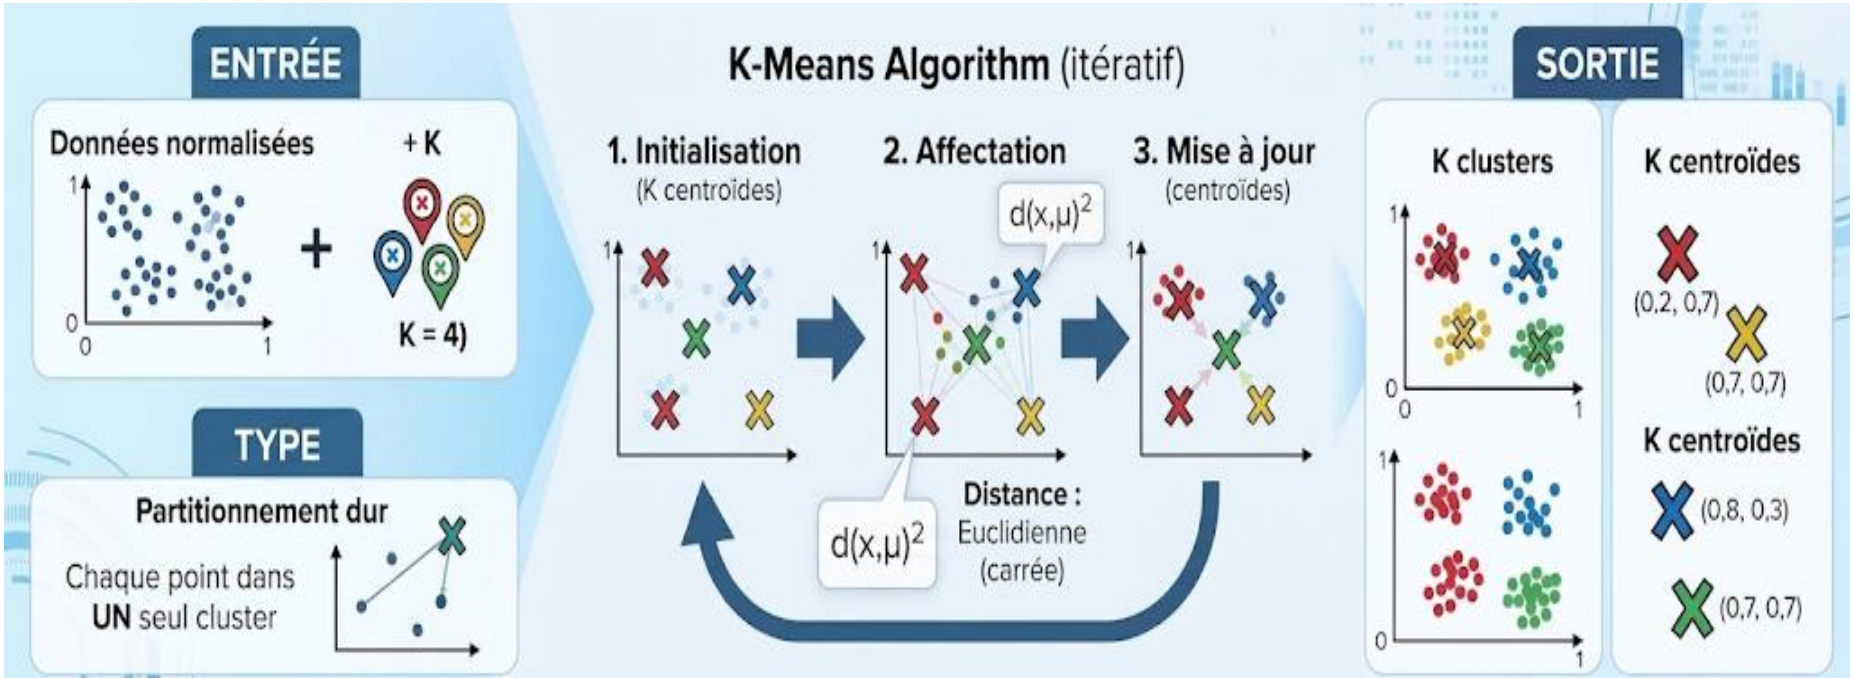
En résumé

Entrée : données normalisées + K.

Sortie : K clusters et K centroïdes.

Distance : Euclidienne (carrée).

Type : partitionnement dur : chaque point dans un seul cluster.



K-means : définition et principe

Inertie intra-classe

$$J = \Sigma_k \Sigma_{x \in C_k} \|x - \mu_k\|^2$$

K : nb de clusters ; C_k : cluster k ; μ_k : son centroïde. Somme des carrés des distances point-centre : k-means la minimise.

Centroïde

$$\mu_k = (1/|C_k|) \Sigma_{\{x \in C_k\}} x$$

$|C_k|$: nombre de points du cluster. Moyenne coordonnée par coordonnée ; elle minimise J pour C_k fixé.

Affectation

$$C_k = \{ x : \|x - \mu_k\| \leq \|x - \mu_j\| \; \forall \, j \}$$

Chaque point rejoint le centroïde le plus proche (cellules de Voronoï).

k-means++

$$P(x) = D(x)^2 \, / \, \Sigma_x' \, D(x')^2$$

D(x) : distance de x au centre déjà choisi le plus proche. Le prochain centre est tiré avec cette probabilité : les points éloignés sont favorisés.

Silhouette

$$s(i) = (b(i) - a(i)) \, / \, \max(a(i), b(i))$$

a(i) : distance moyenne de i à son cluster ; b(i) : distance moyenne au cluster voisin le plus proche. $s \in [-1 ; 1]$.

K-means : algorithme détaillé, k-means++ et choix de K

1. Initialisation. Choisir K puis K centroïdes initiaux. Aléatoire : risque de mauvais départ. **K-means++ : 1er centre tiré au hasard ; chacun des suivants tiré avec probabilité proportionnelle à $D(x)^2$, ce qui répartit les centres et améliore qualité et vitesse.**

2. Affectation. Calculer la distance de chaque point aux K centroïdes ; l'affecter au plus proche.

3. Mise à jour. Recalculer chaque centroïde comme la moyenne de son cluster.

4. Convergence. Répéter 2–3 jusqu'à ce que les affectations ne changent plus (ou que J baisse de moins d'un seuil, ou nombre maximal d'itérations). J décroît à chaque itération : convergence garantie, mais vers un minimum local → relancer plusieurs fois (n_init).

Choix de K. Coude : tracer J en fonction de K, choisir le K où la courbe se plie (gain marginal faible). Silhouette : calculer la silhouette moyenne pour chaque K et prendre le maximum (≈1 : très bon, ≈0 : clusters qui se chevauchent, <0 : mauvaise affectation).

Que cherche à faire K-means ?

- Entrée : un ensemble de N observations représentées par des vecteurs de caractéristiques.
- Paramètre choisi par l'utilisateur : K, le nombre de groupes recherchés.
- Sortie : K clusters et un centroïde par cluster.
- Principe : des points proches selon une distance sont regroupés ensemble.
- K-means alterne deux opérations : affecter les points, puis recalculer les centres.

Chaque symbole correspond à un objet concret dans le jeu de données.

N	**Nombre total de points**	Ex. : 6 observations
K	**Nombre de clusters demandé**	Ex. : K = 2
x_i	**i^e observation (vecteur)**	Ex. : $x_1 = (1, 1)$
C_k	**Ensemble des points affectés au cluster k**	Ex. : C_1 contient 3 points
$\|C_k\|$	**Nombre de points dans le cluster k**	Ex. : $\|C_1\| = 3$
μ_k	**Centroïde du cluster k**	Moyenne des coordonnées
$\|\|x - \mu_k\|\|$	**Distance entre un point et un centroïde**	Souvent distance euclidienne

Vue d'ensemble : la boucle K-means

Les équations ne sont pas utilisées toutes au même moment.

1 Choisir K

Fixer le nombre de groupes

2 Initialiser

Choisir K centres (ex. K-means++)

3 Affecter

Associer chaque point au centre le plus proche

4 Recalculer

Remplacer chaque centre par la moyenne de son groupe

5 Tester

Vérifier si les affectations/centres changent encore

6 Évaluer

Inertie et silhouette

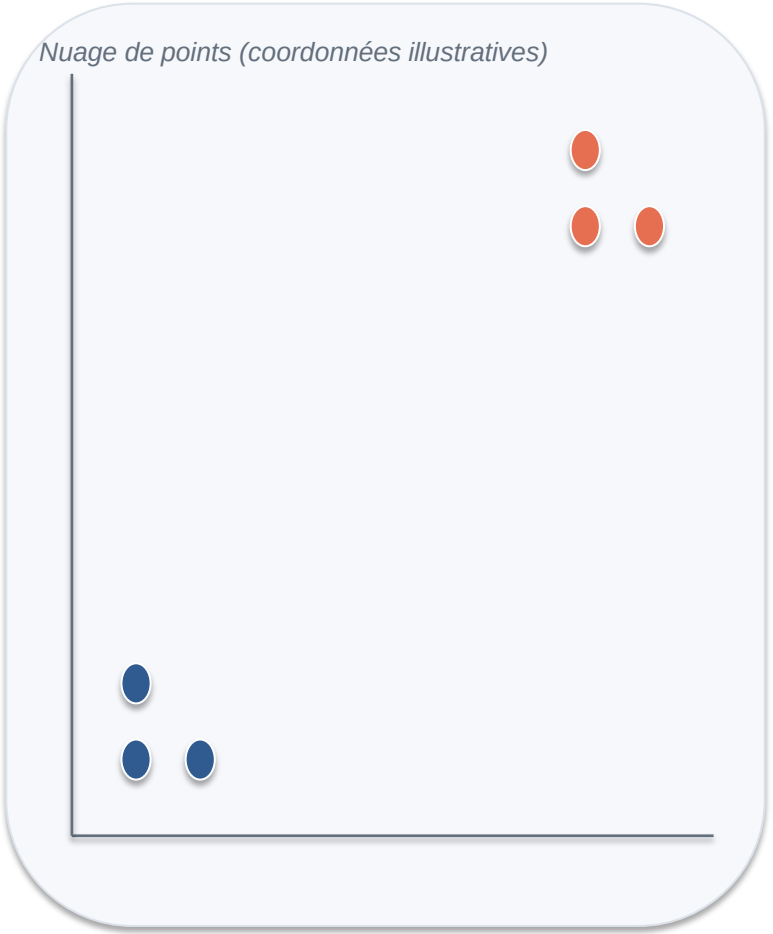
Exemple

Six observations à deux dimensions ; on cherche K = 2 clusters.

P_1	P_2	P_3
(1, 1)	(1, 2)	(2, 1)
P_4	P_5	P_6
(8, 8)	(8, 9)	(9, 8)

$$X = \{P_1, P_2, P_3, P_4, P_5, P_6\}$$

Chaque point est un vecteur (x, y).



Exemple

Étape 1: Choisir K et initialiser les centres

K est fixé avant le lancement ; l'initialisation fournit les premiers centroïdes provisoires.

- Dans l'exemple, on choisit K = 2 : l'algorithme doit construire deux groupes.
- On doit ensuite sélectionner deux centres initiaux $\mu_1^{(0)}$ et $\mu_2^{(0)}$.
- Une initialisation aléatoire peut choisir deux centres très proches : les groupes risquent alors d'être mal séparés au départ.
- K-means++ choisit les centres de façon à favoriser des points éloignés des centres déjà sélectionnés.

$$\mu_1^{(0)} = P_1 = (1,1)$$

Premier centre choisi au hasard, dans l'exemple.

$$P(x) = D(x)^2 / \Sigma_{x'} D(x')^2$$

Probabilité de sélectionner x comme prochain centre.

D(x) est la distance de x au centre déjà choisi le plus proche. Plus D(x) est grande, plus $D(x)^2$ pèse dans le tirage.

Après le premier centre P_1 = (1,1), calculons les distances euclidiennes au carré.

Point	Coordonnées	D(x)²	Probabilité
P_1	(1,1)	0	0 / 326 = 0 %
P_2	(1,2)	1	1 / 326 ≈ 0,31 %
P_3	(2,1)	1	1 / 326 ≈ 0,31 %
P_4	(8,8)	98	98 / 326 ≈ 30,06 %
P_5	(8,9)	113	113 / 326 ≈ 34,66 %
P_6	(9,8)	113	113 / 326 ≈ 34,66 %

$\Sigma D(x)^2 = 0 + 1 + 1 + 98 + 113 + 113 = 326$

Le dénominateur normalise les poids en probabilités.

Un point éloigné, comme P_5 ou P_6, a davantage de chances d'être choisi comme deuxième centre. Le tirage reste probabiliste : ce n'est pas automatiquement le point le plus éloigné.

Exemple

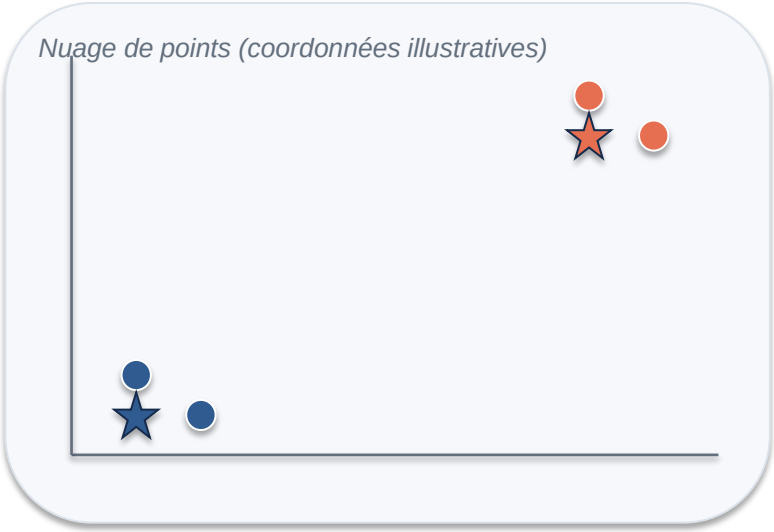
Étape 2: Affecter chaque point au centre le plus proche

C'est ici que l'équation d'affectation de votre illustration intervient.

$$C_k = \{ x : \|x - \mu_k\| \leq \|x - \mu_j\| \text{ pour tout } j \}$$

Chaque observation rejoint le cluster dont le centroïde est le plus proche.

- Pour chaque point x, calculer sa distance à chacun des K centroïdes.
- Comparer ces K distances.
- Attribuer x au cluster qui donne la plus petite distance.
- En cas d'égalité, une règle de départage doit être définie.



Les couleurs représentent les affectations.

Exemple

Étape 2: Affecter chaque point au centre le plus proche

Supposons que les centres initiaux soient $\mu_1 = (1,1)$ et $\mu_2 = (8,8)$.

$$d(x, \mu) = \sqrt{[(x_1 - \mu_1)^2 + (x_2 - \mu_2)^2]}$$

Distance euclidienne en deux dimensions.

Pour $P_2 = (1,2)$:

$d(P_2, \mu_1) = \sqrt{[(1-1)^2+(2-1)^2]} = 1$

Distance au premier centroïde.

$d(P_2, \mu_2) = \sqrt{[(1-8)^2+(2-8)^2]} = \sqrt{85} \approx 9,22$

Distance au deuxième centroïde.

Décision d'affectation

$1 < 9,22$

P_2 est donc affecté à C_1.

On répète le calcul pour P_1, P_3, …, P_6.

Exemple

Étape 2: Affecter chaque point au centre le plus proche

Avec les centres $\mu_1 = (1,1)$ et $\mu_2 = (8,8)$, les points se répartissent ainsi.

Cluster C_1 — bleu

$P_1 = (1,1)$

$P_2 = (1,2)$

$P_3 = (2,1)$

$|C_1| = 3$

Cluster C_2 — orange

$P_4 = (8,8)$

$P_5 = (8,9)$

$P_6 = (9,8)$

$|C_2| = 3$

Important : les centroïdes n'ont pas encore été recalculés. Cette première partition sert à calculer les nouvelles moyennes.

Exemple

Étape 3: Recalculer les centroïdes

Une fois les points affectés, on remplace chaque ancien centre par la moyenne des points de son cluster.

$$\mu_k = (1 / |C_k|) \Sigma_{x \in C_k} x$$

La moyenne est calculée coordonnée par coordonnée.

- Le cluster C_1 contient P_1, P_2 et P_3 : on calcule la moyenne des abscisses et la moyenne des ordonnées.
- Le cluster C_2 contient P_4, P_5 et P_6 : on effectue exactement le même calcul.
- Les nouveaux centroïdes deviennent les centres de référence pour l'itération suivante.

Exemple

Étape 3: Recalculer les centroïdes

Les points de chaque cluster sont moyennés séparément sur chaque dimension.

Nouveau centroïde μ_1

$\mu_1 = ((1+1+2)/3 , (1+2+1)/3)$

$\mu_1 = (4/3 , 4/3)$

$\mu_1 \approx (1{,}33 ; 1{,}33)$

Nouveau centroïde μ_2

$\mu_2 = ((8+8+9)/3 , (8+9+8)/3)$

$\mu_2 = (25/3 , 25/3)$

$\mu_2 \approx (8{,}33 ; 8{,}33)$

Les nouveaux centres se déplacent vers le milieu géométrique des points qui leur sont affectés.

Exemple

Étape 3: Recalculer les centroïdes

Où intervient l'inertie intra-classe ?

Elle mesure la compacité des clusters : plus les points sont proches de leur centroïde, plus l'inertie est faible.

$$J = \sum_{k=1}^{K} \sum_{x \in C_k} \|x - \mu_k\|^2$$

Somme des distances euclidiennes au carré entre chaque point et le centroïde de son cluster.

- Pour chaque cluster, calculer la distance au carré entre chaque point et son centroïde.
- Additionner les distances au carré dans le cluster.
- Additionner ensuite les contributions des K clusters.
- K-means cherche à diminuer J au fil des itérations.

L'inertie est un critère d'optimisation, pas une étape d'affectation. Elle permet de suivre la qualité de la partition.

Exemple

Étape 3: Recalculer les centroïdes

Où intervient l'inertie intra-classe ?

Comparons l'inertie avant et après le recalcul des centroïdes.

Avant mise à jour

Centres : (1,1) et (8,8)

Pour C_1 : 0 + 1 + 1 = 2

Pour C_2 : 0 + 1 + 1 = 2

J_initial = 2 + 2 = 4

Après mise à jour

Pour C_1 autour de (4/3,4/3) :

2/9 + 5/9 + 5/9 = 4/3

Pour C_2 : même résultat = 4/3

J_nouveau = 4/3 + 4/3 = 8/3 ≈ 2,67

L'inertie diminue de 4 à environ 2,67 : les nouveaux centres représentent mieux les points de chaque cluster.

Exemple

Étape 4: Répéter jusqu'à la convergence

A **Affecter les points**

Calculer la distance aux K centres

B **Recalculer les centres**

Moyenne de chaque cluster

C **Comparer**

Centres ou affectations ont-ils changé ?

Si les affectations ne changent plus (ou si le déplacement des centres devient très faible), l'algorithme s'arrête.

En pratique, on fixe aussi un nombre maximal d'itérations pour garantir l'arrêt.

Pseudo-code complet de K-means

Entrée : données X, nombre de clusters K, tolérance ε, itérations max.

1. Initialiser $\mu_1, \ldots, \mu_k$ (par exemple avec K-means++).
2. Répéter :
   a. Pour chaque point x_i, calculer $d(x_i, \mu_k)$ pour $k = 1,\ldots,K$.
   b. Affecter x_i au cluster C_k de distance minimale.
   c. Pour chaque cluster C_k, recalculer $\mu_k = (1/|C_k|) \Sigma x_i$.
   d. Calculer l'inertie $J = \Sigma_k \Sigma_{x \in C_k} \|x - \mu_k\|^2$.
   e. Arrêter si les affectations sont stables ou si le déplacement $< \varepsilon$.
3. En sortie : clusters, centroïdes, inertie ; évaluer éventuellement la silhouette.

À chaque itération, l'affectation et la mise à jour sont répétées dans cet ordre.

K-means : avantages, limites et cas d'utilisation

Avantages

→ Simple à comprendre et à programmer

→ très rapide

→ complexité O(n·K·t) (t itérations)

→ passe à l'échelle sur de grands jeux

→ résultat facile à interpréter grâce aux centroïdes

→ implémenté partout.

Limites

→ K doit être connu

→ dépend de l'initialisation (minimum local)

→ suppose des clusters convexes, sphériques, de taille et densité proches

→ sensible aux outliers et à l'échelle des variables

→ ne gère pas le bruit

→ inadapté aux variables catégorielles.

K-means : avantages, limites et cas d'utilisation

Erreurs fréquentes

→ Oublier de normaliser

→ choisir K uniquement par minimisation de J

→ interpréter un cluster comme une vraie classe

→ ne lancer qu'une seule initialisation.

Cas d'utilisation.

Segmentation de clientèle, quantification d'images (réduction du nombre de couleurs), compression, pré-regroupement de documents, initialisation d'autres modèles.

CAH : définition, ascendant/descendant, matrice des distances

Définition.

La **classification ascendante hiérarchique construit une hiérarchie de partitions emboîtées, représentée par un dendrogramme**. Elle ne demande pas K à l'avance : **on le choisit après coup en coupant l'arbre.**

Approche ascendante (agglomérative)

On part de n clusters d'un seul point puis, à chaque étape, on fusionne les deux clusters les plus proches, jusqu'à un seul cluster. C'est la CAH proprement dite.

Approche descendante (divisive)

On part d'un cluster unique contenant tout, puis on le scinde récursivement (ex. DIANA). Plus coûteuse (nombre de scissions possibles très grand), moins utilisée.

CAH : définition, ascendant/descendant, matrice des distances

Matrice des distances

Matrice symétrique n×n dont l'entrée (i,j) est $d(x_i,x_j)$, diagonale nulle. À chaque fusion, on supprime les deux lignes/colonnes fusionnées et on en ajoute une pour le nouveau cluster, calculée avec le critère de liaison.

Limites

Coût $O(n^2)$ en mémoire et $O(n^2–n^3)$ en temps ; fusions irréversibles ; sensible au bruit et au choix de la liaison.

En résumé

Entrée : matrice de distances + liaison.

Sortie : dendrogramme.

Déterministe : même résultat à chaque exécution.

CAH : critères de liaison

Single (lien simple)

$$D(A,B) = \min_{\{a \in A, b \in B\}} d(a,b)$$

Distance entre les deux points les plus proches. Effet de chaîne : relie des groupes par un pont de points.

Complete (lien complet)

$$D(A,B) = \max_{\{a \in A, b \in B\}} d(a,b)$$

Distance entre les deux points les plus éloignés : clusters compacts de petit diamètre ; sensible aux outliers.

Average (lien moyen)

$$D(A,B) = (1/|A||B|) \; \Sigma_{\{a \in A\}} \Sigma_{\{b \in B\}} d(a,b)$$

Moyenne de toutes les distances par paires : compromis entre single et complete.

Ward

$$\Delta(A,B) = (|A||B|/(|A|+|B|)) \cdot \|\mu_A - \mu_B\|^2$$

μ_A, μ_B : centroïdes. Augmentation d'inertie intra-classe due à la fusion ; on fusionne la paire minimisant Δ. Clusters équilibrés, la plus utilisée (distance euclidienne).

CAH : exemple lien complet

Points 1D : A=1, B=2, C=6, D=7, E=15. Distance = |différence|. Critère : lien complet (max).

1. **Matrice initiale :** AB=1, AC=5, AD=6, AE=14, BC=4, BD=5, BE=13, **CD=1**, CE=9, DE=8.

2. **Fusion 1 (h=1) :** plus petite distance = 1 (AB et CD à égalité) → {A,B}. **Fusion 2 (h=1)** → {C,D}.

3. **Mise à jour (max) : D({A,B},{C,D}) = max(AC,AD,BC,BD) = 6** ; D({A,B},E) = max(14,13) = 14 ; D({C,D},E) = max(9,8) = 9.

4. **Fusion 3 (h=6) :** la plus petite est 6 → {A,B,C,D}. Puis **D({A,B,C,D},E) = max(14,13,9,8) = 14**.

5. **Fusion 4 (h=14) :** E rejoint le cluster restant → un seul cluster.

Résultat : Hauteurs de fusion : 1, 1, 6, 14. Le grand saut de 6 à 14 indique que couper entre les deux donne 2 clusters naturels : {A,B,C,D} et {E}. Avec le lien simple on aurait obtenu les hauteurs 1, 1, 4, 8 : la liaison change l'arbre.

CAH : exemple

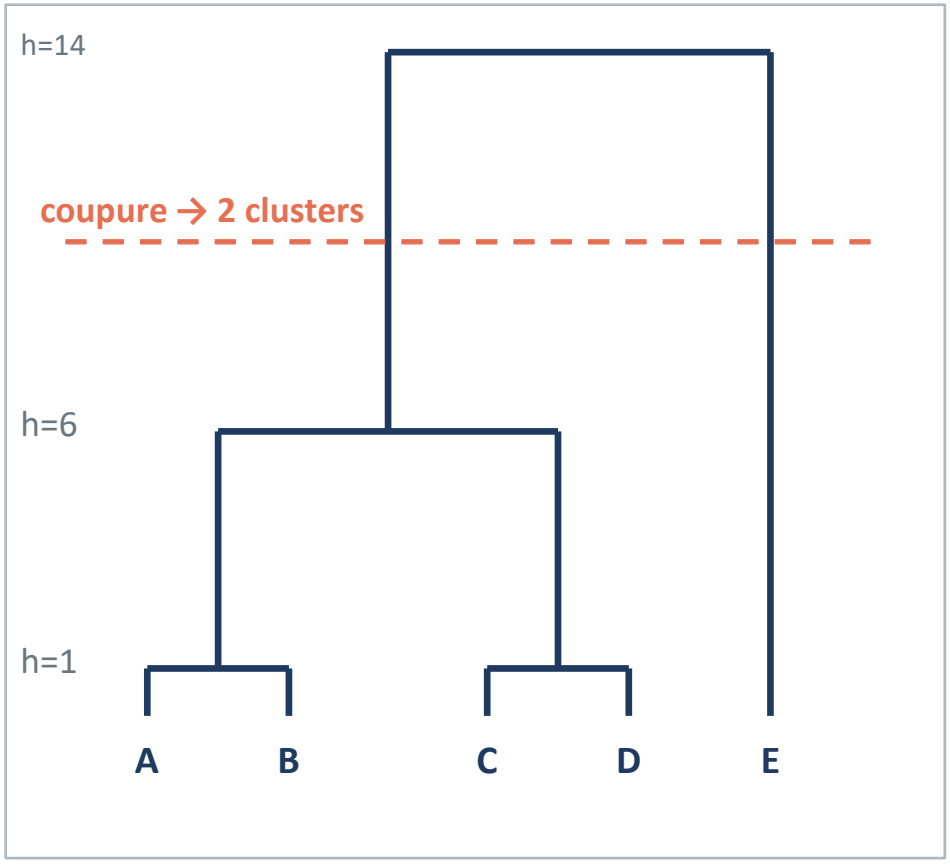


Fig. 3 – Dendrogramme (lien complet)

Lecture de la figure

Étape 1. A–B et C–D fusionnent à la hauteur 1 (petits ponts du bas).

Étape 2. {A,B} et {C,D} fusionnent à 6 : la barre horizontale haute relie les deux sous-arbres.

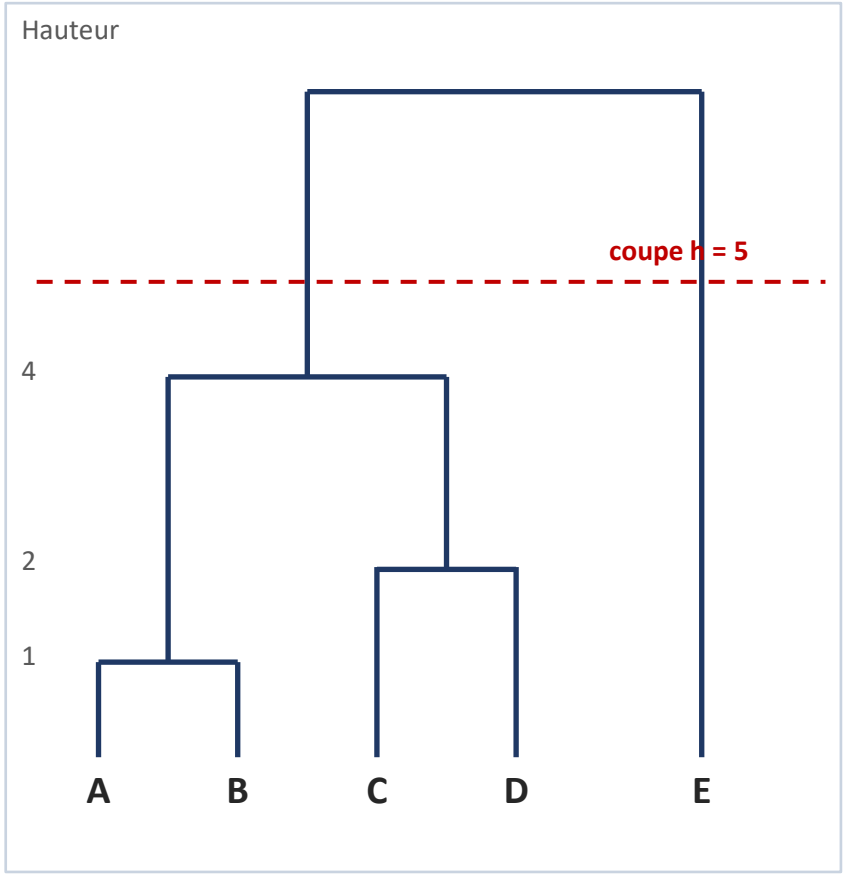
Étape 3. E rejoint à 14 : c'est un point isolé, sa branche est longue.

Lecture. Plus la barre est haute, plus les clusters fusionnés sont dissemblables. Les deux sous-arbres A-B et C-D sont proches en interne.

Limite. L'ordre des feuilles sur l'axe horizontal est arbitraire : seule la hauteur a un sens.

CAH : exemple lien simple

	A=1	B=2	C=6	D=8	E=15
A	0	1	5	7	14
B	1	0	4	6	13
C	5	4	0	2	9
D	7	6	2	0	7
E	14	13	9	7	0



Étape 1. Distance minimale = 1 (A, B) → fusion {A,B} à la hauteur 1.

Étape 2. Minimale suivante = 2 (C, D) → fusion {C,D} à la hauteur 2.

Étape 3. d({A,B},{C,D}) = min(5, 7, 4, 6) = 4 → fusion à la hauteur 4.

Étape 4. d({A,B,C,D}, E) = min(14, 13, 9, 7) = 7 → fusion finale à la hauteur 7.

Coupe à h = 5. Deux groupes : {A,B,C,D} et {E}.

CAH : exemple

CAH avec Ward : exemple pas à pas

Points : A = 1, B = 2, C = 6, D = 9. Formule : $\Delta(X,Y) = (|X|\cdot|Y| / (|X|+|Y|)) \times (\mu_X - \mu_Y)^2$. À chaque étape, on fusionne la paire au plus petit Δ.

Étape 1 : matrice des Δ

	B	C	D
A	0,5	12,5	32
B		8	24,5
C			4,5

Plus petit : $\Delta(A,B) = (1\times1/2) \times 1^2 = 0{,}5$. On fusionne **AB** (centre 1,5).

Étape 2 : on recalcule

	C	D
AB	13,5	37,5
C		4,5

Ex. : $\Delta(AB,C) = (2\times1/3) \times (6 - 1{,}5)^2 = 13{,}5$. Plus petit : C-D. On fusionne **CD** (centre 7,5).

Étape 3 : dernière fusion

	CD
AB	36

$\Delta = (2\times2/4) \times (7{,}5 - 1{,}5)^2 = 36$. Hauteurs : 0,5 → 4,5 → 36. Le grand saut final donne **2 clusters : {A,B} et {C,D}**.

CAH : choisir le nombre de clusters

Principe.

On coupe le dendrogramme par une ligne horizontale ; le nombre de clusters est le nombre de branches coupées. Couper haut → peu de clusters grossiers ; couper bas → beaucoup de clusters fins.

Critère du plus grand saut.

On cherche la plus grande différence entre deux hauteurs de fusion successives et on coupe dans ce saut : fusionner au-delà regrouperait des clusters trop éloignés. Dans notre exemple : saut de 6 à 14 → 2 clusters.

Autres critères.

Courbe des inerties (Ward) : tracer la perte d'inertie à chaque fusion et repérer le coude ; silhouette moyenne pour chaque nombre de clusters ; seuil de distance fixé par le métier (scipy : fcluster).

Limites. Le choix reste en partie subjectif ; un arbre très « serré » n'offre pas de saut net ; la coupe est la même hauteur partout, ce qui convient mal à des clusters d'échelles différentes.

CAH : choisir le nombre de clusters

Critère	K-means	CAH
Principe	Partition en K groupes par centroïdes	Hiérarchie de fusions successives
Nombre de clusters	K fixé à l'avance	Choisi après, par coupe du dendrogramme
Résultat	Une seule partition	Toutes les partitions de 1 à n clusters
Déterminisme	Dépend de l'initialisation	Déterministe
Complexité	$O(n \cdot K \cdot t)$: gros volumes	$O(n^2)$ mémoire, $O(n^2–n^3)$ temps : petits jeux
Formes de clusters	Sphériques, convexes	Dépend de la liaison (Ward : sphérique, single : allongés)
Usage conseillé	Grandes bases, K connu	Petits échantillons, besoin de visualiser la hiérarchie

Interprétation : k-means est plus rapide, CAH plus riche en information. On peut les combiner : k-means pour réduire les données en quelques dizaines de centres, puis CAH sur ces centres.

DBSCAN : c'est quoi ?

Principe

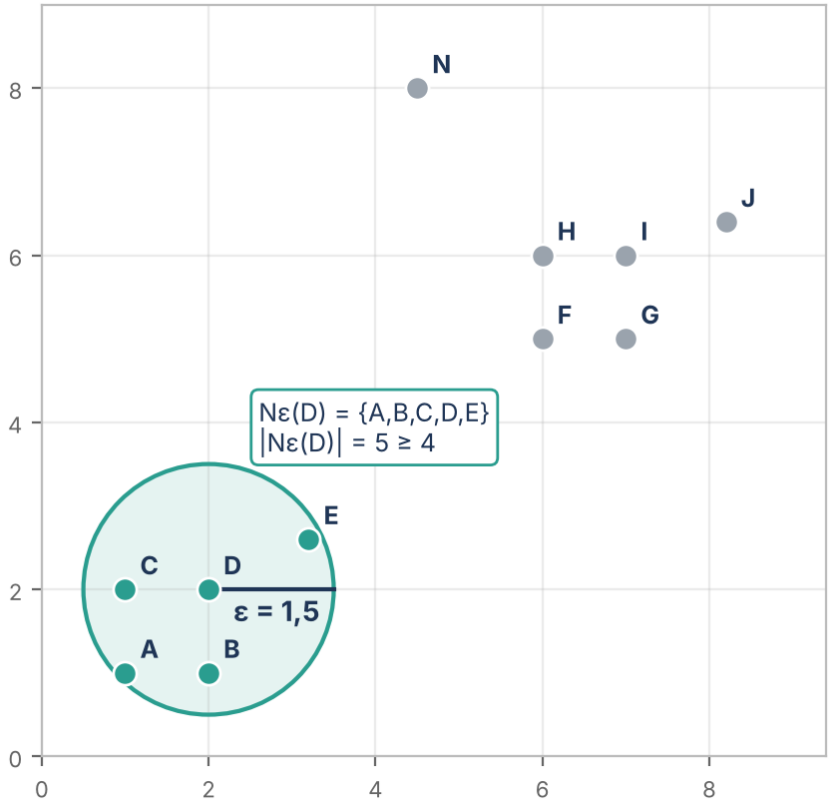
DBSCAN (Density-Based Spatial Clustering of Applications with Noise) regroupe les points situés dans des zones denses et met à part les points isolés : le bruit.

Idée simple

Pense à une foule : si une personne a assez de voisins autour d'elle, elle fait partie du groupe, et le groupe s'étend de proche en proche.

Atouts

1. pas besoin de choisir le nombre de clusters k
2. formes quelconques
3. détecte les valeurs aberrantes.



Le cercle de rayon ε autour de D contient 5 points : D est dans une zone dense.

Deux paramètres, trois types de points

ε (eps). rayon du voisinage autour d'un point.

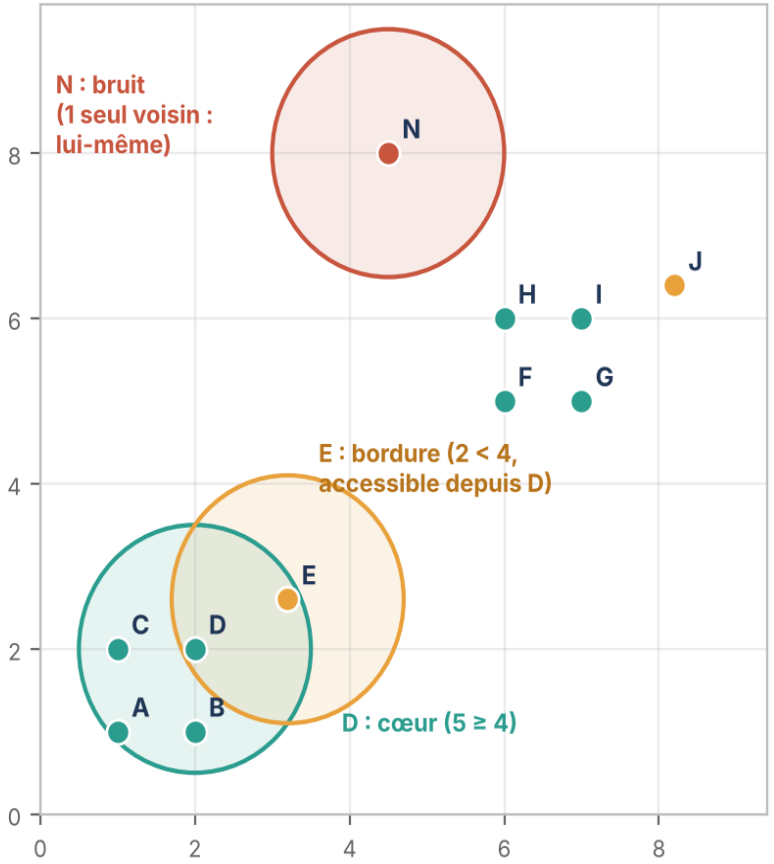
MinPts. nombre minimal de points (lui-même inclus) pour parler de zone dense. Ici : ε = 1,5 et MinPts = 4.

$$d(p,q) = \sqrt{((xp - xq)^2 + (yp - yq)^2)}$$
$$N\varepsilon(p) = \{ q \in D : d(p,q) \leq \varepsilon \}$$
$$p \text{ est cœur } \Leftrightarrow |N\varepsilon(p)| \geq MinPts$$

Cœur : ≥ MinPts voisins dans son cercle ε.

Bordure : pas assez de voisins, mais dans le cercle d'un cœur.

Bruit : ni cœur, ni voisin d'un cœur.



D est cœur (5 ≥ 4), E est bordure (2 < 4), N est bruit (1 < 4).

L'algorithme en 5 étapes

1 **Initialiser**
Fixer ε et MinPts ; tous les points sont « non visités ».

2 **Voisinage**
Pour un point p non visité, calculer $N\varepsilon(p) = \{ q : d(p,q) \leq \varepsilon \}$.

3 **Tester p**
Si $|N\varepsilon(p)| < MinPts$: p est noté bruit (provisoire).
Sinon p est cœur : on crée un cluster C.

4 **Étendre C**
Ajouter les voisins de p à C ; chaque voisin cœur ajoute à son tour ses propres voisins.

5 **Répéter**
Recommencer avec un autre point non visité, jusqu'à tous les avoir traités.

Accessibilité par densité

q est directement accessible depuis p si :

$$q \in N\varepsilon(p) \text{ et } |N\varepsilon(p)| \geq MinPts$$

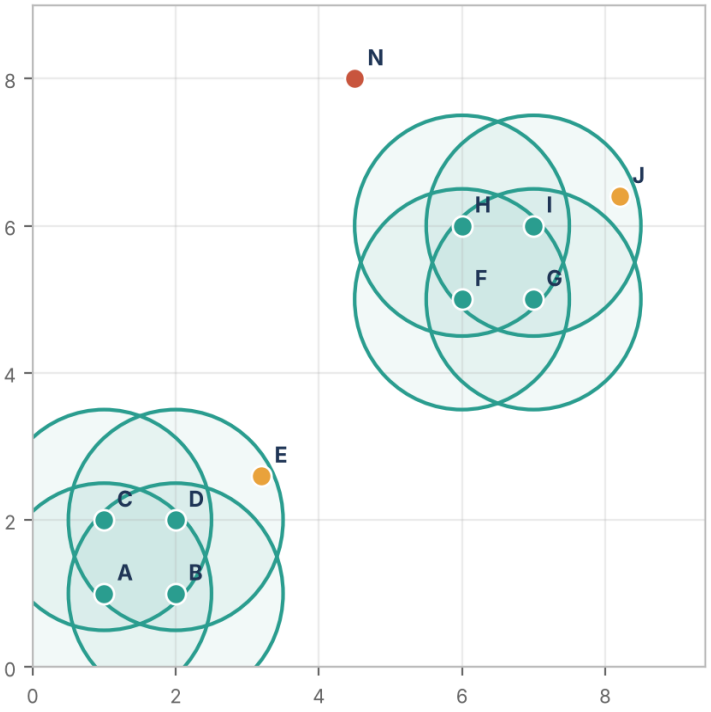
Un cluster est l'ensemble des points reliés par une chaîne de tels pas.

Un bruit provisoire peut être rattaché plus tard à un cluster : il devient alors bordure.

Exemple détaillé : données et voisinages

Étapes 1-2 : calcul de Nε(p) pour les 11 points
(ε = 1,5 ; MinPts = 4)

Point	(x, y)	Nε(p)	|Nε|	Type
A	(1; 1)	{A, B, C, D}	4	cœur
B	(2; 1)	{A, B, C, D}	4	cœur
C	(1; 2)	{A, B, C, D}	4	cœur
D	(2; 2)	{A, B, C, D, E}	5	cœur
E	(3,2; 2,6)	{D, E}	2	bordure
F	(6; 5)	{F, G, H, I}	4	cœur
G	(7; 5)	{F, G, H, I}	4	cœur
H	(6; 6)	{F, G, H, I}	4	cœur
I	(7; 6)	{F, G, H, I, J}	5	cœur
J	(8,2; 6,4)	{I, J}	2	bordure
N	(4,5; 8)	{N}	1	bruit

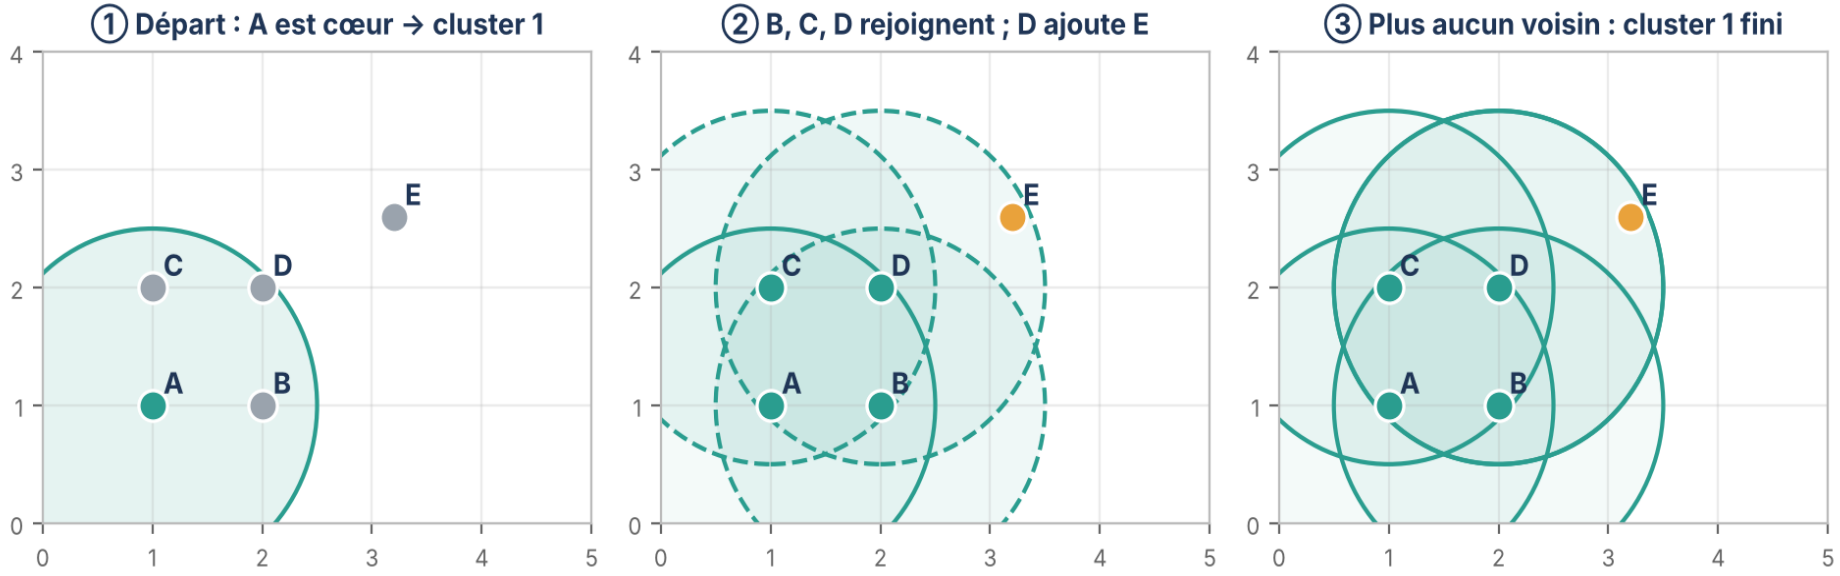


Les cercles ε sont tracés autour des points cœur (en vert).

$$d(A,D) = \sqrt{((2-1)^2 + (2-1)^2)} = 1{,}41 \leq 1{,}5 \rightarrow D \in N\varepsilon(A)$$

$$d(B,E) = \sqrt{((3{,}2-2)^2 + (2{,}6-1)^2)} = 2{,}00 > 1{,}5 \rightarrow E \notin N\varepsilon(B)$$

Exemple : étapes 3-4, naissance du cluster 1



A est cœur : $|N_\varepsilon(A)| = |\{A,B,C,D\}| = 4 \geq 4$. Nouveau cluster C1 = {A} puis on ajoute ses voisins B, C, D.

D est cœur : $|N_\varepsilon(D)| = 5 \geq 4$, donc E rejoint C1. E a seulement 2 voisins (< 4) : bordure, on ne l'étend pas.

Fin : B et C n'apportent aucun nouveau point. C1 = {A, B, C, D, E}, plus rien à explorer.

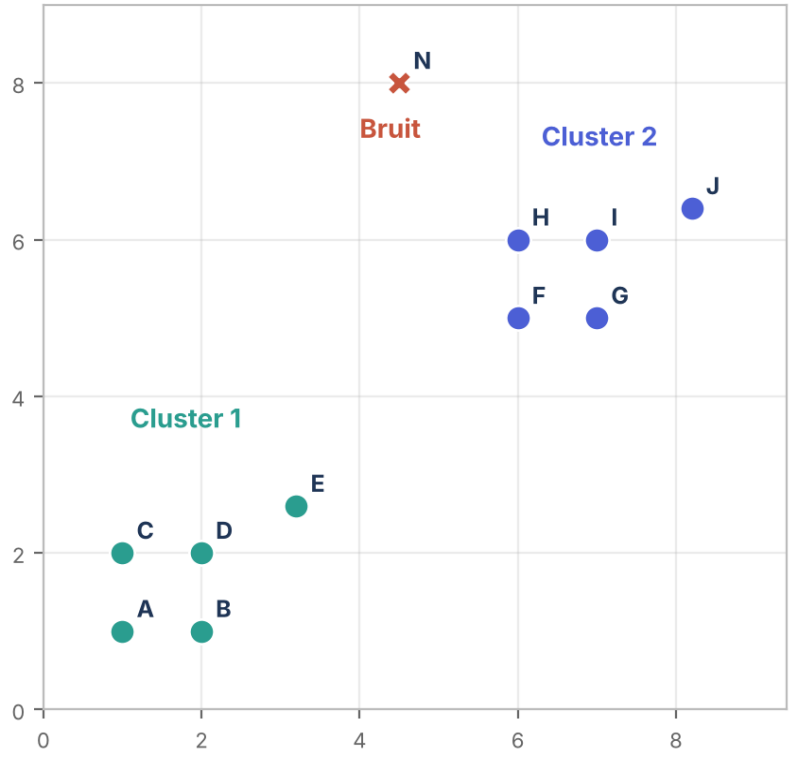
Exemple : étape 5, cluster 2, bruit et résultat

Cluster 2. F est non visité : $|N\varepsilon(F)| = 4 \geq 4$, c'est un cœur. On crée C2, G, H, I (cœurs) s'ajoutent, puis J par I : bordure.

Bruit. N : $|N\varepsilon(N)| = 1 < 4$, et aucun cœur à moins de ε. Il reste bruit.

Fin. Tous les points sont visités : l'algorithme s'arrête.

$$C1 = \{A, B, C, D, E\}$$
$$C2 = \{F, G, H, I, J\}$$
$$Bruit = \{N\}$$



Résultat final : 2 clusters et 1 point de bruit (croix rouge).