الجزائريـــــــة الديمقراطيـــــة الشعبيـــة
وزارة التعليـــــم العـــــالي و البحـــــث العلـــمي
جامعة وهران للعلوم والتكنولوجيا محمد بوضياف
كلية الريـــاضيـــات و اللإعـــلام الآلـــي
République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur Et de la Recherche Scientifique
Université des Sciences et de la Technologie d'Oran Mohamed BOUDIAF
Faculté des Mathématiques et Informatique
Département D'Informatique

Master1 ML DS-IA **Fiche TP2** Régression linéaire multiple

Dr. Ourdighi A.

Objectif

À l'issue de ce TP, vous devrez être capable de :

- explorer un jeu de données et repérer les relations entre variables explicatives et variable à expliquer ;
- estimer un modèle de régression linéaire multiple par les moindres carrés ordinaires (MCO) ;
- diagnostiquer le modèle (résidus, multicolinéarité..) ;
- sélectionner des variables et évaluer la capacité de prédiction sur un jeu de test.

2. Dataset

2.1. Jeu de données fourni : logements.csv

Le fichier logements.csv contient 150 observations simulées de logements. L'objectif est d'expliquer le prix de vente à partir de leurs caractéristiques. Il ne comporte aucune valeur manquante.

Variable	Type	Description
surface_m2	quantitative	Surface habitable en m²
nb_pieces	quantitative (entier)	Nombre de pièces
age_annees	quantitative	Âge du bien en années
distance_centre_km	quantitative	Distance au centre-ville en km
garage	binaire (0/1)	1 si le logement possède un garage, 0 sinon
prix_keuros	quantitative	Variable à expliquer : prix de vente en milliers d'euros

3. Travail Demandé

Partie A : Exploration des données

1. Importer le fichier avec pandas, afficher les 5 premières lignes, la taille du jeu de données et les types des variables (head, shape, info).
2. Calculer les statistiques descriptives (describe) et vérifier l'absence de valeurs manquantes.
3. Tracer l'histogramme de la variable prix_keuros et la matrice de nuages de points (pairplot de seaborn).
4. Calculer et représenter (heatmap) la matrice des corrélations. Quelles variables sont les plus liées au prix ? Quelles variables explicatives sont fortement corrélées entre elles ?

Partie B : Estimation du modèle complet

On considère le modèle :

$$\textbf{prix} = \beta_0 + \beta_1 \cdot \textbf{surface} + \beta_2 \cdot \textbf{pièces} + \beta_3 \cdot \textbf{âge} + \beta_4 \cdot \textbf{distance} + \beta_5 \cdot \textbf{garage} + \varepsilon$$

5. Écrire le modèle sous forme matricielle $Y = X\beta + \varepsilon$ et rappeler l'estimateur des MCO $\hat{\beta} = (X^T X)^{-1} X^T Y$.
6. Calculer $\hat{\beta}$ « à la main » avec numpy (sans bibliothèque de régression), puis l'estimer avec statsmodels.OLS. Vérifier que les résultats coïncident.
7. Interpréter chaque coefficient estimé (signe, ordre de grandeur, unité, « toutes choses égales par ailleurs »).
8. **Lire le tableau summary() : donner R^2, R^2 ajusté, statistique de Fisher et sa p-value. Le modèle est-il globalement significatif ? (facultatif)**
9. **À l'aide des tests de Student, indiquer quelles variables sont significatives au seuil de 5 %. Construire un intervalle de confiance à 95 % pour le coefficient de surface_m2. (facultatif)**

Partie C : Diagnostic du modèle

10. Tracer les résidus en fonction des valeurs ajustées. Observe-t-on une structure (non-linéarité, hétéroscédasticité) ?
11. Vérifier la normalité des résidus (histogramme, QQ-plot).

Partie D : Prédiction et validation

12. Séparer les données en un échantillon d'apprentissage (80 %) et un échantillon de test (20 %) avec train_test_split (random_state=42).
13. Ajuster le modèle final sur l'apprentissage avec LinearRegression de scikit-learn, puis calculer le RMSE, le MAE et le R^2 sur l'échantillon de test.
14. Comparer ces performances à celles du modèle à une seule variable (surface_m2). Que constatez-vous ?
15. Prédire le prix d'un logement de 85 m^2, 3 pièces, 10 ans, situé à 5 km du centre, avec garage, et donner un intervalle de prédiction à 95 %.

Partie E : Pour aller plus loin (bonus)

16. **Standardiser les variables et comparer l'importance relative des coefficients.**
17. **Estimer une régression Ridge et une régression Lasso (RidgeCV, LassoCV). Comparer les coefficients à ceux des MCO, notamment pour nb_pieces et surface_m2.**

4. Rendu

- Un notebook Jupyter (.ipynb) ou un script Python commenté.
- Chaque réponse doit comporter le code, le résultat et une interprétation rédigée.
- à rendre sous une semaine.