Université des sciences et de la technologie d'Oran Mohamed Boudiaf – USTO MB
Faculté des Mathématiques et de l'Informatique - Département d'informatique
1 ier année Master – S1 - 2026 / 2027

Méthodes d'optimisation

Chapitre 1 : Fondamentaux de l'optimisation

Cours 1

Partie 1: *Introduction à l'optimisation*

Présenté Par : Dr. BEKKOUCHE .I

Plan cours 1
Chapitre 1 partie 1 : *Introduction à l'optimisation*

- Définition
- Classification des problèmes d'optimisation
- Optimisation convexe vs non convexe
- Normes et distances

Introduction à l'optimisation

Définition

Définition

Optimiser, c'est chercher la meilleure configuration possible d'un système, celle qui satisfait au mieux un critère donné parmi toutes les configurations envisageables.

L'optimisation est une branche des mathématiques. En pratique, on part d'un problème concret, on le modélise, puis on le résout mathématiquement : de façon analytique pour un problème d'optimisation, de façon numérique pour un programme mathématique.

Modéliser un problème d'optimisation en 3 étapes

1.Variables de décision *Ce que l'on cherche à optimiser*

1. Ce sont les éléments du système sur lesquels on peut agir.
2. On suppose qu'il y en a ***n***, chacune étant un nombre réel.
3. On les regroupe dans un vecteur $x=(x_1,x_2,\dots,x_n)^T \in R_n$.

2.Fonction objectif (ou coût) Ce que l'on maximise ou minimise

1. Elle décrit la performance du système pour une configuration donnée des variables.
2. C'est une fonction $J:R_n \rightarrow R$.
3. Le but est de **minimiser** ou **maximiser** cette fonction.

3.Contraintes *Restrictions imposées aux variables*

1. Les variables ne peuvent pas prendre n'importe quelle valeur.
2. On définit un ensemble $U \subset R^n$.
3. La solution doit vérifier $x \in U$.

Définition générale

Un **problème d'optimisation** consiste à rechercher, parmi un ensemble de solutions admissibles, celle qui minimise (ou maximise) une fonction dite *fonction objectif* (ou fonction coût).

Pour résumer on peut dire que pour décrire un problème d'optimisation on se donne

1. **Une fonction** $J : IR_n \rightarrow IR$ (fonction coût)
2. **Un ensemble** $U \subset IR_n$ (ensemble des contraintes)

On cherche à minimiser J sur U, c'est à dire, on cherche $x^* \in U$ tel que

$$J(x^*) = \min_{x \in U} J(x)$$

ou équivalent

$$J(x^*) \leq J(x), \ \forall x \in U$$

Définition générale

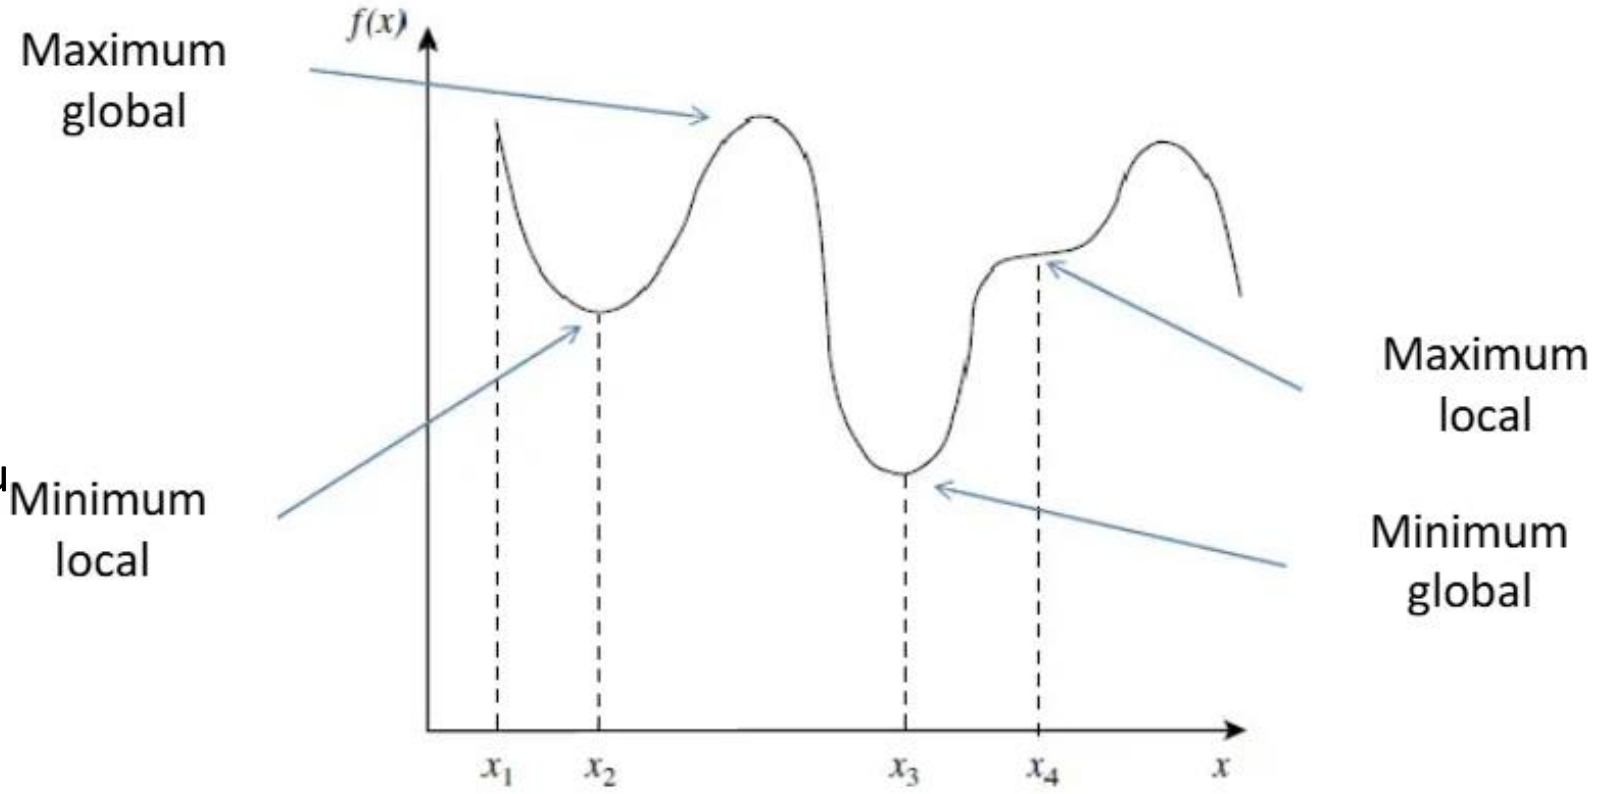
On distingue:

- Le minimum (ou maximum) **relatif** ou **local**

x* tel que f(x*) ≤ f(x) pour tout x dans un voisinage de x*.

- Le minimum (ou maximum) **absolu** ou **global**

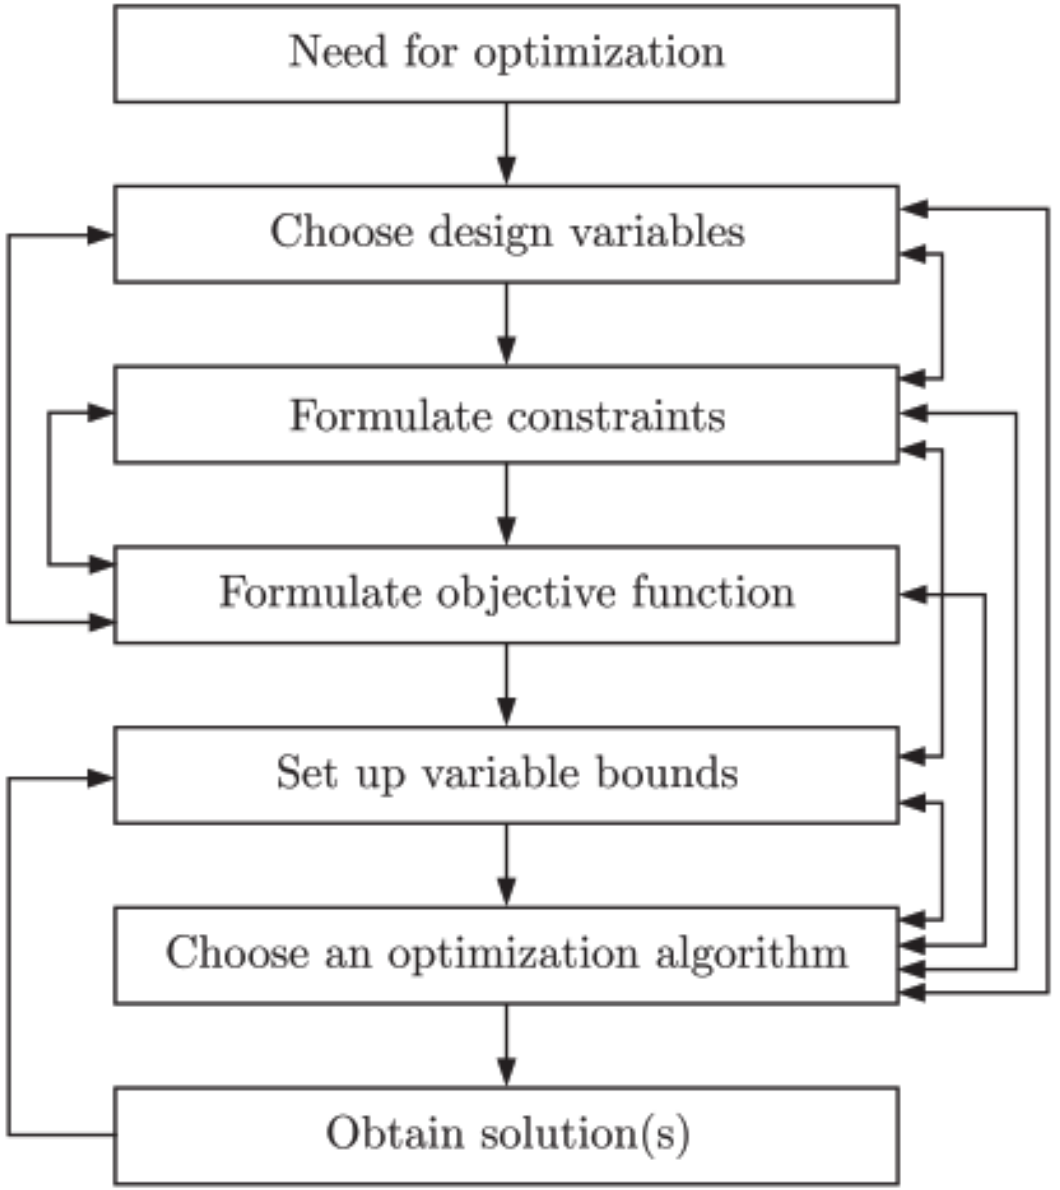
x* ∈ C tel que f(x*) ≤ f(x) pour tout x ∈ C.



Organigramme de la procédure de conception optimale.

les étapes généralement impliquées dans le processus de formulation d'une conception optimale:

- la première étape consiste à reconnaître la nécessité de recourir à l'optimisation pour un problème de conception donné.
- Ensuite, le concepteur doit sélectionner les variables de conception pertinentes pour ce problème.
- La formulation de problèmes de conception optimale implique d'autres considérations, telles que les contraintes, la fonction objectif et les bornes des variable
- le processus de conception optimale suit généralement une certaine hiérarchie, bien qu'une considération puisse influencer une autre.



Exemple : Production d'une usine

1. Variables de décision

•L'usine fabrique deux produits : **A** et **B.**

•Les variables de décision sont :

- x_1 = nombre d'unités de produit A à fabriquer
- x_2 = nombre d'unités de produit B à fabriquer

•Donc $x=(x_1,x_2)^T$.

2. Fonction objectif

- Chaque produit rapporte un bénéfice :

➢ Produit **A → 40 €** par unité

➢ Produit **B → 30 €** par unité

- La fonction objectif est :

$$J(x)=40x_1+30x_2$$

3.Contraintes

- Temps de production disponible : **100 heures**.
- Produit **A** demande **2 h/unité,** produit **B** demande **1 h/unité.**

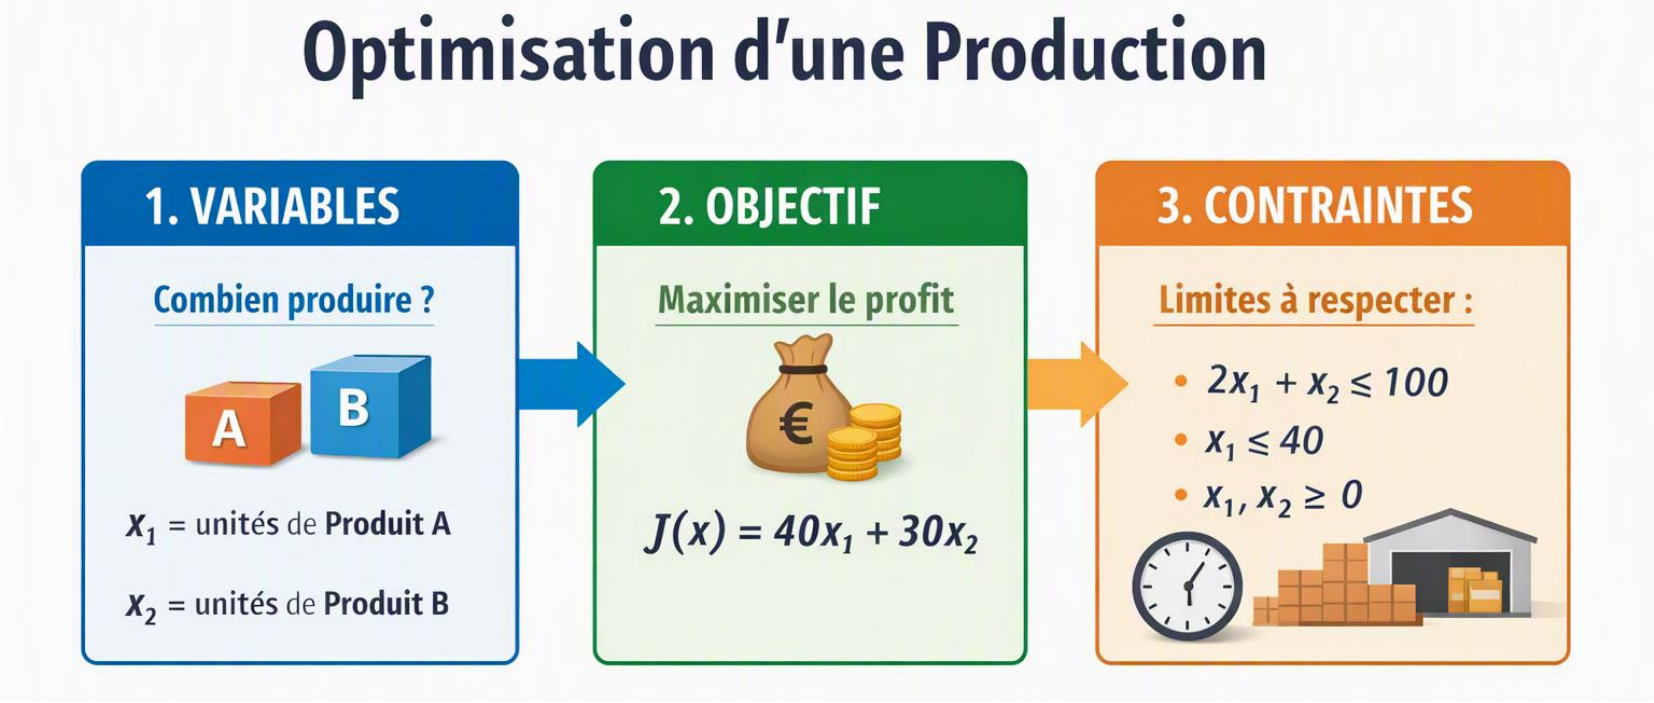
$$2x_1+x_2\leq 100$$

- Capacité de stockage : **maximum 40** unités de produit **A**.

$$x_1\leq 40$$

- Bien sûr, $x_1,x_2\geq 0$.

Exemple : Production d'une usine



Données du problème

- **Variables :** x_1 (produit A), x_2 (produit B)
- **Objectif :** maximiser $J(x)=40x_1+30x_2$
- **Contraintes** :

$$\begin{cases} 2x_1+x_2 \leq 100 \\ x_1 \leq 40 \\ x_1, x_2 \geq 0. \end{cases}$$

Exemple : Production d'une usine

Données du problème

- **Variables :** x_1 (produit A), x_2 (produit B)
- **Objectif :** maximiser $J(x)=40x_1+30x_2$
- **Contraintes** :

$$\begin{cases} 2x_1+x_2 \leq 100 \\ x_1 \leq 40 \\ x_1, x_2 \geq 0. \end{cases}$$

Étapes de résolution

1.Tracer les contraintes dans le plan (x1,x2) :

1. $2x_1+x_2=100$ → droite de production
2. $x_1=40$ → limite de stockage
3. $x_1,x_2 \geq 0$ → premier quadrant

L'ensemble des solutions possibles U est le polygone formé par ces droites

2. Déterminer les sommets du domaine faisable : A(40,20), B(30,40), C(20,60), D(10,80), E (0,100)

3. Évaluer la fonction objectif aux sommets :

J(A)=40(40)+30(20)=2200
J(B)=40(30)+30(40)=2400
J(C)=40(20)+30(60)=2600
J(D)=40(10)+30(80)=2800
J(E)=40(0)+30(100)=3000

Solution optimale : Maximum de J(x) atteint en B(0,100) car l'usine doit produire **0 unité de A** et **100 unités de B** pour un **profit maximal de 3000 €**.

Domaines d'application de l'optimisation

L'optimisation intervient dans de nombreux domaines:

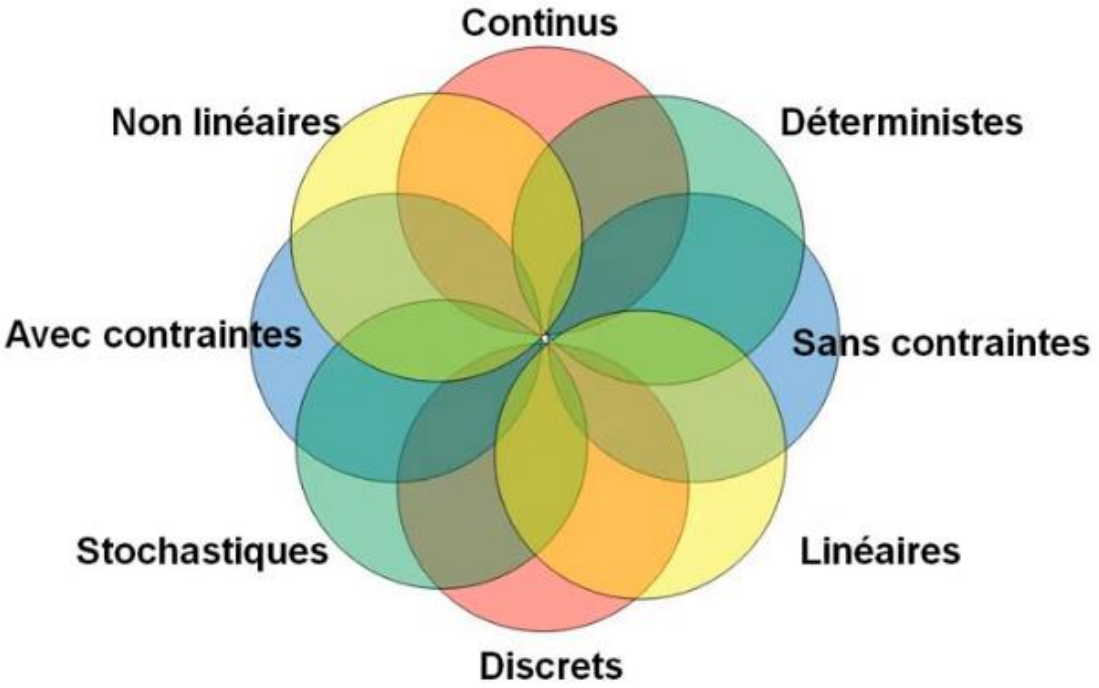
- **en recherche opérationnelle** (problème de transport, économie, gestion de stocks...)
- **en analyse numérique** (approximation/résolution de systèmes linéaires, non linéaires...)
- **en automatique** (modélisation de systèmes, filtrage...)
- **en ingénierie** (dimensionnement de structures, conception optimale de systèmes (réseaux, ordinateurs...))

Introduction à l’optimisation

Classification des problèmes d’optimisation

Classification des problèmes d'optimisation

Critère	Catégories
Présence de contraintes	sans contrainte / avec contraintes
Nature des variables	continue / discrète (combinatoire) / mixte
Structure de f, g, h	linéaire (LP), quadratique (QP), non linéaire (NLP)
Géométrie	convexe / non convexe
Nature des données	déterministe / stochastique
Nombre d'objectifs	mono-objectif / multi-objectif
Dépendance au temps	statique / dynamique



Classification des problèmes d'optimisation

1. *Présence de contraintes*

- **Optimisation sans contrainte :** On cherche à minimiser ou maximiser une fonction J(x) sans aucune restriction sur les variables.

Exemple: Trouver le minimum de $J(x)=x^2+4x+5$. (Pas de restriction sur x.)

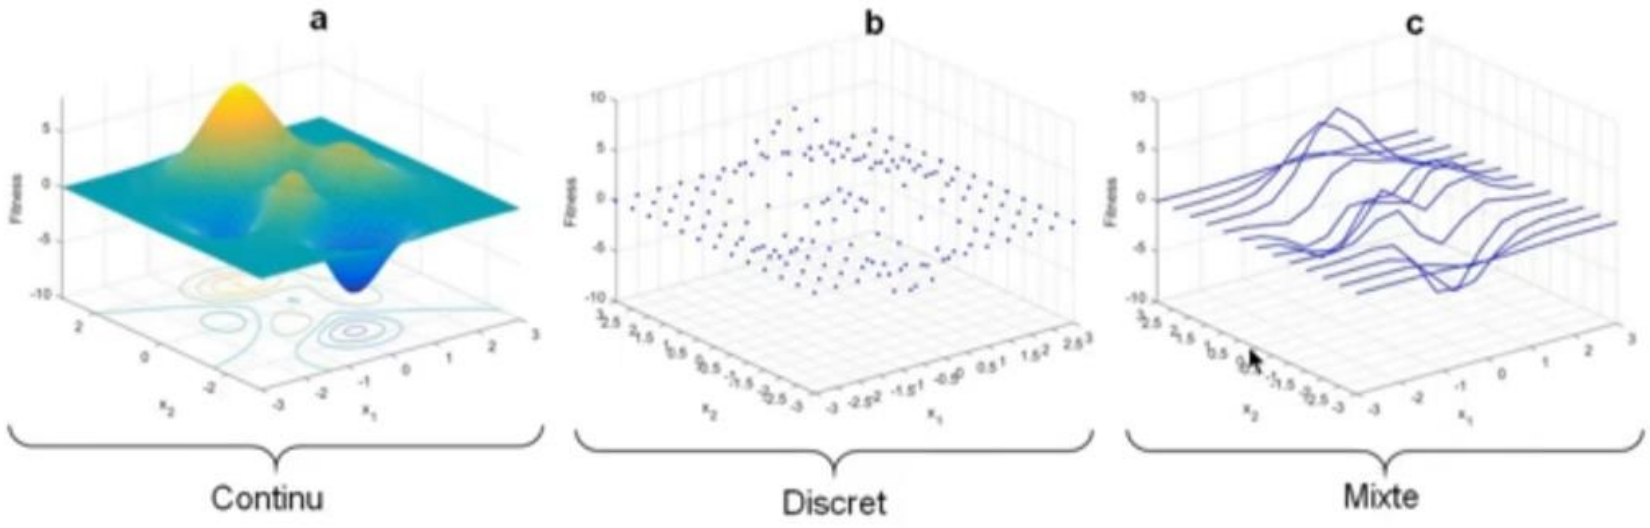
- **Optimisation avec contraintes :** Les variables doivent respecter des conditions (égalités ou inégalités, nécessitant des méthodes dédiées).

Exemple: Maximiser $J(x_1,x_2)=40x_1+30x_2$ *sous* $2x_1+x_2\leq 100$, $x_1\leq 40$ et $x_1,x_2\geq 0$

Classification des problèmes d'optimisation

2. Nature des variables

- **Optimisation continue :** Les variables de décision peuvent prendre n'importe quelle valeur réelles. Plus simple à résoudre. **Exemple** : Choisir la vitesse optimale d'un véhicule ($v \in R$) pour minimiser la consommation d'essence.
- **Optimisation discrète :** Les variables de décision prennent des valeurs a partir d'un ensemble discret (entières, binaires, objets, …etc). **Exemple** : Problème du voyageur de commerce (*TSP*) est de trouver l'ordre optimal de visite des villes (Variables entières pour ordre des villes)
- **Optimisation mixte :** Le mélange de variables continues et discrètes. **Exemple** : Planification de production où : x_1= nombre entier de machines utilisées et x_2 = quantité continue de matière première.



Classification des problèmes d'optimisation

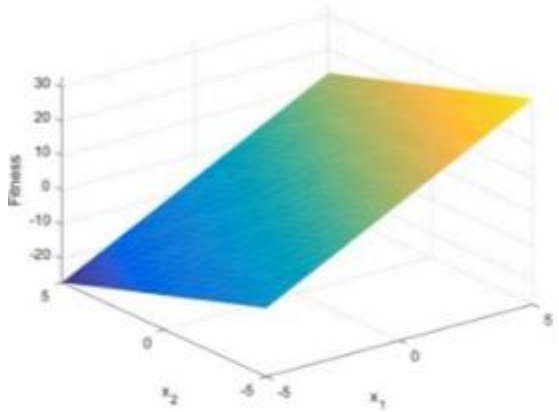
3. Structure de f, g, h

- **Optimisation linéaire:** La fonction objectif et les contraintes sont représentées par des relations **linéaires**.

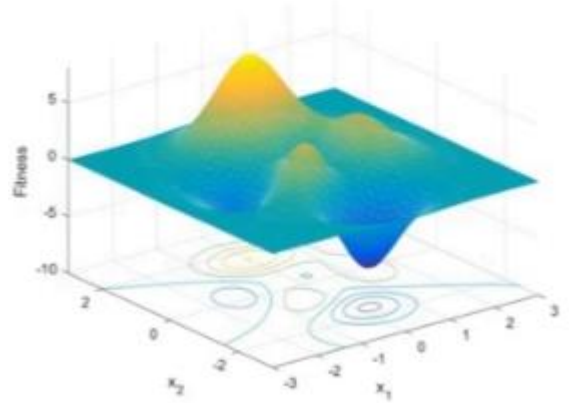
Exemple: *Maximiser* $J(x_1,x_2)=3x_1+2x_2$ *sous* $x_1+x_2\leq 10$, $x_1,x_2\geq 0$.

- **Optimisation non linéaire:** La fonction objectif ou les contraintes sont représentées par des relations **non linéaires**.

Exemple: Minimiser $J(x)=sin(x)+x^2$



Fonction objectif linéaire



Fonction objectif non linéaire

Classification des problèmes d'optimisation

4. Nature des données

- **Optimisation déterministe:** données du modèle sont connues avec précision et ne supposent aucune probabilité ou incertitude

Exemple: Problème de transport avec coûts fixes connus (Toutes les données sont certaines)

- **Optimisation stochastique :** Les données ou paramètres comportent de l'incertitude (aléatoires), c.à.d. des modèles qui ont un caractère aléatoire (Fonction objectif aléatoire ou contraintes aléatoire)

Exemple: Gestion de stock avec demande variable, recuit simulé, algorithmes génétiques, etc.

Classification des problèmes d'optimisation

5. Nombre d'objectifs

- **Optimisation mono-objectif :** Une seule fonction à optimiser.

Exemple: Minimiser le coût de production uniquement.

- **Optimisation multi-objectif :** On cherche à optimiser plusieurs critères simultanément (compromis entre plusieurs objectifs contradictoires)

Exemple: Minimiser le coût **et** maximiser la qualité d'un produit.

Classification des problèmes d'optimisation

6. Dépendance au temps

- **Optimisation statique :** La fonction objectif et contraintes **ne change pas** avec le temps

Exemple : Choisir une fois pour toutes la quantité à produire ce mois-ci.

- **Optimisation dynamique :** La fonction objectif et contraintes **change** avec le temps

Exemple: Gestion d'un réservoir d'eau sur plusieurs jours → décisions successives selon l'évolution du niveau.

Introduction à l'optimisation

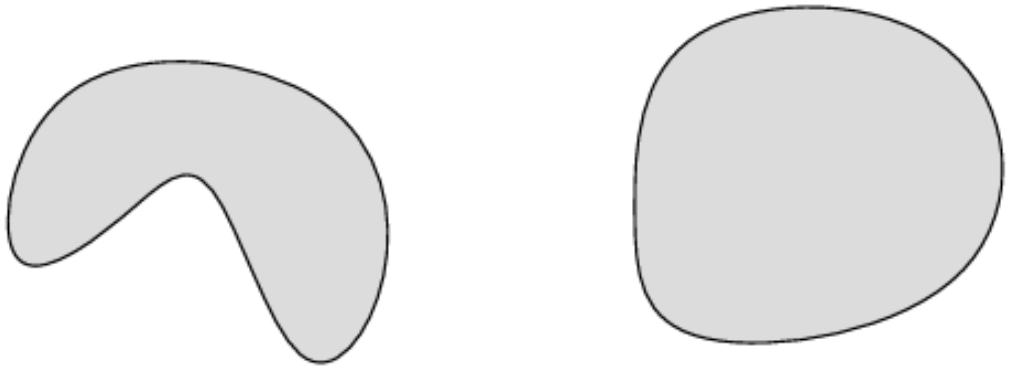
Optimisation convexe vs non convexe

λ

Optimisation convexe vs non convexe

Convexité

Une partie C de R^n est convexe si pour tout $x,y \in C$ et tout $t \in [0,1]$, on a $tx+(1-t)y \in C$. L'espace R^n tout entier, en particulier, est convexe. Il est aisé de vérifier que l'intersection d'un nombre quelconque de convexes est convexe.

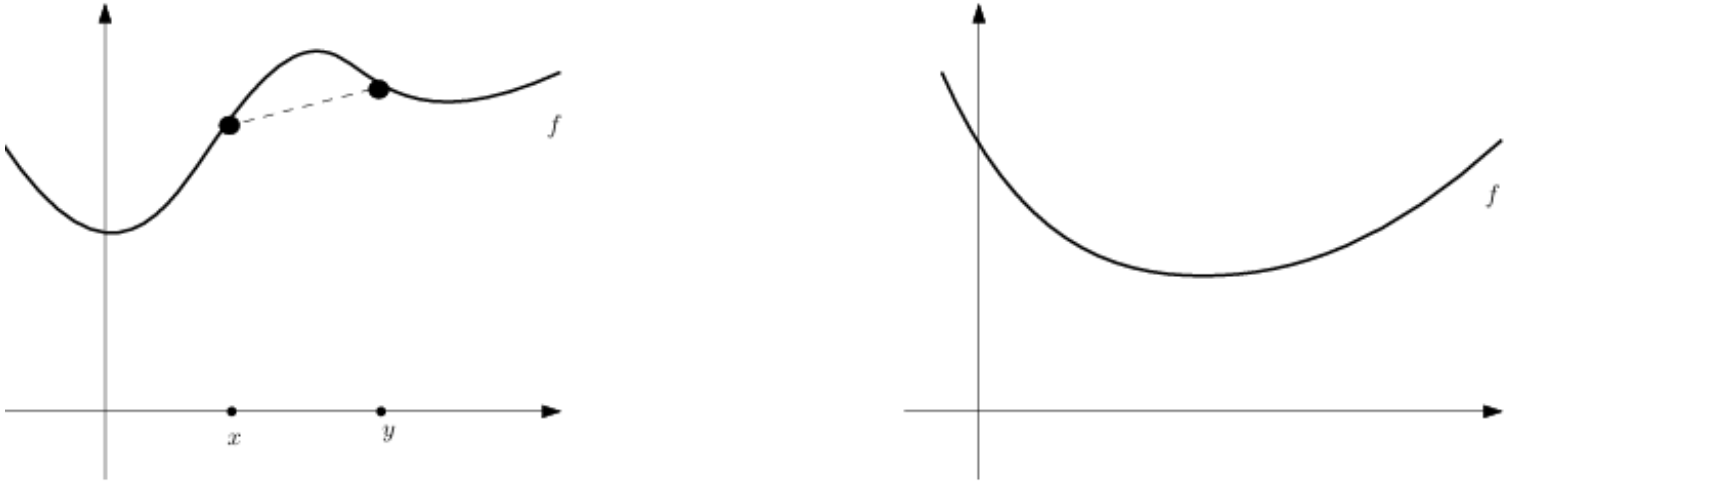


Deux sous-ensembles du plan. Celui de gauche n'est pas convexe, celui de droite l'est.

Optimisation convexe vs non convexe

Convexité

Une partie C de R^n est convexe si pour tout $x,y \in C$ et tout $t \in [0,1]$, on a $tx+(1-t)y \in C$. L'espace R^n tout entier, en particulier, est convexe. Il est aisé de vérifier que l'intersection d'un nombre quelconque de convexes est convexe.



– Deux fonctions réelles d'une variable réelle. Celle de gauche n'est pas convexe, celle de droite

Optimisation convexe vs non convexe

Fonction convexe

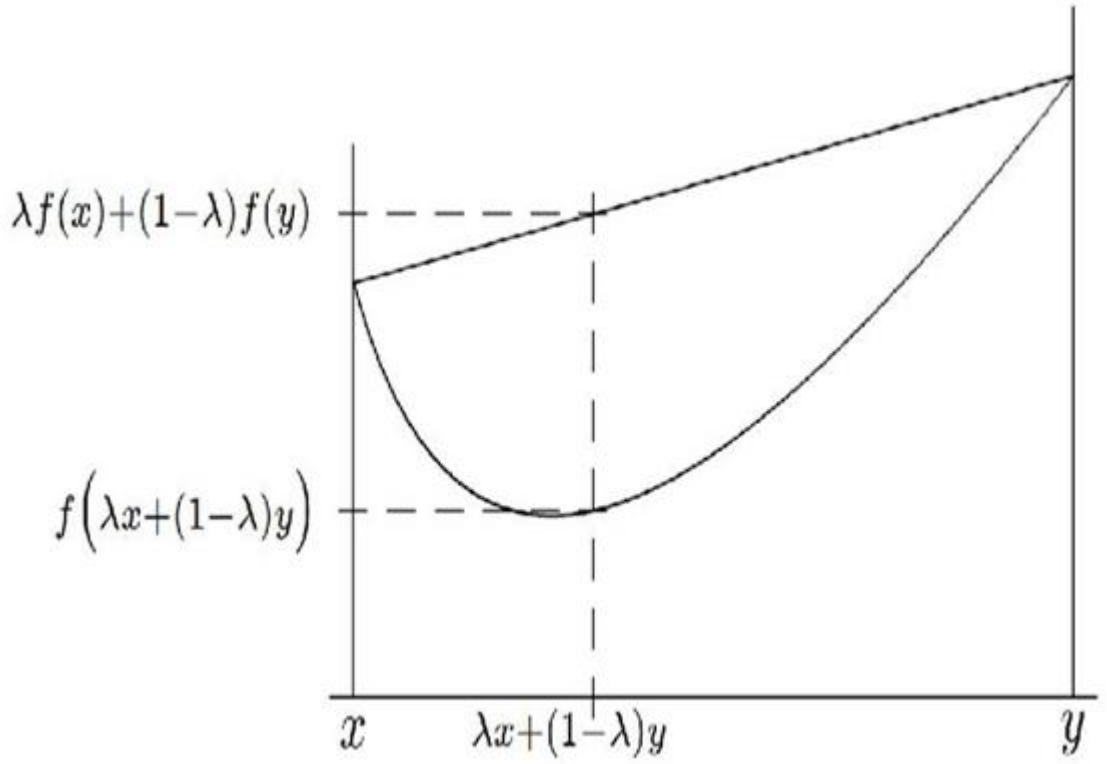
Soit la fonction ***f***, définie sur un intervalle ***C*** de $\boldsymbol{R^n}$, telle que $\boldsymbol{x,y \in C}$ et $\boldsymbol{\lambda \in [0,1]}$, on dit que la fonction ***f*** est **convexe** (ou plus exactement **strictement convexe**) si elle vérifie e l'inégalité suivante:

$$f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda) f(y)$$

Remarque Si la fonction $\boldsymbol{f(x) \in R}$, elle est **convexe** si on a $\boldsymbol{f''(x) \geq 0}$ sur le domaine de définition

Optimisation convexe vs non convexe

Exemple d'une fonction convexe



Optimisation convexe vs non convexe

Fonction convexe

Soit $U \subset R^n$ un ensemble convexe et $f : U \rightarrow R$ une fonction.

1. On dit que f est **convexe** sur U si

$$f(t\,y + (1-t)x) \leq t\,f(y) + (1-t)f(x),\ \forall x, y \in U,\ \forall t \in [0,1]$$

2. On dit que f est **strictement convexe** sur U si

$$f(t\,y + (1-t)x) < t\,f(y) + (1-t)f(x),\ \forall x, y \in U \text{ avec } x = y,\ \forall t \in]0,1[$$

3. On dit que f est **fortement convexe** sur U s'il existe $\alpha > 0$ tel que

$$f(t\,y + (1-t)x) \leq t\,f(y) + (1-t)f(x) - \alpha t(1-t)\,\|y - x\|^2,\ \forall x, y \in U,\ \forall t \in [0,1]$$

4. On dit que f est **concave** (respectivement strictement concave, respectivement fortement concave) si $-f$ est **convexe** (respectivement strictement convexe, respectivement fortement convexe)

Optimisation convexe vs non convexe

Exercice: Démontrer que l'ensemble définie par $\Omega = \{ Z \in R^n : a'Z \geq \beta \}$, ou $a \in R^n$ et $\beta \in R$, est convexe, Ω est appelé demi-espace (halfspace).

Solution:

Soit $Z = \lambda X+(1-\lambda)Y$ pour $\lambda \in [0,1]$. Alors :

$$a'Z = a'(\lambda X+(1-\lambda)Y)$$

$$=\lambda a'X+(1-\lambda)a'Y$$

$$\geq\lambda\beta+(1-\lambda)\beta = \beta \text{ (on a } \lambda\geq 0 \text{ et } (1-\lambda) \geq 0 \text{)}$$

$$a'Z \geq \beta \Rightarrow Z \in \Omega$$

par conséquent, Ω est un ensemble convexe.

Optimisation convexe vs non convexe

1. Convexe

- Un ensemble est convexe si, pour deux points x, y, tout le segment $\lambda x+(1-\lambda)y$ reste dans l'ensemble.
- Une fonction f est convexe si :

$$f(\lambda x+(1-\lambda)y) \leq \lambda f(x)+(1-\lambda)f(y), \forall \lambda \in [0,1]$$

- **Conséquence** : tout minimum local est aussi un minimum global.

2. Non convexe

- L'ensemble ou la fonction présente des "creux" ou "indentations".
- Plusieurs minima locaux possibles.
- Les algorithmes peuvent se bloquer dans une solution sous-optimale.

Optimisation convexe vs non convexe

1. Convexe

Exemple :

- Minimiser $f(x)=x^2$ → parabole convexe, solution unique en x=0.
- Problème de portefeuille financier quadratique (QP).
- Régression logistique (fonction de perte convexe).

2. Non convexe

Exemple :

- Minimiser $f(x)=\sin(x)+x^2$ → plusieurs minima locaux.
- Entraînement d'un réseau de neurones profond.
- Problème du voyageur de commerce (combinatoire).

Optimisation convexe vs non convexe

Comparaison

Aspect	Convexe	Non convexe
Paysage	Bol unique, une vallée	Vallées multiples, crêtes
Solution	Minimum global garanti	Risque de minima locaux
Méthodes	Gradient descent simple, programmation linéaire/quadratique	Métaheuristiques, recuit simulé, algorithmes génétiques
Exemples	Régression linéaire, SVM, programmation linéaire	Réseaux de neurones, TSP, optimisation combinatoire complexe
Fiabilité	Résultats reproductibles	Résultats variables selon initialisation

Introduction à l'optimisation

Normes et distances

(euclidienne, p-norme, norme matricielle)

Normes et distances

- En mathématiques comme en optimisation, la notion de **distance** est essentielle pour mesurer la “taille” d’un vecteur ou la “proximité” entre deux points.
- Cette mesure repose sur les **normes**, qui sont des fonctions associant à chaque vecteur un nombre réel représentant sa longueur ou son amplitude.

Pourquoi les normes sont importantes ?

- Elles permettent de définir la **géométrie** d’un espace (distance, angles, orthogonalité).
- Elles servent à analyser la **stabilité** des algorithmes numériques.
- Elles sont utilisées dans de nombreux domaines : optimisation, machine Learning, traitement du signal, calcul matriciel.

Normes et distances

Trois grandes familles étudiées

1.Norme euclidienne (2-norme) : distance classique “à vol d’oiseau”.

2.p-normes : généralisation, incluant la norme Manhattan (p=1) et la norme max (p=∞).

3.Normes matricielles : mesurent la taille ou la puissance d’une matrice (ex. Frobenius, norme induite).

Définition axiomatique d'une norme.

Une application $\|\cdot\| : \mathbb{R}^n \to \mathbb{R}_+$ est une norme si :

1.$\|x\| \geq 0$, et $\|x\| = 0 \Leftrightarrow x = 0$ (définie positive) ;

2.$\|\alpha x\| = |\alpha| \cdot \|x\|$ pour tout scalaire α (homogénéité) ;

3.$\|x + y\| \leq \|x\| + \|y\|$ (inégalité triangulaire).

Normes et distances

Norme euclidienne (norme 2) :

$\|x\|_2 = \sqrt{(\Sigma_i x_i^2)} = \sqrt{(x^T x)}$

C'est la norme induite par le produit scalaire canonique $\langle x,y \rangle = \sqrt{x^T y}$.

Exemple : distance entre deux points (x_1,y_1) et $(x_2,y_2) \rightarrow \sqrt{(x_1-x_2)^2+(y_1-y_2)^2}$.

Normes et distances

p-norme (norme de Hölder), p ≥ 1 :

$\|x\|_p = (\Sigma_i \, |x_i|^p)^{(1/p)}$

Cas particuliers :

- **p = 1** (norme "Manhattan") : $\|x\|_1 = \Sigma_i \, |x_i|$ favorise la parcimonie (peu de coordonnées non nulles).
- **p = 2** : norme euclidienne.
- **p → ∞** : $\|x\|_\infty = \max_i \, |x_i|$ (norme du maximum, ou "Tchebychev").

Toutes les p-normes sur $\mathbb{R}^n$ sont **équivalentes** (topologiquement) : il existe des constantes **c**, ***C > 0*** telles que **$c\|x\|_a \leq \|x\|_b \leq C\|x\|_a$** pour toute paire de normes — conséquence de la dimension finie.

Normes et distances

Norme matricielle induite (norme d'opérateur):

Pour $\mathbf{A \in \mathbb{R}^{m \times n}}$, la norme induite par une norme vectorielle $\|\cdot\|$ est :

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|$$

Cas particuliers :

- **Norme spectrale (induite 2)** : $\|A\|_2 = \sigma_{max}(A)$, la plus grande valeur singulière de A.
- **Norme induite 1** : max des sommes des valeurs absolues par colonne.
- **Norme induite ∞** : max des sommes des valeurs absolues par ligne.

Normes et distances

Comparaison

Norme	Intuition	Exemple d'usage
Euclidienne (L2)	Distance "à vol d'oiseau"	Géométrie, physique
p-norme (Lp)	Distance généralisée	Machine learning, optimisation
Norme matricielle	Taille/puissance d'une matrice	Analyse de stabilité, calcul numérique

$$\|x\|_2 = \sqrt{\sum_i x_i^2}$$

$$\|x\|_1 = \sum_i |x_i|$$

$$\|x\|_\infty = \max_i |x_i|$$

Fin de la presentation