Université des sciences et de la technologie d'Oran Mohamed Boudiaf – USTO MB
Faculté des Mathématiques et de l'Informatique - Département d'informatique
1 ier année Master – S1 - 2026 / 2027

Méthodes d'optimisation

Chapitre 2 : Optimisation convexe et programmation mathématique

Cours 4
Partie 1: Optimisation convexe

Présenté Par : Dr. BEKKOUCHE .I

Plan cours 4
Chapitre 2 partie 1 : Optimisation convexe

- Propriétés et théorèmes fondamentaux.
- Dualité et interprétation en IA.

Optimisation convexe

Introduction

Introduction

Rappels express

- **Fonction convexe** : sa courbe est un « bol » (le segment entre deux points de la courbe reste au-dessus de la courbe).
- **Ensemble convexe** : le segment entre deux de ses points reste dans l'ensemble (disque plein : oui ; anneau : non).
- **Problème convexe** : minimiser une fonction convexe sur un ensemble convexe (contraintes d'inégalité convexes, contraintes d'égalité linéaires).

Introduction

Test pratique pour une fonction à plusieurs variables :

- calculer la Hessienne et regarder ses valeurs propres.
- Si elles sont toutes ≥ 0 en tout point, f est convexe. (Une valeur propre négative = une direction où la courbe « s'effondre » comme une selle.)

Fonction	Hessienne	Valeurs propres	Verdict
$f(x, y) = x^2 + xy + y^2$	[[2, 1], [1, 2]]	1 et 3	tout ≥ 0 : **convexe**
$f(x, y) = x^2 - y^2$	[[2, 0], [0, −2]]	2 et −2	une valeur négative : **non convexe** (selle)

Optimisation convexe

Propriétés et théorèmes fondamentaux

Propriétés et théorèmes fondamentaux

Théorème 1 — tout minimum local est global.

- ***En mots* :** dans un problème convexe, si l'algorithme s'arrête dans une vallée, c'est la plus profonde.
- ***Idée de la preuve* :** supposons que x* soit un minimum local et qu'un point y soit strictement plus bas.
- Sur le segment qui relie x* à y, la **convexité place la courbe sous la corde** : les points du segment très proches de x* sont donc plus bas que x*. Cela contredit le fait que x* est un minimum local.

Propriétés et théorèmes fondamentaux

Théorème 1 — tout minimum local est global

Exemple: On lance la descente de gradient (pas 0,1, 300 itérations) depuis deux points de départ différents :

Fonction	Départ $x_0 = 0,5$	Départ $x_0 = -0,5$	Conclusion
$f(x) = x^2$ (convexe)	→ 0	→ 0	même résultat, toujours le minimum global
$f(x) = x^4 - x^2$ (non convexe)	→ 0,7071	→ −0,7071	deux vallées : le résultat dépend du départ

Dans le cas non convexe, rien ne dit quelle vallée est la meilleure (ici elles sont à égalité, mais en général ce n'est pas le cas).

Propriétés et théorèmes fondamentaux

Théorème 2 — l'ensemble des solutions optimales est convexe

- ***En mots*** **:** si deux points x_1 et x_2 sont optimaux, tous les points entre eux le sont aussi.
- ***Exemple*** **:** $f(x) = \max(0, |x| - 1)$ est convexe et vaut 0 pour tout x de l'intervalle $[-1, 1]$: l'ensemble des solutions est l'intervalle $[-1, 1]$, qui est convexe.
- Un problème convexe a donc soit une solution unique, soit tout un « plateau » connecté de solutions, jamais deux solutions isolées.

Propriétés et théorèmes fondamentaux

Théorème 3 — condition d'optimalité

- ***Sans contrainte* :** pour f convexe et dérivable, $\nabla f(x^*) = 0$ **suffit** pour que x^* soit un minimum global (au chapitre 1, ce n'était que nécessaire).
- ***Avec contrainte $x \in C$* :** x^* est optimal si et seulement si **aucune direction admissible ne fait descendre f**, c'est-à-dire $\nabla f(x^*)^T(y - x^*) \geq 0$ pour tout y de C.

Propriétés et théorèmes fondamentaux

Théorème 3 — condition d'optimalité

***Exemple* :** min $(x - 3)^2$ sur l'intervalle C = [0, 2].

La solution attendue est $x^* = 2$ (le point de C le plus proche de 3).

Vérification : $\nabla f(2) = 2(2 - 3) = -2$, donc $\nabla f(2) \cdot (y - 2) = -2(y - 2)$.

Pour tout $y \leq 2$, cette quantité est ≥ 0.

Si on testait $x = 1{,}5$: $\nabla f(1{,}5) = -3$, et en prenant $y = 2$, on obtient $-3 \cdot 0{,}5 = -1{,}5 < 0$: il existe une direction admissible qui fait descendre f, donc 1,5 n'est pas optimal.

Propriétés et théorèmes fondamentaux

Théorème 4 — KKT suffisantes et dualité forte

Pour un problème convexe, les conditions KKT (chapitre 1) sont **suffisantes**, et la dualité est « forte » sous une condition simple (voir chapitre 2 : Dualité et interprétation en IA).

Propriétés et théorèmes fondamentaux

Boîte à outils : reconnaître une fonction convexe

- La **somme** de fonctions convexes est convexe ; le **maximum** de fonctions convexes est convexe.
- Une fonction convexe composée avec une fonction **affine** (Ax + b) reste convexe.
- Les **normes** sont convexes ; l'**intersection** d'ensembles convexes est convexe.

Propriétés et théorèmes fondamentaux

Fonction	Convexe ?	Justification
x^2, e^x, $\|x\|$	oui	$f'' \geq 0$, ou $\max(x, -x)$
$\max(0, x)$	oui	maximum de deux fonctions affines
$-\log(x)$, pour $x > 0$	oui	$f'' = 1/x^2 > 0$
$\|Ax - b\|^2$ (moindres carrés)	oui	norme composée avec une fonction affine, puis carré
log(1 + e^(−y·w^{T}x)) (perte logistique)	oui	convexe en w (l'entraînement d'une régression logistique est un problème convexe)
x^3 sur $\mathbb{R}$	non	$f'' = 6x$ change de signe
x·y	non	Hessienne indéfinie (valeurs propres ±1)
Perte d'un réseau de neurones profond	en général non	voir chapitre 3

Propriétés et théorèmes fondamentaux

Méthode pour vérifier qu'un problème est convexe

1. La fonction objectif est-elle convexe ? *(Hessienne $\succeq 0$, ou règles ci-dessus)*
2. Chaque contrainte d'inégalité **$g_i(x) \leq 0$: g_i** est-elle convexe ?
3. Chaque contrainte d'égalité **$h_j(x) = 0$: h_j** est-elle affine ?

Donc si trois fois « oui » : problème convexe, on peut utiliser un solveur

Optimisation convexe

Dualité et interprétation en IA

Dualité et interprétation en IA

Principe

- À chaque problème (le **primal**), on associe un problème « miroir » (le **dual**) qui fournit une **borne** sur la valeur optimale.
- Image : pour un problème de minimisation de coût, le dual donne des **minorants garantis** : « on ne pourra jamais faire moins que ça ».
- Chercher le meilleur minorant revient à résoudre le dual.
- Quand les deux valeurs se rejoignent, la solution est prouvée optimale.

Dualité et interprétation en IA

Construction du dual en 4 étapes (pour min f sous $g(x) \leq 0$) :

1. Écrire le Lagrangien $L(x, \mu) = f(x) + \mu \cdot g(x), \quad \mu \geq 0$
2. Minimiser L par rapport à x → fonction duale $d(\mu) = \min_x L(x, \mu)$
3. Maximiser $d(\mu)$ sous $\mu \geq 0$ → problème dual
4. Comparer : $d(\mu) \leq p^*$ pour tout $\mu \geq 0$ (dualité faible)

Dualité et interprétation en IA

- **Dualité faible** (toujours vraie) : pour tout $\mu \geq 0$, $d(\mu) \leq p^*$ (valeur optimale du primal).
- **Dualité forte** (problème convexe + condition de Slater : il existe un point où toutes les inégalités sont strictes) : le meilleur minorant est exactement p*, c'est-à-dire max d = p*. Il n'y a pas d'« écart de dualité ».

Dualité et interprétation en IA

Exemple 1: **min x^2 sous $x \geq 1$.** On écrit la contrainte $g(x) = 1 - x \leq 0$.

- Lagrangien : $L = x^2 + \mu(1 - x)$.
- Minimisation en x : $\partial L/\partial x = 2x - \mu = 0$, donc $x = \mu/2$. On remplace : $d(\mu) = \mu^2/4 + \mu(1 - \mu/2) = \mathbf{\mu - \mu^2/4}$.
- Dual : max sur $\mu \geq 0$ de $\mu - \mu^2/4$. Dérivée : $1 - \mu/2 = 0$, donc $\mu = 2$ et $d(2) = 2 - 1 = \mathbf{1}$.
- Primal : $x^* = 1$, $p^* = 1$. Donc *max d = p = 1** (dualité forte).

Chaque valeur de μ fournit un minorant, qui ne dépasse jamais la valeur du primal :

μ	0	1	2	3	4
$d(\mu) = \mu - \mu^2/4$	0	0,75	**1**	0,75	0

Tous les $d(\mu)$ sont $\leq 1 = p^*$ (dualité faible), et le meilleur minorant est atteint en $\mu = 2$, qui est justement le multiplicateur KKT.

Dualité et interprétation en IA

Exemple 2: le fil rouge du chapitre 1 : min $x^2 + y^2$ sous $x + y \geq 2$. Ici $g = 2 - x - y \leq 0$.

- $L = x^2 + y^2 + \mu(2 - x - y)$. Dérivées : $2x - \mu = 0$ et $2y - \mu = 0$, donc $x = y = \mu/2$.
- $d(\mu) = 2\cdot(\mu^2/4) + \mu(2 - \mu) = \mu^2/2 + 2\mu - \mu^2 = \mathbf{2\mu - \mu^2/2}$.
- Maximum : $2 - \mu = 0$, donc $\mu = 2$ et $d(2) = 4 - 2 = \mathbf{2}$. Le primal vaut aussi 2 (en (1, 1)) ✔.

Interprétation de μ. C'est le « prix » de la contrainte (voir chapitre 1 : $\lambda = \partial f^*/\partial b$). Ici $\mu = 2$: si on exige $x + y \geq 2 + \varepsilon$, la valeur optimale augmente d'environ 2ε.

Dualité et interprétation en IA

Interprétations en IA

a) Les SVM (machines à vecteurs de support): Le SVM à marge dure cherche l'hyperplan qui sépare deux classes avec la plus grande marge :

Primal : $\boldsymbol{\min \tfrac{1}{2}\|w\|^2 \quad \text{sous} \quad y_i\,(w \cdot x_i + b) \geq 1}$ pour tout i

Dual : $\boldsymbol{\max \Sigma\alpha_i - \tfrac{1}{2}\,\Sigma\Sigma\,\alpha_i\alpha_j\,y_iy_j\,(x_i \cdot x_j)}$ sous $\alpha_i \geq 0,\ \Sigma\,\alpha_i y_i = 0$

Le dual est très utile pour deux raisons :

(1) il ne dépend des données qu'à travers les **produits scalaires** $x_i \cdot x_j$, ce qui permet le **« kernel trick »** (remplacer $x_i \cdot x_j$ par un noyau pour obtenir des frontières non linéaires) ;

(2) les α_i non nuls désignent exactement les **vecteurs de support** (complémentarité : $\alpha_i > 0$ seulement si la contrainte i est serrée).

Dualité et interprétation en IA

Exemple Deux points en 1D : $x_1 = +1$ (classe $y_1 = +1$) et $x_2 = -1$ (classe $y_2 = -1$).

•***Primal*** **:**

les contraintes sont $w + b \geq 1$ (point 1) et $w - b \geq 1$ (point 2, car $y_2(w \cdot x_2 + b) = -(-w + b) = w - b$).

Pour minimiser $\frac{1}{2}w^2$, on prend le plus petit w possible : **$w = 1, b = 0$**, valeur $\frac{1}{2} \cdot 1^2 =$ **0,5**.

•***Dual*** **:**

la condition $\Sigma\alpha_i y_i = 0$ donne $\alpha_1 - \alpha_2 = 0$, donc $\alpha_1 = \alpha_2 = \alpha$. L'objectif vaut $\Sigma\alpha - \frac{1}{2}\Sigma\Sigma\alpha_i\alpha_j y_i y_j x_i x_j$.

Les quatre termes de la double somme valent chacun $\alpha^2 \cdot (y_i y_j x_i x_j) = \alpha^2 \cdot 1$, soit $4\alpha^2$ au total.

Donc objectif = $2\alpha - 2\alpha^2$.

Maximum : $2 - 4\alpha = 0$, donc **$\alpha = 0,5$**, valeur $1 - 0,5 =$ **0,5**.

Les deux valeurs coïncident (0,5 = 0,5) :

- dualité forte.
- On retrouve aussi $w = \Sigma\alpha_i y_i x_i = 0,5 \cdot (+1)(+1) + 0,5 \cdot (-1)(-1) = 1$.
- Les deux points ont $\alpha > 0$: ce sont les deux vecteurs de support.

Dualité et interprétation en IA

b) La régularisation (Ridge, Lasso)

Un terme de pénalité $\lambda\|w\|^2$ est en réalité le **multiplicateur de Lagrange d'une contrainte de « budget »** $\|w\|^2 \leq t$. Exemple 1D : min $(w-3)^2$ sous $w^2 \leq 1$.

- KKT : $2(w-3) + 2\mu w = 0$, donc $w = 3/(1+\mu)$. La contrainte est active (le minimum libre $w = 3$ est interdit) : $w = 1$, donc **$\mu = 2$**.
- Version pénalisée : min $(w-3)^2 + \lambda w^2$ donne $w = 3/(1+\lambda)$. Avec **$\lambda = 2$**, on obtient $w = 1$: la même solution.

Plus λ est grand, plus le budget est serré : les poids sont « rétrécis » vers 0.
C'est l'effet de régularisation que l'on règle en apprentissage (par validation croisée).

Pénalité λ	Solution $w = 3/(1+\lambda)$	Budget utilisé w^2
0	3	9
0,5	2	4
2	1	1
5	0,5	0,25

Fin de la presentation